重庆工商大学学报(自然科学版)
Journal of Chongqing Technology and Business University(Natural Science Edition)
ISSN 1672-058X,CN 50-1155/N

《重庆工商大学学报(自然科学版)》网络首发论文

题目：　基于 TPE-Informer-LSTM 融合框架的股票价格预测研究
作者：　何文定，何光，邹盈
收稿日期：　2025-04-09
网络首发日期：　2025-07-03
引用格式：　何文定，何光，邹盈．基于 TPE-Informer-LSTM 融合框架的股票价格预测研究[J/OL]．重庆工商大学学报(自然科学版).
https://link.cnki.net/urlid/50.1155.N.20250703.1553.006

网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

网络首发时间：2025-07-03 16:39:41　　网络首发地址：https://link.cnki.net/urlid/50.1155.N.20250703.1553.006

基于 TPE-Informer-LSTM 融合框架的股票价格预测研究

何文定 [a]，何光 [a]，邹盈 [b]

重庆工商大学 a.数学与统计学院；b.管理科学与工程学院，重庆 400067

摘要：【目的】 为了更好地捕捉时间序列数据的长期依赖和短期波动的相互影响，提升股票价格预测的准确性和鲁棒性，提出一种融合 TPE 贝叶斯算法、Informer 与 LSTM 的改进模型，用于股票价格的预测。**【方法】**在这个改进模型中，TPE 贝叶斯算法对改进模型的超参数进行全局寻优，利用最佳超参数组合运行模型；LSTM 模块捕捉时间序列的短期变化及动态依赖关系，通过残差连接作为 Informer 模块的输入，Informer 模块通过概率稀疏自注意力机制捕捉时间序列的多尺度长期依赖以及全局信息，通过全连接层整合信息以进行预测。**【结果】**该模型在平安银行股票数据集上相较于 LSTM、CNN、Informer、Transformer 在均方误差上分别降低了约 18.5%、41.6%、58.5%、72%。同时，该模型在不同平滑天数的技术指标与多只不同领域股票数据集的预测中，预测效果均优于其余深度学习对比预测模型。**【结论】**TPE-Informer-LSTM 模型能够精准捕捉时间序列中的长期依赖和短期波动特征，表现出良好的多尺度特征捕捉能力与泛化能力，预测精度进一步得到提升，对股票价格的预测具有重要参考价值。

关键词：Informer；LSTM；股票价格预测；贝叶斯优化算法

中图分类号：TP391；C812　　**文献标识码：A**

A Study on Stock Price Prediction Based on the TPE-Informer-LSTM Fusion Framework

HE Wending[a]，HE Guang[a]，ZOU Ying[b]

Chongqing Technology and Business University a. School of Mathematics and Statistics; b. School of Management Science and Engineering, Chongqing 400067

Abstract: Purpose: 【Object】 In order to better capture the interaction between long-term dependencies and short-term fluctuations in time series data, and to improve the accuracy and robustness of stock price predictions, this paper proposes an improved model that integrates the TPE Bayesian algorithm, Informer, and LSTM for stock price prediction. **【Methods】** In this improved model, the TPE Bayesian algorithm performs global optimization of the hyperparameters of the improved model and runs the model using the optimal hyperparameter combination. The LSTM module captures short-term changes and dynamic dependencies in the time series. This information is fed into the Informer module via a residual connection. The Informer module uses a probabilistic sparse self-attention mechanism to capture multi-scale long-term dependencies and global information in the time series, and integrates the information through a fully connected layer to make predictions. **【Results】**The model achieves a reduction of 18.5%, 41.6%, 58.5%, and 72% in mean square error on Ping An Bank stock dataset compared with LSTM, CNN, Informer, and Transformer. At the same time, the model outperforms the rest of the deep learning prediction models in the prediction of technical indicators with different smoothing days and multiple stock datasets from different sectors. **【Conclusion】** The TPE-Informer-LSTM model effectively captures long-term dependencies and short-term fluctuations in time series data, demonstrating strong multi-scale feature extraction and generalization capabilities. Its improved prediction accuracy makes it a valuable reference for stock price forecasting.

Keywords: Informer; LSTM; Stock Price Prediction; Bayesian Optimization Algorithm

1　引言

股票市场作为金融市场的核心组成部分，其在一定程度上能够反映金融市场的动态变化，是衡量国家经济状况的重要指标之一。股票价格的走势预测一直是金融领域以及投资者广泛关注的焦点，准确预测股票价格能够为投资者制定投资策略提供有力支持。股票价格的预测通常基于股票的历史数据展开，股票数据具有非线性、多变量、长记忆性以及噪声高等特点，导致股票市场的预测难度增加。

针对股票价格的预测，国内外学者开展了大量研究，并取得了一定成果。目前，对于股票价格的预测研究成果主要分为两类：线性模型和非线性模型。在线性模型预测中，周静雯[1]利用差分整合移动平均模型(Autoregressive Intergrated

收稿日期：2025-04-09；修回日期：2025-07-02。

基金项目：重庆市自然科学基金项目（CSTB2022NSCQ-MSX1548）。

作者简介：何文定（2002-），男，重庆渝北区人，硕士研究生，从事机器学习与金融时间序列研究。

通信作者：何光（1981-），男，重庆万州人，博士，教授，从事经济金融统计建模与算法研究.Email：heguang@ctbu.edu.cn

Moving Average Model, ARIMA)对中国银行在2023 年的交易日收盘价格进行预测，为单变量价格预测提供了思路。李潇宁[2]利用多元线性模型，利用多个自变量对上证股票收盘价格进行预测，拟合效果较好。这些模型在处理线性时间序列数据方面具有一定的优势，优点在于简单、可解释性强，局限性在于假设输入特征和目标变量之间是线性关系，且对数据的平稳性要求较高。随着经济的不断发展，股票市场产生了海量的数据，股票数据表现出非线性，高噪声的特点，线性模型已难以达到预测的要求。SEZER[3]使用多种深度学习模型用于金融时间序列预测，包括卷积神经网络(Convolutional Neural Networks, CNN)、长短期记忆网络(Long Short-Term Memory, LSTM)等模型，说明深度学习相较于机器学习在金融时间序列预测的结果上更好。在非线性模型预测中，景楠[4]提出卷积神经网络和 LSTM 结合，并引入注意力机制的模型，对期货价格进行预测，其中卷积神经网络提取重要特征，LSTM 捕捉序列中的信息，注意力机制整合信息，通过结合各个模型的优点，模型预测效果得到提升。孙晨宇[5]关注序列本身，通过经验模态分解对序列进行分解处理，利用 LSTM 结合注意力机制进行股票数据预测。Transformer[6]模型是一种完全基于自注意力机制的模型，Informer[7]在 Transformer 的框架上进行了改进和优化，能捕获长期依赖关系。杨璇[8]根据改进的 Transformer 模型进行股票预测，熊飞[9]根据 Transformer 的改进模型 Informer 进行股票的预测。以上均利用 Transformer 的优化框架进行股票价格的预测，结果表明 Transformer 的架构在金融时间序列中的有效性。这些算法可以从大量数据中提取有效信息，且无需预先设定假设，能很好的处理股票序列中的非线性特征。

以上深度学习组合模型相较于线性模型和传统数学模型预测效果更好，这些非线性深度学习模型能很好地进行多变量金融序列的预测，对股票价格的预测具有指导意义。尽管这些模型预测效果较好，但模型参数设置都较为主观，模型中超参数的设置能直接决定实验效果的优良，深度学习模型超参数众多，算法的参数设置是一项具有挑战性的工作。TPE(Tree-structured Parzen Estimator)贝叶斯算法适合中小规模的深度学习模型超参数调优，邓帅[10]利用贝叶斯优化算法优化卷积神经网络的超参数，预测效果得到提升，查雯婷[11]利用 TPE 算法优化 LSTM 的超参数进行预测，预测效果得到提升，证明利用 TPE 算法优化深度学习模型参数的可行性。

综述现有研究，运用深度学习的算法预测股票价格是研究的热点，目前深度学习组合模型在预测效果上取得了不错的成绩。然而，股票数据具有长记忆依赖的特征，股票的历史走势和近期变动是投资者重点关注的因素。当今学者大多未考虑股票序列的长期依赖与短期波动的相互影响，未能充分提取序列长期和短期的信息。同时，股票相关的技术指标也是股票价格预测需关注的问题。模型超参数的设置也是提升预测效果的关键，利用算法优化超参数具有实际意义。

为了更好地捕捉时间序列数据的长期依赖和短期波动的相互影响，提升股票价格预测的准确性和鲁棒性。本文提出一种 Informer 与 LSTM 融合模型，利用 TPE 贝叶斯算法优化模型超参数来进行股票价格的预测。TPE 能自适应地调整参数探索空间的大小，并在尽可能少的迭代次数内找到全局最优解[12]，通过融合 Informer 的全局建模能力与 LSTM 的局部特征捕捉能力，实现多尺度特征提取，全面捕捉序列数据中的长期和短期依赖关系，其双重噪声过滤架构，Informer 剔除市场操纵信号[13]，LSTM 抑制高频交易噪声，显著提升鲁棒性[14]。此外，本文引入股票技术指标，更全面地捕捉股票的特征[15]。本文通过与不同的深度学习预测模型进行性能对比，探究该模型的预测能力，对股票技术指标进行不同滑动天数的处理，进一步探究该模型的信息提取能力，同时在多只股票数据集上进行对比，探究该模型的泛化能力。综上，本文贡献在于：第一，提出 Informer-LSTM 融合模型，实现时间序列多尺度的特征提取，全面捕捉序列的信息；第二，融入了 TPE 贝叶斯算法进行超参数寻优，提高预测的准确度；第三，引入股票技术指标，更全面的反映股票的特征信息。

2 研究方法和评价指标

2.1 长短期记忆网络(LSTM)网络结构

LSTM 是循环神经网络(Recurrent Neural Network, RNN)的改进形式，通过引入输入门、遗忘门和输出门的机制，动态调控细胞状态中的信息流动，核心优势在于利用门控结构和记忆单元，解决在长时间序列预测中出现的梯度消失和爆炸问题[16]，LSTM 被广泛应用于时间序列问题中。图 1 展示了 LSTM 内部结构。

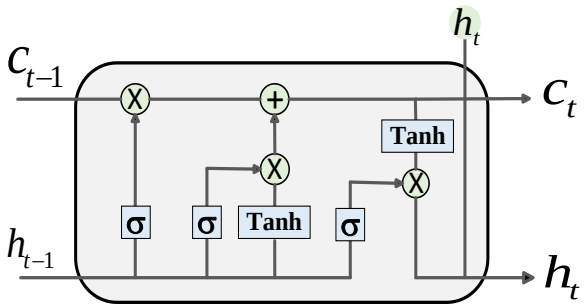

图 1　LSTM 内部结构

Fig. 1 The internal structure of LSTM

LSTM 的遗忘门是决定从上一时刻细胞状态 c_{t-1} 中保留或丢弃信息到 c_t 的过程。“遗忘”过程根据新信息 x_t 和上一时刻的隐含状态 h_{t-1}，通过 Sigmoid 激活函数计算得到记忆细胞获取信息的百分比 f_t，遗忘门函数计算方法如式(1)所示：

$$f_t = \sigma(\boldsymbol{W_f}.[h_{t-1}, x_t] + \boldsymbol{b_f}) \tag{1}$$

输入门是控制新信息写入细胞状态的过程，表明从新信息 x_t 保存到记忆细胞 c_t 的信息，输入门计算过程如(2)、(3)所示，i_t 为输入门权重，c_{ht} 为记忆细胞的过程态。

$$i_t = \sigma(\boldsymbol{W_i}.[h_{t-1}, x_t] + \boldsymbol{b_i}) \tag{2}$$

$$c_{ht} = \tanh(\boldsymbol{W_c}.[h_{t-1}, x_t] + \boldsymbol{b_c}) \tag{3}$$

最终细胞状态更新如(4)所示，t 时刻的记忆细胞信息 c_t 由 t-1 时刻的记忆信息 c_{t-1} 和过程状态 c_{ht} 组成：

$$c_t = f_t.c_{t-1} + i_t.c_{ht} \tag{4}$$

输出门是决定细胞状态 c_t 输出到隐藏状态 h_t 的信息量，使用 Sigmoid 函数决定细胞输出的权重，细胞状态使用 Tanh 函数和 Sigmoid 函数输出相乘，输出门结果如式(5)、(6)所示，o_t 为权重函数，h_t 为最终输出的隐含状态。

$$o_t = \sigma(\boldsymbol{W_o}.[h_{t-1}, x_t] + \boldsymbol{b_o}) \tag{5}$$

$$h_t = o_t.\tanh(c_t) \tag{6}$$

其中，σ代表 Sigmoid 函数，$\boldsymbol{W_f}$，$\boldsymbol{W_i}$，$\boldsymbol{W_o}$ 代表权重矩阵，$\boldsymbol{b}$ 为偏置系数矩阵。

2.2　Informer 网络结构

2.2.1 ProbSparse 自注意力机制

自注意力机制(Self-Attention)是 Transformer 模型的核心组件之一，该组件在处理序列数据时通过计算序列中每个元素与其他元素之间的相关性，动态地调整对每个元素的关注程度，从而捕捉序列内部的复杂依赖关系[17]。自注意力机制通过将输入序列映射到 3 个向量：查询（$\boldsymbol{Q}$）、键（$\boldsymbol{K}$）和值（$\boldsymbol{V}$），经过矩阵乘积运算得到注意力得分，即每个元素的注意力权重。自注意力机制的计算式为。

$$Attention(\boldsymbol{Q}, \boldsymbol{K}, \boldsymbol{V}) = \mathrm{softmax}(\frac{\boldsymbol{Q}\boldsymbol{K}^T}{\sqrt{d}})\boldsymbol{V} \tag{7}$$

其中，$\boldsymbol{Q}$、$\boldsymbol{K}$、$\boldsymbol{V}$ 分别为查询矩阵、关键字矩阵、值矩阵，d 为向量空间的维数。

Informer 提出的 ProbSparse 自注意力机制，相较于传统注意力机制计算所有元素的注意力得分，其稀疏性度量能有效降低计算复杂度，仅关注序列中重要的时间点，选择信息量最大的前 u 个查询进行计算，忽略对注意力贡献小的部分，降低计算成本，且能有效的捕捉长序列的特征[18]，稀疏性评估函数最大均值测度为。

$$M(\boldsymbol{q_i}, \boldsymbol{K}) = \max_j\{\frac{\boldsymbol{q_i}\boldsymbol{k_j^T}}{\sqrt{d}}\} - \frac{1}{L}\sum_{j=1}^{L}\frac{\boldsymbol{q_i}\boldsymbol{k_j^T}}{\sqrt{d}} \tag{8}$$

其中，$\boldsymbol{q_i}$ 表示第 i 个查询向量，$\boldsymbol{k_j}$ 表示第 j 个键值。

2.2.2　Informer 编码器-解码器结构

Informer 模型的整体构架基于编码器-解码器(Encoder-Decoder)结构，主要由堆叠的编码器和解码器组成，模型分为输入、编码器、解码器和输出 4 个部分，具体结构如图 2 所示。

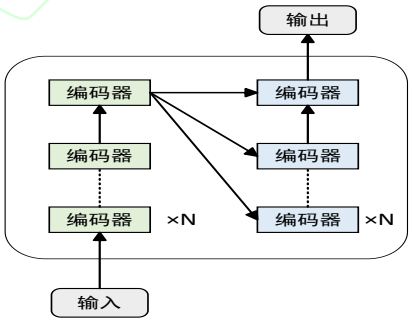

图 2　编码器-解码器(Encoder-Decoder)结构

Fig.2 The Encoder-Decoder architecture

编码器负责对输入的时间序列进行编码，提取关键特征信息。编码器由多层编码器层堆叠而成，其核心组件包括 ProbSparse 自注意力层、注意力蒸馏、前馈神经网络和残差连接。ProbSparse 自注意力机制通过概率方法选择关键信息，注意力蒸馏通过减少序列的长度，有效降低计算复杂度和内存使用，前馈神经网络用于对每个时间步的特征进行非线性变换，在每个子层后添加残差连接和层归一化，以缓解梯度消失问题。

解码器接收编码器的输出和一个初始的目标序列，Informer 采用生成式解码器，通过堆叠的多层解码器结构实现高效的多步序列预测，每层包含掩码概率稀疏注意力机制、编码-解码交叉注意

力以及前馈神经网络 3 个核心模块。其中掩码多头自注意力机制确保预测过程的时序因果性，交叉注意力有效融合编码器的全局信息，前馈神经网络层则进行特征非线性转换，Informer 结构如图 3 所示。

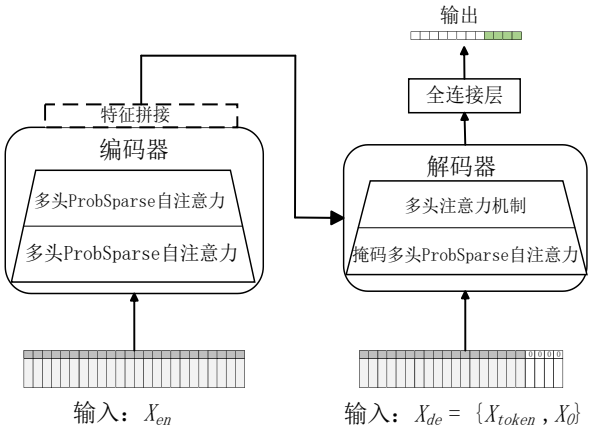

图 3　Informer 结构图

Fig.3 The internal structure of Informer

2.3　TPE 贝叶斯优化

TPE 是一种基于树结构的贝叶斯优化方法，针对中小规模，离散连续型的超参数空间的优化问题设计[19]。TPE 算法能够自适应地调整参数搜索空间的大小，并且能够在尽可能少的迭代次数内找到全局最优解，其优势在于离散参数处理能力和其计算效率，适合深度学习模型超参数的优化。具体步骤如下：

初始化参数空间，并随机采样：定义超参数的搜索空间 $\mathcal{X}$，每个维度对应一个超参数的取值范围，随机生成一组初始参数配置$\{x_1,x_2,x_3....x_n\}$，并评估他们的性能$\{f(x_1),f(x_2),f(x_3)...f(x_n)\}$。

划分观测值，计算核密度：根据观测值的性能，将观测值分为两组：表现好的组 G 和表现坏的 B，使用 Parzen 窗方法分别对 G 和 B 的分布构建核密度估计。表现好的分布用 $l(x)$，坏的分布用 $g(x)$表示，表达式如(9)，(10)所示。

$$l(x)=\frac{1}{|\mathrm{G}|}\sum_{x_i\in G}K(x,x_i,h) \tag{9}$$

$$g(x)=\frac{1}{|\mathrm{B}|}\sum_{x_i\in B}K(x,x_i,h) \tag{10}$$

其中，$K(x,x_i,h)$是核函数，h 是带宽参数。

评估，选择新采样点：计算每个可能的参数配置的期望改进(EI)，EI 是衡量参数配置潜在改进的指标。选择 EI 最大的参数配置作为新的采样点，表达式如(11)所示。

$$EI(X)=\gamma l(x)-(1-\gamma)g(x) \tag{11}$$

评估新采样点，更新观测值：使用选定的新参数配置评估模型的性能，将评估结果加入到观测值中，用于下一次迭代的代理模型构建，达到预测的迭代次数或满足性能要求则停止实验。

2.4　评价指标构建

本文选取 3 个评价指标评估模型的性能：均方误差(Mean Square Error,MSE)，平均绝对误差(Mean Absolute Error,MAE)，平均绝对百分比误差(Mean Absolute Percentage Error,MAPE)[20]。

μ_{MSE} 是衡量预测值与实际值之间差异的指标，是样本的实际值与预测值之差的平方的平均值，计算公式如(12)所示。

$$\mu_{MSE}=\frac{1}{n}\sum_{i=1}^{n}(y_i-\hat{y}_i)^2 \tag{12}$$

μ_{MAE} 是样本的实际值与预测值之差的绝对值的平均值，计算公式如(13)所示。

$$\mu_{MAE}=\frac{1}{n}\sum_{i=1}^{n}|y_i-\hat{y}_i| \tag{13}$$

μ_{MAPE} 是样本实际值与预测值之差的绝对值与实际值的比值的平均值，计算公式如(14)所示。

$$\mu_{MAPE}=\frac{1}{n}\sum_{i=1}^{n}\left|\frac{y_i-\hat{y}_i}{y_i}\right|\times 100\% \tag{14}$$

其中，n 是样本量，y_i 是第 i 个样本的实际值，$\hat{y}_i$ 是第 i 个样本的预测值，μ_{MSE}、μ_{MAE}、μ_{MAPE} 值越小，表示模型的预测越准确，三种检验指标各有优点，共同作为检验模型预测能力的指标。

3　TPE-Informer-LSTM 模型构建

3.1 TPE-Informer-LSTM 模型整体结合框架

本文将 Informer 与 LSTM 两种模型融合，Informer 通过注意力机制聚焦全局信息，捕捉长时间跨度内的关键特征与趋势，LSTM 的门控机制则专注于处理局部信息，精准建模短期波动。二者结合，既保留了 Informer 在长时间序列预测中的全局视野与高效特征提取能力，又融入了 LSTM 对局部细节的精准把控，实现优势互补，TPE-Informer-LSTM 模型的结构如图 4、图 5 所示。

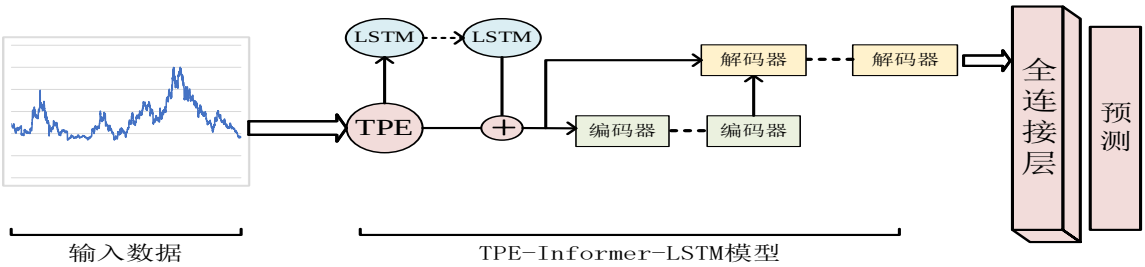

图 4　TPE-Informer-LSTM 模型结构

Fig.4 The TPE-Informer-LSTM model structure

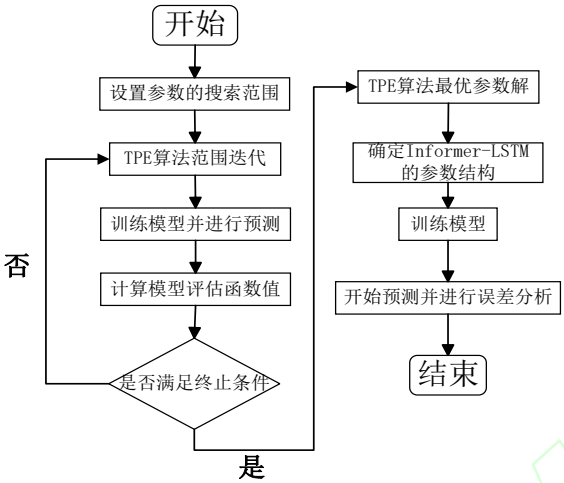

图 5　TPE-Informer-LSTM 流程

Fig. 5 TPE-Informer-LSTM Process

TPE-Informer-LSTM 建模具体过程如下：

（1）数据输入部分。本文将时间序列数据和辅助标记结合作为输入数据。原始时间序列数据用于生成输入序列和目标序列，辅助标记对时间戳进行编码，用于增强模型对时间模式的捕捉能力。通过滑动窗口的方式，利用固定的滑动窗口将序列划分为输入序列和目标序列。同时，划分训练集和测试集。

（2）TPE 贝叶斯优化部分：TPE 算法对待优化的参数定义一个搜索空间，使其在特定的范围内进行搜索优化，搜索空间太大会导致计算资源的浪费，太小则可能无法得到最优的参数组合。设置训练轮数进行训练，算法会遍历每一个参数组合，采用最小化验证损失作为优化目标，通过优化目标函数不断进行迭代，并储存运行结果。最后，利用最佳参数组合重新创建模型，在训练集上进行训练。

（3）LSTM 部分。该部分由多个 LSTM 单元组成，负责捕捉时间序列的短期变化及动态依赖关系。输入数据经过第一个 LSTM 层处理，得到包含短期动态特征的隐藏状态并作为下一层的输入，经过最后一层 LSTM 的处理，输出包含短期动态特征的信息。

（4）Informer 部分。Informer 会对输入序列的每个时间步添加时间和位置信息以转换为可以处理的表示特征。编码器中 ProbSparse 自注意力机制捕捉序列的长期趋势和全局信息，同时利用前馈连接层增强特征的非线性表达能力。编码器提取的信息输出作为解码器的输入，解码器对编码器的输出和目标序列进行解码，输出包含时间序列全局特征和长期趋势的信息。

（5）全连接层和预测部分。通过全连接层进行信息整合。同时，通过一个全连接层将整合后的特征映射到目标维度进行预测。

3.2　预测模型实现流程

预测流程由数据获取及处理、数据归一化、划分训练集测试集、TPE 模型参数寻优、训练 Informer-LSTM 模型、输出预测结果组成。股票技术指标根据股票历史日 K 线计算得到，和股票基础日 K 线指标共同作为 TPE-Informer-LSTM 模型的多维度输入，训练模型进行预测，股票预测实现流程框架如图 6 所示。

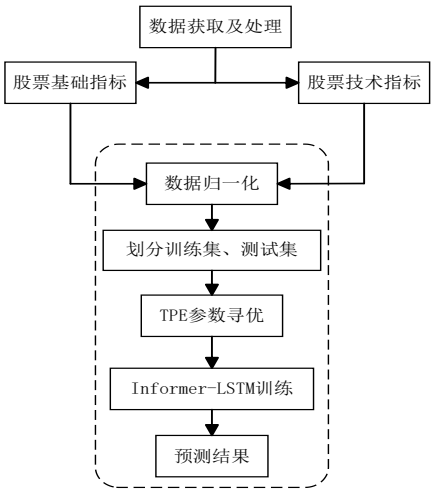

图 6　股票预测实现流程框架

Fig.6 The framework for the implementation process of stock prediction

4　实证分析

本节研究 TPE-Informer-LSTM 模型预测股票价格的有效性，泛化性。利用 TPE-Informer-LSTM

模型对平安银行股票价格进行预测，通过与不同的深度学习预测模型进行性能对比，探究该模型的预测能力，对股票技术指标进行不同滑动天数的处理，进一步探究该模型的信息提取能力，同时在多只股票数据集上进行对比，探究该模型的泛化能力。

4.1 实验数据预处理

股票价格序列数据选取 A 股平安银行（股票代码 000001），时间跨度为 2014-01-02 至 2024-01-19，共 2 447 天数据，数据源来自 Tushare 数据接口，获取的股票数据包含股票代码、交易日期、开盘价、最高价、最低价、收盘价、成交量[21]。基本指标反映了股票市场中每日的交易信息，能有效提取股票序列的特征。

技术指标引入布林带、价格移动平均线、移动平均线等，指标选取了 BBANDS_high、BBANDS_low、BBANDS_middle、价格移动平均线(EMA)、佳庆指标(AD)、平衡量指标(OBV)、WMA、移动平均(MA)8 个指标[22]，能有效反映股票数据的特征，将股票基础指标和技术指标结合作为模型的输入。

由于股票市场存在休市或停牌等现象，数据存在部分日期没有交易数据的情况，为避免因缺失值导致数据长度不一致等情况，将不存在交易数据的日期进行删除。同时，股票数据中不同特征的数值范围差异较大，某些特征数值过大会影响模型的训练效果，故通过归一化将这些特征放缩到相同的范围，且不改变特征的分布，使模型能有效地学习每个特征的规律。归一化表达式如下：

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \tag{15}$$

本文选取平安银行股票数据，选取前 80%作为训练集，剩下的 20%作为测试集，通过滑动窗口的方式划分股票数据集。

4.2 模型超参数设置

经过 TPE 模型进行参数寻优后的超参数设置为：采用 Relu 激活函数，加快收敛速度并防止过拟合，使用 Adam 优化器更新模型的参数，TPE-Informer-LSTM 模型具体超参数设置如表 1 所示，对比模型超参数如表 2 所示。

表 1 TPE-Informer-LSTM 超参数设置表

Table 1 TPE-Informer-LSTM Hyperparameter Settings Table

主要参数	数值
维度	256
注意力头个数	4
丢弃率	0.1
编码器、解码器个数	3
全连接层维度	512
学习率	0.0005
LSTM 层数	3
LSTM 隐藏层单元数	256
批次大小	64

表 2 对比模型超参数设置表

Table 2 Comparison of Model Hyperparameter Settings Table

模型	主要参数	数值
CNN	卷积层层数	64
	卷积核大小	3
	最大池化层大小	2
	全连接层维度	100
LSTM	LSTM 隐藏层单元数	20、50
	全连接层维度	25、1
	丢弃率	0.2
Transformer	维度	256
	注意力头个数	4
	编码器、解码器个数	4
	全连接层维度	512
Informer	维度	256
	注意力头个数	4
	编码器、解码器个数	4
	全连接层维度	512

4.3 模型预测能力对比

本节重点分析 TPE-Informer-LSTM 模型预测股票价格的有效性，与其他预测模型进行对比。预测数据为 A 股平安银行股票基础数据，时间跨度为 2014-01-02 至 2024-01-19，共 2 447 d 数据，加上合成的技术指标作为模型的输入，技术指标进行了 5 d 的平滑处理，共 13 个变量，并与基础数据时间对齐。根据对比模型，一共设置 4 组对比实验模型，分别为 CNN、LSTM、Transformer、Informer，利用过去 7 d 的历史数据，预测未来 1 d 的数据，根据性能评估指标进行结果的分析，结果如表 3 所示。

表 3 性能评估指标分析结果

Table 3 Analysis results of performance evaluation indicators

模型	μ_{MSE}	μ_{MAE}	μ_{MAPE}
Informer	0.1671	0.3254	2.5093
CNN	0.1187	0.2553	1.9230
LSTM	0.0850	0.2106	1.6047
Transformer	0.2482	0.3388	2.4513
TPE-Informer-LSTM	0.0693	0.1881	1.4427

图 7 展示了 TPE-Informer-LSTM 的预测结果。通过测试集评估各种模型对样本外序列的预测能力，μ_{MSE}、μ_{MAE}、μ_{MAPE} 值越小，表示模型的预测

越准确。通过各项指标对比可以发现，在平安银行股票数据集上，TPE-Informer-LSTM 模型相较于其他深度学习模型预测效果更好，在所有评估指标上都优于其他模型。相较于 LSTM，该模型在 μ_{MSE} 上降低了约 18.5%，μ_{MAE} 上降低了 10.6%，μ_{MAPE} 上降低了 10.9%，比 CNN、Informer、Trasnformer 在 μ_{MSE} 上分别降低了 41.6%、58.5%、72%。证明 TPE-Informer-LSTM 在处理长时间序列上明显优于其他模型，证明该模型在时间序列预测中的有效性。

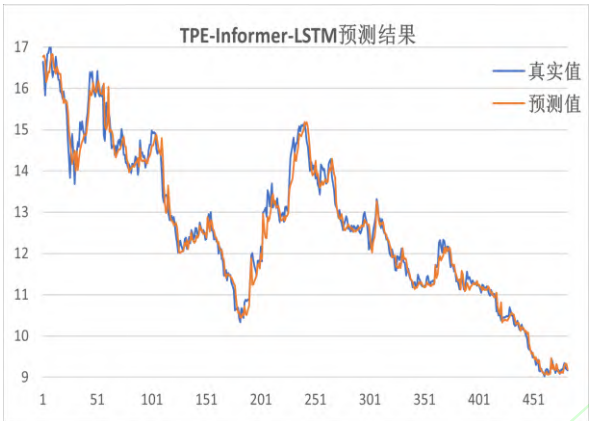

图 7　TPE-Informer-LSTM 预测结果图

Fig.7 Figure of Prediction Results of TPE-Informer-LSTM

4.4 不同平滑天数预测对比

本节研究对于不同平滑天数的技术指标的预测结果对比，不同的平滑天数能捕捉股票序列不同的特征，平滑天数短能较好地保留股票序列的短期波动和细节信息，但对噪声的抑制作用有限，无法提取序列的长期趋势和季节性成份，平滑天数长能更稳定反馈长期趋势，但细节信息可能会被平滑掉。在股票市场中，使用较短的平滑天数可以快速反映股票价格的短期波动，而较长的平滑天数可以更好的提取股票数据的长期趋势和季节性成份。前文对股票的技术指标进行了 5 d 的平滑处理，接着将进行不同平滑天数的预测结果对比。技术指标平滑 10 d 预测结果如表 4 所示。

通过各项指标对比可以发现，TPE-Informer-LSTM 预测能力最好，LSTM、CNN、Informer 依次次之，Transformer 模型预测效果最差，预测误差最大。该模型相较于 LSTM、CNN、Informer、Trasnformer 在 μ_{MSE} 上分别降低了 12.7%、38.5%、51.2%、82.6%。在 μ_{MAE}，μ_{MAPE} 指标上也有不同幅度的降低。

技术指标平滑 20 d 预测结果如表 5 所示。在指标平滑 20 d 情况下，TPE-Informer-LSTM 和 LSTM 预测结果接近，相较于其他模型预测结果更好，Transformer 的预测结果最差。

表 4　技术指标平滑 10 d 预测结果

Table 4 The 10-day prediction results based on smoothed technical indicators

模型	μ_{MSE}	μ_{MAE}	μ_{MAPE}
Informer	0.1542	0.2873	2.1486
CNN	0.1213	0.2546	1.9347
LSTM	0.0862	0.2146	1.6459
Transformer	0.4334	0.4480	3.1010
TPE-Informer-LSTM	0.0752	0.1934	1.4881

表 5　技术指标平滑 20 d 预测结果

Table 5 Prediction results of technical indicators smoothed over 20 days

模型	μ_{MSE}	μ_{MAE}	μ_{MAPE}
Informer	0.1643	0.3327	0.0258
CNN	0.1149	0.2483	0.0190
LSTM	0.0925	0.2413	0.0190
Transformer	0.3613	0.4377	0.0315
TPE-Informer-LSTM	0.0881	0.2026	1.5690

本节比较了各个模型在技术指标不同平滑天数的情况下的预测结果，由结果可知，不论在较短或较长的平滑天数下，TPE-Informer-LSTM 的预测效果最好，证明了该模型能有效地捕捉序列中长期和短期的信息，具备捕捉时间多尺度的能力，模型的预测效果良好。

4.5 不同股票数据集预测结果

本节重点研究 TPE-Informer-LSTM 组合模型在不同的股票数据集上的预测表现，探究该模型在其他数据集上的泛化能力，选取了不同领域的股票数据，如国农科技（股票代码 000004），深振业（股票代码 000006）的股票数据，利用股票历史的日 k 线数据，得到技术指标，作为模型的输入，比较各个模型的预测能力。在万科 A 股数据集上各模型结果对比如表 6 所示。

表 6 万科 A 股数据集各模型对比结果

Table 6 Comparison Results of Models on Vanke A - Share Dataset

模型	μ_{MSE}	μ_{MAE}	μ_{MAPE}
Informer	0.1842	0.3493	2.6899
CNN	0.3422	0.4201	2.6718
LSTM	0.3331	0.4329	2.6940
Transformer	0.8835	0.6814	3.6125
TPE-Informer-LSTM	0.1594	0.2826	1.8032

由表 6 可知，TPE-Informer-LSTM 预测效果显著优于其他模型，Informer 模型次之。相较于 Informer 模型，在 μ_{MSE} 上降低 13.4%、μ_{MAE} 上降低 19.1%,、μ_{MAPE} 上降低 32.9%。相较于平安银行股

票数据集，该数据集各模型的预测效果下降，这与数据的分布和股票性质有关，万科 A 属于地产行业，股票数据的噪声更大，故预测效果下降，但 TPE-Informer-Transformer 的预测效果仍最好。

表 7　深振业股票数据集各模型对比结果

Table 7 Comparison Results of Models on Shenzhen Zhenye Stock Dataset

模型	μ_{MSE}	μ_{MAE}	μ_{MAPE}
Informer	0.1837	0.3431	2.6547
CNN	0.0743	0.1819	3.7958
LSTM	0.0817	0.2451	5.2509
Transformer	0.1725	0.2660	4.2426
TPE-Informer-LSTM	0.0251	0.1052	2.1420

在深振业股票数据集各模型结果对比如表 7 所示。TPE-Informer-LSTM 预测效果显著优于其他模型。

本节比较了 TPE-Informer-LSTM 在不同股票数据集上的表现，由结果可知，在不同领域的股票数据集上，该模型的预测效果同样优于其他模型，证明了该模型在面对不同类型股票的股票数据预测性能的有效性，具有良好的泛化性。

5 结论与展望

本文围绕深度学习算法在股票价格预测领域的应用展开研究，构建了一种 TPE-Informer-LSTM 组合预测模型。基于股票历史数据与技术指标的多维度特征，对股票的收盘价格进行动态预测，在横向上选取不同领域的股票数据集，在时间纵向上设置不同时间跨度的平滑窗口，并与其他深度学习模型进行对比，从多维度的研究了该模型的有效性。

本文实证研究发现，股票基本指标和技术指标融合能更全面地反映股票的特征；相较于 Transformer、LSTM、CNN 等深度学习模型，TPE-Informer-LSTM 的预测精度更高；该模型在处理不同平滑时间窗口的股票数据，预测效果相较于其他模型更好，证明其具备捕捉时间序列多尺度特征的能力；在不同的数据集上表现同样优于其他模型，验证了模型良好的泛化能力。

本研究为研究股票价格提供了新的方法论工具，但仍有值得深入探究的方向：优化模型的复杂度，当前组合模型参数量较大，可探索轻量化改进，如知识蒸馏等提升部署的效率；新增正则化与惩罚项进行优化，约束模型的复杂程度，提升复杂程度。

参考文献：

[1] 周静雯.基于 ARIMA 模型的股票预测——以中国银行为例[J].现代计算机,2024,30(14):89-92.
ZHOU Jingwen. Stock prediction based on ARIMA model—taking bank of China as an example[J]. Modern Computer, 2024, 30(14): 89-92.

[2] 李潇宁. 多元线性回归与时间序列模型在股票预测中的应用[J]. 科技创业月刊, 2019, 32(2): 153-155.
LI Xiaoning. Application of multiple linear regression and time series model in stock forecasting[J]. Pioneering with Science & Technology Monthly, 2019, 32(2): 153-155.

[3] SEZER O B, GUDELEK M U, OZBAYOGLU A M. Financial time series forecasting with deep learning: a systematic literature review: 2005–2019 [J]. Applied Soft Computing, 2020, 90: 106181.

[4] 景楠,史紫荆,舒毓民.基于注意力机制和 CNN-LSTM 模型的沪铜期货高频价格预测[J/OL].中国管理科学 https://doi.org/10.16381/j.cnki.issn1003-207x.2020.0342.
JING Nan, SHI Zijing, SHU Yumin. High-frequency price prediction of Shanghai copper futures based on attention mechanism and CNN-LSTM model[J/OL]. Chinese Journal of Management Science, https://doi.org/10.16381/j.cnki.issn1003-207x.2020.0342.

[5] 孙晨宇,张树东.基于 CEEMDAN 与 LSTM-Attention 的股市预测模型[J].计算机应用与软件,2023,40(12):119-125,146.
SUN Chenyu, ZHANG Shudong. Stock market prediction model based on CEEMDAN with LSTM-Attention[J]. Computer Applications and Software,2023,40(12):119-125,146.

[6] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[J]. Advances in Neural Information Processing Systems, 2017, 30:288-301.

[7] ZHOU H, ZHANG S, PENG J, et al. Informer: beyond efficient transformer for long sequence time-series forecasting[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2021, 35(12): 11106-11115.

[8] 杨璇. 基于改进 Transformer 模型的股票价格预测[D]. 南昌: 江西财经大学, 2024.
YANG Xuan. Stock price prediction based on the improved transformer model[D]. Nanchang: Jiangxi University of Finance and Economics, 2024.

[9] 熊飞. 基于 INFORMER 机制的股价预测模型及量化交易研究[D]. 大连: 大连交通大学, 2023.

XIONG Fei. Research on stock price forecasting model and quantitative trading based on INFORMER mechanism[D]. Dalian: Dalian Jiaotong University, 2023.
[10] 邓帅. 基于改进贝叶斯优化算法的CNN超参数优化方法[J]. 计算机应用研究，2019，36(7): 1984-1987.
DENG Shuai. Hyper-parameter optimization of CNN based on improved Bayesian optimization algorithm[J]. Application Research of Computers, 2019, 36(7): 1984-1987.
[11] 查雯婷,闫利成,陈波,等.基于 TPE-LSTM 的区域超短期风电功率预测[J].计算机应用与软件,2022,39(11):25-30,111.
ZHA Wangting, YAN Licheng, CHEN Bo, et al. Ultra-short-term wind power prediction based on TPE-LSTM[J]. Computer Applications and Software, 2022, 39(11): 25-30,111.
[12] 王誉，陈超. 基于 TPE 优化深度森林模型的电力负荷预测[J]. 洛阳师范学院学报, 2024, 43(11): 15-19.
WANG Yu, CHEN Chao. Electric power load forecasting based on TPE-optimized deep forest model[J]. Journal of Luoyang Normal University, 2024, 43(11): 15-19.
[13] ZHANG C, SUN Y, DING Y, et al. Informer-based method for stock intraday price prediction[J]. International Journal of Computational Intelligence and Applications, 2024: 2442002.
[14] 彭燕，刘宇红，张荣芬. 基于LSTM的股票价格预测建模与分析[J]. 计算机工程与应用，2019, 55(11): 209-212.
PENG Yan, LIU Yuhong, ZHANG Rongfen. Modeling and analysis of stock price forecast based on LSTM[J]. Computer Engineering and Applications, 2019, 55(11): 209-212.
[15] 齐太威，于文年. 基于 LSTM 的多指标股票预测[J]. 计算机与数字工程, 2024, 52(2): 337-342.
QI Taiwei, YU Wennian. Multi-index stock forecast based on LSTM[J]. Computer & Digital Engineering, 2024, 52(2): 337-342.
[16] LIN Y, YAN Y, XU J, et al. Forecasting stock index price using the CEEMDAN-LSTM model[J]. The North American Journal of Economics and Finance, 2021, 57: 101421.
[17] 林昕,朱小栋.基于Attention机制的LSTM股价预测模型[J].重庆工商大学学报(自然科学版),2022,39(2):75-82.
LIN Xin, ZHU Xiaodong. Attention-mechanism-based LSTM model for stock price predicting[J]. Journal of Chongqing Technology and Business University(Natural Science Edition), 2022, 39(2): 75-82.
[18] 赵佳蔚.基于交叉注意力 Informer 机制的股票价格预测[D].上海：东华大学,2024.
ZHAO Jiawei. Stock Price Prediction Based on Cross-Attention Informer Mechanism[D]. Shanghai: Donghua University, 2024.
[19] 崔红艳，张子禄，胡静，等. 基于 TPE-BP 神经网络的爆破振速预测模型研究[J]. 矿业研究与开发, 2024, 44(5): 53-58.
CUI Hongyan, ZHANG Zilu, HU Jing, et al. Study on prediction of blasting vibration velocity based on TPE-BP neural network[J]. Mining Research and Development, 2024, 44(5): 53-58.
[20] 李梦,黄章杰,徐健晖.基于深度学习和小波分析的 LSTM-Wavelet 模型股价预测[J].重庆工商大学学报(自然科学版),2023,40(2):99-105.
LI Meng, HUANG Zhangjie, XU Jianhui. Stock price prediction with LSTM-Wavelet model based on deep learning and Wavelet analysis[J]. Journal of Chongqing Technology and Business University (Natural Science Edition), 2023, 40(2): 99-105.
[21] 于孝建,刘国鹏,刘建林,等.基于 LSTM 网络和文本情感分析的股票指数预测[J].中国管理科学,2024,32(8):25-35.
YU Xiaojian, LIU Guopeng, LIU Jianlin, et al. Stock index prediction based on LSTM networks and text sentiment analysis[J]. Chinese Journal of Management Science, 2024, 32(8): 25-35.
[22] 管健. 基于 RNN-CNN 模型股票价格预测方法研究[D]. 南京: 南京信息工程大学, 2023.
GUAN Jian. Research on stock price forecasting method based on RNN-CNN model[D]. Nanjing: Nanjing University of Information Science & Technology, 2023.