第4卷 第2期 计 量 经 济 学 报 Vol. 4, No. 2
2024年3月 China Journal of Econometrics Mar., 2024

doi: 10.12012/CJoE2023-0014

基于门限自回归条件异方差区间模型的大宗商品价格预测

包皓文 [1,2,3], 孙玉莹 [1,2,3], 洪永淼 [1,2,3], 汪寿阳 [1,2,3,4]

(1. 中国科学院数学与系统科学研究院, 北京 100190; 2. 中国科学院预测科学研究中心, 北京 100190; 3. 中国科学院大学经济与管理学院, 数字经济监测预测预警与政策仿真教育部哲学社会科学实验室, 北京 100190; 4. 上海科技大学创业与管理学院, 上海 201210)

摘 要 大宗商品是工业生产和金融投资中不可或缺的组成部分, 准确的大宗商品价格预测对保障工业生产顺利进行和帮助投资者规避风险具有重要意义. 但现有的大宗商品价格预测模型大多是基于收盘价构建的点值模型, 忽略了价格的波动信息. 因此, 本文从区间价格预测的角度出发, 提出了一个带有外生变量的门限自回归条件异方差区间模型 (HTARIX), 构建了一个基于区间型数据的检验统计量来检验模型是否存在条件异方差, 进而提出了广义最小 D_K 距离估计求解模型参数, 并将其应用于大宗商品市场. HTARIX 模型的优势在于能够捕捉区间型时间序列模型的条件异方差和非线性特征. 相比于传统的点值数据模型, 我们的方法能够更加充分地利用区间的内部信息. 实证结果表明, 本文提出的模型在大宗商品区间价格预测上的表现优于其他对比模型.

关键词 大宗商品价格; 区间数据; 条件异方差; 门限自回归区间模型; 非线性

收稿日期: 2023-03-04

基金项目: 国家自然科学基金(72322016, 72073126, 72091212, 71973116); 国家自然科学基金 “计量建模与经济政策研究” 基础科学中心项目 (71988101)

Supported by National Natural Science Foundation of China (72322016, 72073126, 72091212, 71973116); National Natural Science Foundation of China (NSFC) Fundamental Scientific Center Project “Econometric Modelling and Economic Policy Studies” (71988101)

作者简介: 包皓文, 博士, 研究方向: 计量经济学理论与应用、经济与金融预测, E-mail: bhw@amss.ac.cn; 通信作者: 孙玉莹, 副研究员, 研究方向: 计量经济学理论与应用、模型平均与组合预测, E-mail: sunyuying@amss.ac.cn; 洪永淼, 世界计量经济学会会士、发展中国家科学院院士, 中国科学院数学与系统科学研究院特聘研究员, 研究方向: 计量经济学、时间序列分析、金融计量学、统计学, E-mail: ymhong@amss.ac.cn; 汪寿阳, 发展中国家科学院院士、国际系统与控制科学院院士, 中国科学院数学与系统科学研究院特聘研究员, 研究方向: 金融系统工程、经济分析与预测, E-mail: sywang@amss.ac.cn.

Commodity Price Forecasting Based on Heteroskedasticity Threshold Autoregressive Models for Interval Data

BAO Haowen[1,2,3], SUN Yuying[1,2,3], HONG Yongmiao[1,2,3], WANG Shouyang[1,2,3,4]

(1. Academy of Mathematics and Systems Science, Chinese Academy of Sciences, Beijing 100190, China; 2. Center for Forecasting Science, Chinese Academy of Sciences, Beijing 100190, China; 3. School of Economics and Management, and MOE Social Science Laboratory of Digital Economic Forecasts and Policy Simulation, University of Chinese Academy of Sciences, Beijing 100190, China; 4. School of Entrepreneurship and Management, ShanghaiTech University, Shanghai 201210, China)

Abstract Commodity is an important part of industrial production and financial investment, and accurate commodity price forecasting is of great significance to safeguard industrial production and help investors avoid risks. However, most of the existing commodity price forecasting models are point-value models based on closing prices, which ignores the volatility information. Therefore we propose a heteroskedasticity threshold autoregressive interval model with exogenous variables (HTARIX) and apply it to the commodity markets. We also construct a test statistic based on interval-valued data to test whether there is conditional heteroskedasticity in the model, and propose a generalized minimum D_K distance estimation. The advantage of our model is that it can capture the conditional heteroskedasticity and nonlinear features of interval-valued time series models. Compared with the point-valued models, our method contains more information of the data. The empirical results imply that HTARIX model performs better than other comparative models in interval-valued commodity price forecasting.

Keywords commodity price; interval-valued data; conditional heteroskedasticity; TARI; nonlinear

1 引言

大宗商品作为不可或缺的工业材料和重要的金融投资产品, 兼具商品属性和金融属性, 在现代化工业生产和金融市场中扮演着重要角色. 大宗商品的价格波动不仅会影响下游企业的生产运营也会造成金融市场动荡, 甚至可能对国家和地区的政治经济产生严重冲击. 因此, 大宗商品的价格波动长期以来受到工业界和学术界的广泛关注, 准确地预测大宗商品价格走势对政策制定者和投资者具有重要意义 (卢全莹, 史惠婷和汪寿阳, 2022; 何亚男和汪寿阳, 2011; 卢全莹, 柴建和曹蒲菊等, 2022; 周浩等, 2021; 张翔等, 2017; Wang et al., 2018; Costola and Lorusso, 2022).

大宗商品价格预测是经济和金融分析领域中一项重要且充满挑战的研究课题, 目前关于大宗商品价格预测的建模大多是以点值数据为研究对象, 研究方法主要包括: 因子增广自回归模型 (Zagaglia, 2010), 支持向量回归模型 (王珏等, 2017), GARCH 模型 (Zhang et al., 2019), 向量自回归模型 (Heath, 2019), BEKK-条件 Wishart 模型 (Asai et al., 2020) 等. 与此同时, Zhang et al. (2008) 将集成经验模态分解应用于原油价格分析中, 从短期波动和长期趋势的角度揭示原油价格变化的内在特征; Ahumada and Cornejo (2016) 在价格预测模

型中考虑大豆、玉米和小麦三种农产品之间的相关性, 结果表明包括价格相互作用的模型可以改善预测效果; Zhang et al. (2019) 利用 LASSO 和弹性网络方法筛选出重要的预测变量并提高了原油价格预测的准确性; Yen-Ku et al. (2022) 使用自回归分布滞后 (ARDL) 模型研究了新冠疫情期间中国股票市场中原油价格、黄金价格、原油价格波动和黄金价格波动之间的动态关系. 这些研究在大宗商品价格的预测和分析方面取得了显著的效果, 但它们仅使用了点值的大宗商品收盘价, 忽略了价格变化中的潜在信息, 导致信息的缺失. 具体而言, 大宗商品价格是一种高频的观测数据, 而收盘价仅是某一时刻的数据, 对点值数据的建模没有考虑大宗商品盘中价格可能提供的信息, 例如, 每日的最高价和最低价反映了投资者对大宗商品当日价格的最高期望和最低期望, 包含了投资者的预期和市场的波动信息, 这些信息可能提高价格预测的精度. 因此, 区间数据已经被学者们应用于大宗商品价格的研究中 (Lu et al., 2022; Yang et al., 2016; Sun et al., 2022).

区间数据是符号数据中非常重要的一个分支, 关于符号数据的研究可追溯至 Diday (1989). 此后, 有大量文献关注区间数据的理论研究, 例如, Billard and Diday (2000) 基于区间内的点均匀分布的前提假设, 首次提出了关于区间中点的建模方法, 利用经典的回归方法得到区间回归模型的参数估计. Neto and De Carvalho (2008) 通过对区间的中点和范围分别建立线性回归模型 (CRM) 来拟合区间序列, 并在 Neto and De Carvalho (2010) 中通过对区间范围的回归模型施加限制条件改进了 CRM 模型得到 CCRM 模型, 他们的工作揭示了区间信息在预测模型中的重要地位. 区别于基于区间的中点和范围的建模方法, Han et al. (2016) 将区间变量定义为概率空间上的映射, 并将区间观测值看作是不可分割的集合, 进而提出了区间值向量自回归移动平均 (IVARMA) 模型, IVARMA 向量体系中的每个模型都可以看成是自回归条件区间模型 (ACI). 在此基础上, Sun et al. (2018) 建立了门限自回归区间模型 (TARI) 来刻画区间数据中的非线性特征. Sun et al. (2019) 提出了基于区间数据的 Wald 检验方法, 目的是检验门限效应在 TARI 模型中是否具有统计学意义上的显著性, 并推导出其渐近性质. Yang et al. (2016) 在包含区间外生解释变量的自回归条件区间模型 (ACIX) 中引入区间型的工具变量. 除了理论方面的研究, 区间数据在经济和金融领域有着广泛的应用, 例如, 原油市场 (Lu et al., 2022), 在岸和离岸市场人民币价格 (Sun et al., 2020), 股票市场研究 (Sun et al., 2021; Qiao et al., 2021), 牲畜交易价格研究 (Zhang et al., 2020) 等.

然而, 现有的区间模型大都是在同方差假定下进行模型的参数估计, 但条件异方差在金融数据建模中是常见的 (Akgiray, 1989; Cheong, 2009). 因此, 为了捕捉大宗商品区间价格预测模型中的条件异方差和非线性特征, 本文提出了一个带有外生变量的门限自回归条件异方差区间模型 (HTARIX), 它可以看作 Sun et al. (2018) 中 TARIX 模型在条件异方差情形下的推广. 具体而言, 本文提出了 TARIX 模型中条件异方差的一种检验方法, 并建立了关于检验统计量的渐近理论, 进而基于广义最小 D_K 距离估计来求解模型参数. HTARIX 模型的优势主要体现在以下三个方面: 第一, 相比于对区间的中点和范围 (或左, 右端点) 分别建模的方法, 我们将区间视为不可分割的随机集合, 从而得到一个更加简约的模型. 第二, HTARIX 模型可以捕捉区间时间序列过程中的非线性特征, 使得我们的方法能够更加有效地对复杂金融数据进行建模, 因此拥有更加广泛的应用价值. 第三, 我们提出的 TARIX 模型中条件异方

差的检验方法能够处理区间数据建模过程中存在条件异方差的问题, 进而得到更加有效的参数估计, 弥补了区间数据建模理论中的空白.

在本文中, 我们将 HTARIX 模型应用于黄金, 原油和玉米三种代表性大宗商品的价格预测中, 并从金融市场, 货币市场, 宏观经济等方面选取相关指标作为预测模型的外生变量. 实证结果表明, 本文提出的 HTARIX 模型在所有对比模型 (ACIX, CRX, ARX, VARX 和 TARIX) 中的预测表现是最优的. 首先, 回归模型中条件异方差的存在会影响参数估计的有效性, 而本文提出的条件异方差检验表明三种大宗商品区间价格预测模型均存在条件异方差. 因此相比于 TARIX 模型, 基于广义最小 D_K 距离估计得到 HTARIX 模型的参数估计更加有效, 进而可能提高模型的预测精度. 其次, 相比于 ACIX 模型, HTARIX 模型通过门限变量的选择从供需结构, 经济政策变化等角度刻画大宗商品价格变化的非线性特征和切换机制, 有效地提高了大宗商品区间价格模型的预测性能. 再者, HTARIX 模型将区间看成不可分割的整体进行建模, 充分利用了区间的内部信息, 由此得到比 CRX, ARX, VARX 更加简约的模型, 例如, HTARIX 模型的参数个数仅有 CRX 模型的二分之一, 有助于提高模型的预测准确性.

本文剩余内容的结构安排如下: 第二部分构建了 HTARIX 模型的结构框架, 给出了 TARIX 模型条件异方差的检验统计量, 并介绍了广义最小 D_K 距离估计过程; 第三部分是实证分析和模型预测结果讨论; 第四部分是结论. 所有定理和推论的证明过程均在附录中.

2 条件异方差门限区间模型

2.1 模型介绍

在介绍区间回归模型之前, 我们首先引入区间型随机变量的定义及其运算规则 (Han et al., 2016). 假设 Y 是一个区间型随机变量, 它被定义为概率空间 $(\Omega, \mathcal{F}, P)$ 上的一个可测映射, 即 $Y:\Omega \to I_{\mathbb{R}}$, 其中 $I_{\mathbb{R}}$ 是实数域 $\mathbb{R}$ 上所有有序数对构成的集合. 根据定义, 对任意 $\omega \in \Omega$, 我们有 $Y(\omega) = [Y_L(\omega), Y_R(\omega)]$. 假设 $Y = [Y_L, Y_R], X = [X_L, X_R]$ 是两个区间型随机变量, $c \in \mathbb{R}$ 是任意常数, 定义以下运算规则:

$$Y + cX = [Y_L + cX_L, Y_R + cX_R].$$

此外, 根据 Näther and Körner (2022), 我们引入区间型随机变量之间的 D_K 距离. 记 Y 和 X 之间的 D_K 距离为 $D_K(Y, X)$, 具体形式如下:

$$D_K(Y,X)^2 = \int_{(u,v)\in \boldsymbol{S}^0} [s_Y(u) - s_X(u)][s_Y(v) - s_X(v)]\mathrm{d}K(u,v),$$

其中, $s_Y(u)$ 是定义在单位球面 $\boldsymbol{S}^0 = \{-1, 1\}$ 上的区间 Y 的支撑函数, 即:

$$s_Y(u) = \begin{cases} \sup\limits_{y\in Y}\{u\cdot y | u \in \boldsymbol{S}^0\}, \text{当} Y_L \le Y_R, \\ \inf\limits_{y\in Y}\{u\cdot y | u \in \boldsymbol{S}^0\}, \text{当} Y_R \le Y_L. \end{cases}$$

进一步, 我们定义由 D_K 距离衍生的范数, 即 $\|Y\|_K = D_K(Y, [0,0])$, 容易验证 $\|\cdot\|_K$ 满足范数的正定性、正齐次性以及三角不等式. 至此, 我们得到了区间型变量的赋范线性空间.

为了捕捉区间型大宗商品价格的潜在数据特征, 本文提出了一种带有外生变量的门限自回归条件异方差区间模型 (HTARIX). 该模型是对 Sun et al. (2018) 提出的带有外生变量的门限自回归区间模型 (TARIX) 在条件异方差情形下的推广. 本文要估计的 TARIX 模型具有如下表达形式:

$$Y_i = \boldsymbol{X}_i\boldsymbol{\beta}_0^{(1)} I(q_i \le \gamma) + \boldsymbol{X}_i\boldsymbol{\beta}_0^{(2)} I(q_i > \gamma) + \varepsilon_i, \quad i = 1, \cdots, n, \tag{1}$$

其中, $\boldsymbol{X}_i = ([1,1], [-\frac{1}{2}, \frac{1}{2}], X_1, \cdots, X_r)$ 是解释变量, 包含截距项, 被解释变量 Y_i 的滞后项以及外生变量; $\boldsymbol{\beta}_0^{(1)}$ 和 $\boldsymbol{\beta}_0^{(2)}$ 是模型的真实参数; q_i 是门限变量 (标量); γ 是给定的阈值; $\varepsilon_i = [\varepsilon_{L,i}, \varepsilon_{R,i}]$ 是区间扰动项. 模型 (1) 中的区间型变量均是广义区间, 即我们允许区间的左端点大于右端点, 以更好地适应金融数据的建模过程. 广义区间的相关概念最早可追溯至 Kaucher (1980), 同时, 广义区间也被广泛应用于区间数据的预测研究中, 例如: Han et al. (2016)、Yang et al. (2016)、He et al. (2021) 等.

在估计模型 (1) 中的参数时, 可应用最小 D_K 距离估计, 即:

$$(\hat{\boldsymbol{\beta}}_n^{(1)}, \hat{\boldsymbol{\beta}}_n^{(2)}, \hat{\gamma}) = \operatorname{argmin}\left\{\frac{1}{n}\sum_{i=1}^{n}\|Y_i - \boldsymbol{X}_i\boldsymbol{\beta}_n^{(1)} I(q_i \le \gamma) - \boldsymbol{X}_i\boldsymbol{\beta}_n^{(2)} I(q_i > \gamma)\|_K^2\right\}.$$

其中, $\boldsymbol{\beta}_n^{(1)}$ 和 $\boldsymbol{\beta}_n^{(2)}$ 是待估参数. 在满足特定的假设条件下, Sun et al. (2018) 指出估计量 $(\hat{\boldsymbol{\beta}}_n^{(1)}, \hat{\boldsymbol{\beta}}_n^{(2)})$ 是一致的且服从渐进正态分布.

2.2 条件异方差检验

检验扰动项是否存在条件异方差是回归分析理论中非常重要的内容, 异方差的存在将导致传统的估计方法 (如: 最小二乘估计等) 得到的参数估计量不再是最优无偏估计. 如引言中所述, 在大宗商品价格的预测建模中, 模型通常不满足条件同方差假定, 因此有必要对模型是否存在条件异方差进行检验. 为了检验 TARIX 模型的随机扰动项 ε_i 是否存在条件异方差, 我们基于 White (1980a) 给出的条件异方差检验方法, 提出 TARIX 模型的条件异方差检验. 具体而言, 考虑原假设:

$$\mathbb{H}_0 : E(\|\varepsilon_i\|_K^2 | \boldsymbol{X}_t) = \sigma_0^2. \tag{2}$$

其中, ε_i 是模型 (1) 的区间随机扰动项, $E(\|\varepsilon_i\|_K^2 | \boldsymbol{X}_t)$ 是其条件方差. 如果原假设 (2) 是错误的, 我们认为模型 (1) 存在条件异方差. 由于 ε_i 是不可观测的, 因此直接对 (2) 式进行检验是困难的. 为了构造可行的检验统计量, 我们考虑以下假设:

假设 1　Y_i 是平稳遍历序列, 且满足 $E(\|Y_i\|_K^2) < \infty$; $\{\varepsilon_i\}$ 是区间鞅差分序列 (IMDS), 即: $E(\varepsilon_i | I_{i-1}) = [0,0]$, I_{i-1} 是 $i-1$ 时刻的信息集; 且 ε_i 和 $\boldsymbol{X}_i$ 满足: $E(\langle s_{\varepsilon_i}, s_{\boldsymbol{X}_i}\rangle_K) = \boldsymbol{0}$.

假设 2　(a) 存在正的常数 δ 和 Δ, 使得 $E(\|\varepsilon_i\|_K^{2(1+\delta)}) < \Delta$, $E(\langle s_{X_{ij}}, s_{X_{ik}}\rangle_K^{1+\delta}) < \Delta$, $(j,k = 1, \cdots, p)$; (b) 对足够大的 n, $\bar{M}_n = n^{-1}\sum_{i=1}^{n} E(\langle s'_{\boldsymbol{X}_i}, s_{\boldsymbol{X}_i}\rangle_K)$ 是非奇异的, 且 $\bar{M}_n > \delta > 0$.

假设 3　(a) 存在正的常数 δ 和 Δ, 使得 $E(|\|\varepsilon_i\|_K^2 \langle s_{X_{ij}}, s_{X_{ik}}\rangle_K|^{1+\delta}) < \Delta$, $(j,k = 1, \cdots, p)$; (b) 对足够大的 n, $\bar{V}_n = n^{-1}\sum_{i=1}^{n} E(\|\varepsilon_i\|_K^2 \langle s'_{\boldsymbol{X}_i}, s_{\boldsymbol{X}_i}\rangle_K)$ 是非奇异的, 且 $\bar{V}_n > \delta > 0$.

假设 4 存在正的常数 δ 和 Δ, 使得对所有的 $i=1,\cdots,n$ 和 $j,k,l,m=1,\cdots,p$, 满足:

$$E(\|\varepsilon_i\|_K^{4(1+\delta)})<\Delta,$$
$$E(|\langle s_{X_{ij}},s_{X_{ik}}\rangle_K\langle s_{X_{il}},s_{X_{im}}\rangle_K|^{1+\delta})<\Delta.$$

假设 5 对足够大的 n, $\bar{B}_n=\frac{1}{n}\sum_{i=1}^n E\{(\|\varepsilon_i\|_K^2-\sigma_i^2)^2(\Psi_i-\bar{\Psi}_n)'(\Psi_i-\bar{\Psi}_n)\}$ 是非奇异的, 且 $\det\bar{B}_n>\delta>0$, 其中 $\Psi_i=(\Psi_{i1},\cdots,\Psi_{i\frac{p(p+1)}{2}})$, $\bar{\Psi}_n=(\bar{\Psi}_{n1},\cdots,\bar{\Psi}_{n\frac{p(p+1)}{2}})$, $\bar{\Psi}_{ns}=\frac{1}{n}\sum_{i=1}^n E(\Psi_{is})$, $\Psi_{is}=\langle s_{X_{iq}},s_{X_{il}}\rangle_K$, $s=1,\cdots,p(p+1)/2$, $q=1,\cdots,p$, $l=1,\cdots,q$.

假设 6 存在正的常数 δ 和 Δ, 使得 $E(|\|X_{ij}\|_K^4\Psi_{is}\Psi_{it}|^{1+\delta})<\Delta$, 其中 $j=1,\cdots,p$; $s,t=1,\cdots,p(p+1)/2$.

假设 7 存在正的常数 δ 和 Δ, 使得对所有的 i, 我们有:

$$E(|\|X_{ij}\|_K^2\langle s_{X_{ik}},s_{X_{il}}\rangle_K|^{1+\delta})<\Delta,\quad \text{for}\quad j,k,l=1,\cdots,p.$$

注 1 假设 1 定义了区间鞅差分序列, 并指出 ε_i 和 $\boldsymbol{X}_i$ 是不相关的; 由假设 2 的 (a) 可以看出, 扰动项 ε_i 的方差以及回归量协方差矩阵的元素是一致有界的, 假设 2 的 (b) 指出回归量 $\boldsymbol{X}_i$ 的协方差矩阵是非奇异的, 并且其行列式是正的; 假设 3 和假设 2 在形式上类似, 它确保了 $\bar{V}_n$ 和 $\bar{V}_n^{-1}$ 的一致有界性; 假设 4 对 ε_i 和 $\boldsymbol{X}_i$ 四阶矩的一致有界性作出规定; 假设 4 和 5 为大数定律和中心极限定理的应用提供了条件; 假设 6 和 7 是关于一致有界性的假定, 它们可由回归量的一致有界性保证.

在门限参数 γ 已知的情况下, 基于上述假设条件, 我们可以构造包含参数估计量 $\hat{\boldsymbol{\beta}}_n=(\hat{\boldsymbol{\beta}}_n^{(1)},\hat{\boldsymbol{\beta}}_n^{(2)})$ 和方差估计量 $\hat{\sigma}_n^2=1/n\sum_{i=1}^n\|Y_i-\boldsymbol{X}_i\hat{\boldsymbol{\beta}}_n^{(1)}I(q_i\le\gamma)-\boldsymbol{X}_i\hat{\boldsymbol{\beta}}_n^{(2)}I(q_i>\gamma)\|_K^2$ 的检验统计量. 在某些假设条件下 (详见附录 A), Sun et al. (2018) 证明了 TARIX 模型参数估计量满足:

$$\|\hat{\boldsymbol{\beta}}_n-\boldsymbol{\beta}_0\|=O_p(1/\sqrt{n}). \tag{3}$$

为了检验原假设 (2), 我们给出以下定理:

定理 1 当假设 1~6 和公式 (3) 成立时, 如果 ε_i 独立于 $\boldsymbol{X}_i$, 且对所有 i 有 $E(\|\varepsilon_i\|_K^2)=\sigma_0^2$, 则,

$$nD_n(\hat{\boldsymbol{\beta}}_n,\hat{\sigma}_n^2)'\hat{B}_n^{-1}D_n(\hat{\boldsymbol{\beta}}_n,\hat{\sigma}_n^2)\sim\chi^2_{p(p+1)/2}, \tag{4}$$

其中,

$$D_n(\hat{\beta}_n,\hat{\sigma}_n^2)=\frac{1}{n}\sum_{i=1}^n\Psi_i'(\|\hat{\varepsilon}_i\|_K^2-\hat{\sigma}_n^2),$$
$$\hat{B}_n=\frac{1}{n}\sum_{i=1}^n(\|\hat{\varepsilon}_i\|_K^2-\hat{\sigma}_n^2)^2(\Psi_i-\hat{\Psi}_n)'(\Psi_i-\hat{\Psi}_n),$$
$$\hat{\Psi}_n=\frac{1}{n}\sum_{i=1}^n\Psi_i,$$
$$\hat{\varepsilon}_i=Y_i-\boldsymbol{X}_i\hat{\boldsymbol{\beta}}_n^{(1)}I(q_i\le\gamma)-\boldsymbol{X}_i\hat{\boldsymbol{\beta}}_n^{(2)}I(q_i>\gamma).$$

注 2　定理 1 是 White (1980a) 中定理 2 在 TARIX 模型上的推广. 注意到, 公式 (4) 也可以看作定理 1 衍生的假设检验问题的原假设, 当原假设被显著拒绝时, 意味着定理 1 的假设条件至少有一个不成立. 但在实际应用定理 1 时, 我们通常认为导致原假设被拒绝的主要原因是回归模型被错误设定, 即 ε_i 与 $\boldsymbol{X}_i$ 之间存在相关性. 而在大多数情况下, 条件异方差是导致相关性的主要因素 (White, 1980a). 因此, 当定理 1 的原假设被拒绝时, 我们有理由认为模型 (1) 存在条件异方差.

注意到定理 1 中的检验统计量形式较为复杂, 因此检验定理 1 的原假设非常繁琐. 为了构造一个简化的检验过程, 我们引入下述的辅助回归:

$$\begin{aligned}\|\hat{\varepsilon}_i\|_K^2 &= \alpha_0 + \alpha_1 \Psi_{i1} + \cdots + \alpha_{\frac{p(p+1)}{2}} \Psi_{i\frac{p(p+1)}{2}} + v_i \\ &= \alpha_0 + \sum_{j=1}^{p}\sum_{k=j}^{p} \alpha_s \langle s_{X_{ij}}, s_{X_{ik}} \rangle_K + v_i, \end{aligned} \tag{5}$$

其中 $\hat{\varepsilon}_i$ 如定理 1 中所定义, 是 TARIX 模型残差项的估计量, α_s 是辅助回归 (5) 的待估参数. 本文构造的辅助回归 (5) 是 $\|\hat{\varepsilon}_i\|_K^2$ 对截距项, 区间因变量支撑函数的所有二次项以及交叉项的回归. 若辅助回归中任何一个系数 α_s $(s > 0)$ 不等于 0, 则意味着原模型存在条件异方差. 基于定理 1, 我们得到下面的推论.

推论 1　给定假设 1∼5, 7 以及公式 (3), 如果 ε_i 独立于 X_i, 且对所有 i 有 $E(\|\varepsilon_i\|_K^2) = \sigma_0^2$, $E(\|\varepsilon_i\|_K^4) = \mu_4$, 则:

$$nR^2 \sim \chi^2_{p(p+1)/2}, \tag{6}$$

其中, R^2 是辅助回归 (5) 的 R 方.

注 3　推论 1 中的条件 $E(\|\varepsilon_i\|_K^4) = \mu_4$ 意味着在原假设 (2) 下, 辅助回归 (5) 的扰动项 v_i 是条件同方差的. 在大多数情况下, 推论 1 可以用来检验模型是否存在条件异方差, 但注意到当推论 1 的原假设被拒绝时, 仅能认为模型 (1) 扰动项的条件方差与 $\boldsymbol{X}_i$ 的一次项和二次项无关, 推论 1 无法检验条件方差和 $\boldsymbol{X}_i$ 更高阶的项之间的关系.

2.3 广义最小 D_K 距离估计

对于区间型线性回归模型, Han et al. (2016) 提出了最小 D_K 距离估计, Sun et al. (2018) 将其应用于 TARIX 模型, 但他们都隐含了条件同方差的前提假设, 本文将给出处理包含条件异方差的 TARIX 模型的广义最小 D_K 距离估计量. 当模型 (1) 存在条件异方差时, 我们假设其扰动项满足 $E(\|\varepsilon_i\|_K^2|\boldsymbol{X}_i) = \sigma^2 V(\boldsymbol{X}_i)$ 或 $E(\|\boldsymbol{\varepsilon}\|_K^2|\boldsymbol{X}) = \sigma^2 \boldsymbol{V}(\boldsymbol{X})$, 其中 $\boldsymbol{V}(\boldsymbol{X})$ 是已知形式的矩阵. 当 $\boldsymbol{V}(\boldsymbol{X})$ 是对角矩阵时, 扰动项 $\boldsymbol{\varepsilon}$ 不存在条件自相关, 即对任意 $i \neq j$, $\mathrm{cov}(\varepsilon_i, \varepsilon_j|\boldsymbol{X}) = 0$. 假设 $\boldsymbol{V}$ 是对称正定矩阵, 由 Cholesky 分解, 存在非奇异矩阵 $\boldsymbol{C}$, 使得 $\boldsymbol{V}^{-1} = \boldsymbol{C}'\boldsymbol{C}$. 下面我们给出广义最小 D_K 距离估计.

模型 (1) 的矩阵形式可变换为:

$$\boldsymbol{CY} = \boldsymbol{CX}\boldsymbol{\beta}_n^{(1)} I(q \leq \gamma) + \boldsymbol{CX}\boldsymbol{\beta}_n^{(2)} I(q > \gamma) + \boldsymbol{C}\boldsymbol{\varepsilon}.$$

将上式改写为:

$$\boldsymbol{Y}^* = \boldsymbol{X}^*\boldsymbol{\beta}_n^{(1)} I(q \le \gamma) + \boldsymbol{X}^*\boldsymbol{\beta}_n^{(2)} I(q > \gamma) + \boldsymbol{\varepsilon}^*, \tag{7}$$

其中, $\boldsymbol{Y}^* = \boldsymbol{C}\boldsymbol{Y}$, $\boldsymbol{X}^* = \boldsymbol{C}\boldsymbol{X}$, $\boldsymbol{\varepsilon}^* = \boldsymbol{C}\boldsymbol{\varepsilon}$. 我们将利用最小 D_K 距离估计求解变换后回归模型 (7) 的过程称为广义最小 D_K 距离估计. 显然对模型 (7), 我们有 $E(\|\boldsymbol{\varepsilon}^*\|_K^2|\boldsymbol{X}^*) = E(\|\boldsymbol{\varepsilon}^*\|_K^2|\boldsymbol{X}) = \boldsymbol{C}\sigma^2\boldsymbol{V}\boldsymbol{C}' = \sigma^2 \cdot \mathbf{1}$, 其中 $\mathbf{1}$ 是 $n \times n$ 的单位矩阵. 因此变换后的模型 (7) 的扰动项不再具有条件异方差, 如此一来, 通过广义最小 D_K 距离估计, 我们消除了原模型 (1) 中的条件异方差.

注 4 注意到, 变换后的模型 (7) 不仅消除了条件异方差, 也消除了扰动项中可能存在的自相关性, 但本文主要关心的问题是 TARIX 模型中的条件异方差, 因此对自相关性的问题不做过多说明. 上述广义最小 D_K 距离估计过程也适用于 ACIX 模型, 在该情形下, 我们提出的广义最小 D_K 距离估计可以看成是广义最小二乘法在区间情形下的推广. 广义最小 D_K 距离估计的主要意义在于, 给出了区间回归模型中条件异方差的一种处理方式, 并得到参数的有效估计, 进而有可能提高模型的预测性能. 但在实际应用中, 由于协方差矩阵 $\boldsymbol{V}$ 的未知性, 广义最小 D_K 距离估计往往是不可行的.

为了得到可行的广义最小 D_K 距离估计, 我们需要确定协方差矩阵 $\boldsymbol{V}$, 通常是通过非参数方法得到 $\boldsymbol{V}$ 的估计量 $\hat{\boldsymbol{V}}$. 为了得到 $n \times n$ 矩阵 $\boldsymbol{V}$ 的一致估计, 我们有必要对 $\boldsymbol{V}$ 施加一定的限制条件, 一种常见的方法是假设 $\boldsymbol{V}$ 是对角矩阵, 即:

$$E(\|\boldsymbol{\varepsilon}\|_K^2|\boldsymbol{X}) = \sigma^2\boldsymbol{V} = \mathrm{diag}\{\sigma_1^2(\boldsymbol{X}_1), \cdots, \sigma_n^2(\boldsymbol{X}_n)\}.$$

在不存在自相关性的假设条件下, 我们可以用区间残差的 D_K 范数 $\|\hat{\varepsilon}_i\|_K^2$ $(i = 1, \cdots, n)$ 来构造协方差矩阵的估计量 $\hat{\boldsymbol{V}}$.

注 5 本文提出的广义最小 D_K 距离估计可以消除模型的条件异方差, 进而提高区间回归模型参数估计的有效性, 除此之外, 区间数据中的其他特征 (如: 异常值, 非平稳性等) 也可能导致一般的最小 D_K 距离估计无法给出合适的参数估计. 因此, 研究区间回归模型中参数的其他估计方法对提高模型的稳健性和预测性能具有积极意义. 例如, 区间数据中离群值的出现可能对由最小 D_K 距离估计得到的样本外预测结果产生不利影响, 直接删除离群值会忽略其中蕴含的有效信息, 基于 Wang and Hao (2022), 我们可以构造一种区间回归模型的稳健加权最小 D_K 距离估计, 通过赋予异常观测值更小的权重降低其对参数估计的影响, 同时利用其中包含的有效信息. 具体而言, ACIX 模型的参数估计可表示为: $\hat{\boldsymbol{\beta}} = \mathrm{argmin}_{\boldsymbol{\beta}} \sum_{t=1}^T w_t \|Y_t - \boldsymbol{X}_t\boldsymbol{\beta}\|_K^2$, 其中 $w_t = w(Y_t)$ 是给定的核函数, 例如, $w(Y_t) = (1 + \|Y_t\|_K)^{-\lambda}$, λ 是调节参数. 该方法还可以在预测的偏差和方差之间进行权衡, 根据实际需求调整预测结果. 关于区间回归模型估计方法的讨论, 我们将在未来的工作中进行更加深入的研究.

3 数据描述和实证分析

3.1 数据描述

本文使用三种具有代表性的大宗商品价格进行实证分析, 分别是: 纽约商业交易所 (COMEX) 黄金期货收盘价, 布伦特原油期货结算价, 芝加哥商品交易所 (CBOT) 玉米期货收盘价. 我们利用原始日度点值时间序列来构造月度的区间值时间序列. 具体而言, 我们利用以上三种大宗商品在一个月内的最低收盘价 ($Y_{L,t}$) 和最高收盘价 ($Y_{R,t}$) 来构造月度区间价格 $Y_t = [Y_{L,t}, Y_{R,t}]$, 区间的中点定义为 $Y_{m,t} = (Y_{L,t} + Y_{R,t})/2$, 区间的范围定义为 $Y_{r,t} = Y_{R,t} - Y_{L,t}$, 样本时间范围是 2015 年 7 月 – 2021 年 12 月.

表 1 给出了黄金, 原油和玉米月度区间价格数据 (左右端点, 中点, 范围) 的描述性统计特征, 从表 1 可以观察到以下几点: 首先, 大宗商品区间价格的左右端点和中点的标准差远大于范围的标准差, 说明大宗商品区间价格趋势的波动性比范围的波动性更高; 其次, 原油区间价格范围的峰度异常高, 主要原因是新冠疫情期间原油价格波动非常剧烈; 再者, COMEX 黄金的区间价格具有较小的标准差, 其左右端点和中点的峰度均小于 0, 且其范围的峰度小于原油和玉米, 这些特征表明黄金价格具有较小的波动性和较为 “矮胖” 的分布, 符合黄金作为避险资产的特质.

在时间序列的平稳性方面, 我们对三种大宗商品区间价格的左右端点分别应用 ADF 检验, $Y_{L,t}$ 和 $Y_{R,t}$ 均未通过平稳性检验, 但其一阶差分序列均在 0.01 的显著性水平上拒绝原假设, 因此可以得到三种大宗商品的月度最高价和最低价是一阶差分平稳的. 本文将对经过对数差分处理后的三种大宗商品区间价格平稳序列进行建模.

大宗商品价格的影响因素一直以来都是学者, 政策制定者和投资者等重点关注的问题, 在这方面也已经存在大量的相关研究 (Lu et al., 2022; Yu et al., 2019; Zhang et al., 2018; Yang et al., 2016). 根据这些文献, 大宗商品价格受到供需关系, 宏观经济, 金融市场等多方面因素的影响. 本文中, 我们分别将美国标准普尔 500 波动率指数 (VIX), 美国经济政策不确定性指数, 美元指数等指标作为区间型解释变量来预测大宗商品价格, 详见表 2, 例如, 标准普尔 500 波动率指数的月度区间指数 (VIX_t) 是由日度 VIX 指数的月内最低值 ($\mathrm{VIX}_{L,t}$) 和最高值 ($\mathrm{VIX}_{R,t}$) 构成. 在门限变量选择方面, 基于经济学理论和大宗商品价格机制分析,

表 1　被解释变量的统计性质

	COMEX 黄金				布伦特原油				CBOT 玉米			
	$Y_{L,t}$	$Y_{R,t}$	$Y_{m,t}$	$Y_{r,t}$	$Y_{L,t}$	$Y_{R,t}$	$Y_{m,t}$	$Y_{r,t}$	$Y_{L,t}$	$Y_{R,t}$	$Y_{m,t}$	$Y_{r,t}$
平均	7.2254	7.2750	7.2502	0.0495	3.9493	4.0861	4.0177	0.1369	5.9306	6.0183	5.9745	0.0877
中位数	7.1679	7.2026	7.1843	0.0428	3.9940	4.1211	4.0333	0.1130	5.8777	5.9503	5.9115	0.0725
标准差	0.1713	0.1769	0.1737	0.0228	0.2802	0.2222	0.2470	0.1087	0.1737	0.1965	0.1835	0.0533
峰度	−1.0975	−1.0982	−1.1083	1.0699	1.7602	−0.3905	0.3649	23.1692	1.6105	2.4274	1.9643	4.0130
偏度	0.4814	0.5502	0.5182	1.1800	−1.1497	−0.4171	−0.7256	4.2585	1.5683	1.7570	1.6727	1.8405
最小值	6.9584	6.9910	6.9747	0.0176	2.9617	3.5296	3.2456	0.0313	5.7104	5.7907	5.7585	0.0201
最大值	7.5529	7.6296	7.5913	0.1246	4.3730	4.4590	4.4160	0.8252	6.4505	6.6490	6.5400	0.2908

注: 表格中黄金, 原油和玉米的价格数据均为原始价格取自然对数之后结果, 为了记号的简便性, 我们仍然用 $Y_{L,t}$, $Y_{R,t}$, $Y_{m,t}$, $Y_{r,t}$ 来表示取对数之后的价格. 注意到即使在新冠疫情期间, 布伦特原油价格也是正的, 因此, 取对数的处理过程是合理的. 样本范围是 2015 年 7 月 – 2021 年 12 月. 所有的数据均来源于 Wind 数据库.

表 2 区间型解释变量及其说明

被解释变量	解释变量	单位	形式
COMEX 黄金	标准普尔 500 波动率指数	/	$\mathrm{VIX}_t = [\mathrm{VIX}_{L,t}, \mathrm{VIX}_{R,t}]$
	美国经济政策不确定性指数	/	$\mathrm{EPU}_t = [\mathrm{EPU}_{L,t}, \mathrm{EPU}_{R,t}]$
	COMEX 黄金价格滞后一阶项	美元/盎司	$\mathrm{Gold}_{t-1} = [\mathrm{Gold}_{L,t-1}, \mathrm{Gold}_{R,t-1}]$
布伦特原油	名义美元指数	/	$\mathrm{GDI}_t = [\mathrm{GDI}_{L,t}, \mathrm{GDI}_{R,t}]$
	美国十年期国债收益率	%	$\mathrm{TY}_t = [\mathrm{TY}_{L,t}, \mathrm{TY}_{R,t}]$
	道琼斯工业平均指数	/	$\mathrm{DJ}_t = [\mathrm{DJ}_{L,t}, \mathrm{DJ}_{R,t}]$
	布伦特原油价格滞后一阶项	美元/桶	$\mathrm{Oil}_{t-1} = [\mathrm{Oil}_{L,t-1}, \mathrm{Oil}_{R,t-1}]$
CBOT 玉米	美国经济政策不确定性指数	/	$\mathrm{EPU}_t = [\mathrm{EPU}_{L,t}, \mathrm{EPU}_{R,t}]$
	道琼斯工业平均指数	/	$\mathrm{DJ}_t = [\mathrm{DJ}_{L,t}, \mathrm{DJ}_{R,t}]$
	CBOT 大豆总持仓	/	$\mathrm{SP}_t = [\mathrm{SP}_{L,t}, \mathrm{SP}_{R,t}]$
	CBOT 玉米价格滞后一阶项	美分/蒲式耳	$\mathrm{TY}_{t-1} = [\mathrm{TY}_{L,t-1}, \mathrm{TY}_{R,t-1}]$

本文将经济政策不确定性总指数作为预测黄金价格的门限变量, 将原油区间价格中点的对数收益率作为预测原油价格的门限变量, 而将厄尔尼诺指数作为预测玉米价格的门限变量. 文中使用的所有数据均可从万得数据库下载[1].

3.2 实验设计

在估计模型参数之前, 我们分别对黄金、原油、玉米区间价格的 TARIX 模型进行条件异方差检验, 结果发现三种预测模型均拒绝原假设, 即原始模型存在条件异方差, 因此我们采用广义最小 D_K 距离估计来求解模型参数. 本文中, 我们采用滚动窗口预测方法, 滚动窗口大小为 60 个月, 每次向前滚动一步. 具体步骤如下, 第一个训练集是从 2015 年 7 月 – 2020 年 6 月, 并基于此得到 2020 年 7 月的预测值; 第二个训练集为 2015 年 8 月 – 2020 年 7 月, 进而得到 2020 年 8 月的预测值, 以此类推, 我们分别进行向前滚动 12, 15 和 18 个月的预测, 滚动预测周期记为 T_f. 为了评价预测结果的准确性, 我们引入 10 种评价指标, 这些指标被广泛应用于区间预测的研究中 (Rodrigues and Salish, 2015; Sun et al., 2018; Lu et al., 2022). 表 3 给出了评价指标的定义及其含义, 其中 ω_1, ω_2, ω_{NSD1}, ω_{NSD2}, ω_{rate1}, ω_{rate2} 是从区间的角度衡量预测结果和实际值之间的差异, ω_L, ω_R, ω_{mid}, ω_{range} 则是基于区间中特殊的点 (范围) 来评价预测结果的优劣, 此外, 所有指标的取值越小意味着越好的预测性能.

为了研究 HTARIX 模型在预测性能方面的表现, 我们还引入了五种常见的区间回归模型进行预测结果的比较, 分别是 TARIX, ACIX, CRX, AR, VARX, 这些区间模型在实际应用中均表现出良好的效果. 其中 TARIX 模型即是不进行条件异方差处理的门限区间模型. ACIX 模型 (Han et al., 2016) 可以看作包含外生变量的 ARMA 模型在区间情境下的推广,

[1]本文使用的数据及代码已在科学数据银行 (ScienceDB) 公开, DOI: 10.57760/sciencedb.14918. 若使用文中数据信息, 请注明引文和数据出处.

表 3　评价指标及含义

评价指标	含义
$\omega_1 = 1 - \frac{1}{T}\sum_t \frac{\min(\hat{Y}_{R,t}, Y_{R,t}) - \max(\hat{Y}_{L,t}, Y_{L,t})}{\max(\hat{Y}_{R,t}, Y_{R,t}) - \min(\hat{Y}_{L,t}, Y_{L,t})}$	衡量预测区间和真实区间不重叠的区域
$\omega_2 = \frac{1}{T}\sqrt{\sum_t D_K(\hat{Y}_t, Y_t)}$	基于 D_K 距离的评价准则
$\omega_{\mathrm{NSD1}} = \frac{1}{T}\sum_t \frac{w([Y_{L,t}, Y_{R,t}] \cup [\hat{Y}_{L,t}, \hat{Y}_{R,t}]) - w([Y_{L,t}, Y_{R,t}] \cap [\hat{Y}_{L,t}, \hat{Y}_{R,t}])}{w([Y_{L,t}, Y_{R,t}] \cup [\hat{Y}_{L,t}, \hat{Y}_{R,t}])}$	衡量区间的标准化对称差
$\omega_{\mathrm{NSD2}} = 2 - \frac{1}{T}\sum_t \frac{w([\hat{Y}_{L,t}, \hat{Y}_{R,t}]) + w([Y_{L,t}, Y_{R,t}])}{R([Y_{L,t}, Y_{R,t}] \cup [\hat{Y}_{L,t}, \hat{Y}_{R,t}])}$	
$\omega_L = \sqrt{\frac{1}{T}\sum_t (\hat{Y}_{L,t} - Y_{L,t})^2}$	预测区间左端点的 RMSE
$\omega_R = \sqrt{\frac{1}{T}\sum_t (\hat{Y}_{R,t} - Y_{R,t})^2}$	预测区间右端点的 RMSE
$\omega_{\mathrm{mid}} = \sqrt{\frac{1}{T}\sum_t (\hat{M}_t - M_t)^2}$	预测区间中点的 RMSE
$\omega_{\mathrm{range}} = \sqrt{\frac{1}{T}\sum_t (\hat{R}_t - R_t)^2}$	预测区间长度的 RMSE
$\omega_{\mathrm{rate1}} = 1 - \frac{1}{T}\sum_t \frac{w([Y_{L,t}, Y_{R,t}] \cap [\hat{Y}_{L,t}, \hat{Y}_{R,t}])}{w([Y_{L,t}, Y_{R,t}])}$	预测结果的未覆盖率
$\omega_{\mathrm{rate2}} = 1 - \frac{1}{T}\sum_t \frac{w([Y_{L,t}, Y_{R,t}] \cap [\hat{Y}_{L,t}, \hat{Y}_{R,t}])}{w([\hat{Y}_{L,t}, \hat{Y}_{R,t}])}$	预测结果的无效率

注: 表格中的实际区间值记为 $Y_t = [Y_{L,t}, Y_{R,t}]$, 预测区间记为 $\hat{Y}_t = [\hat{Y}_{L,r}, \hat{Y}_{R,t}]$; $w(\cdot)$ 表示区间的宽度, $R(\cdot)$ 表示区间的极差, 例如, 如果区间 $I = [a_1, b_1] \cup [a_2, b_2]$, 且满足 $a_1 < b_1 < a_2 < b_2$, 则 $w(I) = (b_1 - a_1) + (b_2 - a_2)$, $R(I) = b_2 - a_1$.

其回归参数可由最小 D_K 距离估计求解, 模型具体形式如下:

$$Y_t = \alpha_0 + \beta_0 I_0 + \boldsymbol{Z}_t'\boldsymbol{\theta} + \epsilon_t,$$

其中, $Y_t = [Y_{L,t}, Y_{R,t}]$, $\boldsymbol{Z}_t = (Y_{t-1}, \cdots, Y_{t-p}, \boldsymbol{X}_t', \cdots, \boldsymbol{X}_{t-q}')$, $\boldsymbol{\theta} = (\beta_1, \cdots, \beta_p, \delta_1', \cdots, \delta_q')$ 是待估参数, $I_0 = [-\frac{1}{2}, \frac{1}{2}]$ 是区间截距项. ACIX 模型和 TARIX 模型的主要区别在于是否考虑区间时间序列的结构性变化, 前者是线性回归过程. CRX 模型 (González-Rivera and Lin, 2013) 则是分别对区间的中点和范围进行回归估计, 模型可以表示为:

$$\begin{aligned} Y_{m,t} &= \beta_{m,0} + \boldsymbol{Z}_{m,t}'\boldsymbol{\theta}_m + \epsilon_{m,t}, \\ Y_{r,t} &= \beta_{r,0} + \boldsymbol{Z}_{r,t}'\boldsymbol{\theta}_r + \epsilon_{r,t}, \end{aligned}$$

其中, $\{Y_{m,t}, \boldsymbol{Z}_{m,t}\}$ 和 $\{Y_{r,t}, \boldsymbol{Z}_{r,t}\}$ 分别表示区间变量的中点和范围, 模型参数由 OLS 估计得到. 和 CRX 模型类似, ARX 模型分别对区间的左右端点进行建模, 即:

$$\begin{aligned} Y_{L,t} &= \beta_{L,0} + \boldsymbol{Z}_{L,t}'\boldsymbol{\theta}_L + \epsilon_{L,t}, \\ Y_{R,t} &= \beta_{R,0} + \boldsymbol{Z}_{R,t}'\boldsymbol{\theta}_R + \epsilon_{R,t}. \end{aligned}$$

CRX 和 ARX 模型是通过建立两个线性回归模型来对区间数据进行建模, 在传统的区间数据研究中, 是一类常见的方法. VARX 模型是包含外生变量的向量自回归模型, 模型可以表

示为:

$$\begin{pmatrix} Y_{L,t} \\ Y_{R,t} \end{pmatrix} = \theta_0 + \theta_1 \begin{pmatrix} Z_{L,t,1} \\ Z_{R,t,1} \end{pmatrix} + \cdots + \theta_s \begin{pmatrix} Z_{L,t,s} \\ Z_{R,t,s} \end{pmatrix} + \begin{pmatrix} \epsilon_{L,t} \\ \epsilon_{R,t} \end{pmatrix}.$$

VARX 模型将区间数据看作二元的点值向量过程, 和 ACIX 模型的区别在于没有考虑区间内部点之间的关系以及区间截距项的影响, 我们期望通过预测结果的比较说明区间内部的信息是有价值的, 直接对二元的点值过程进行建模不能有效提高模型的预测精度. VARX 模型在已有的区间预测研究中也常被当作比较模型 (Sun et al., 2018; Lu et al., 2022; Lin and González-Rivera, 2016). 值得注意的是, 上面提到的五种比较模型中, TARIX 模型和 ACIX 模型是对区间型变量的回归建模, 它们将区间视作不可分割的集合, 而 CRX, ARX 和 VARX 模型本质上是对点值型变量建模.

3.3 实证结果

本节展示了 HTARIX 模型对黄金、原油、玉米三种大宗商品价格的预测性能, 并与五种常见的区间预测方法作比较, 结果见表 4~6, 每列中的黑体被用于强调该指标下的最小值. 从这些表格中, 我们观察到以下几个特征.

首先, 在三种大宗商品区间价格的预测中, 相比于其他回归模型, 本文提出的 HTARIX 模型在几乎所有的指标中都表现出最优的预测性能, 例如, 在表 4 中, 当预测期为 2020 年 7 月 – 2021 年 6 月时, HTARIX 模型的 w_1 为 0.0396, 较其余五种模型的 w_1 分别降低了 12.6%, 32.0%, 22.2%, 20.1% 和 0.81%. 此外, 假设检验表明, 基于表 2 中变量构建的黄金, 原油和玉米区间价格预测模型存在条件异方差. 因此, 我们可以得出结论, 条件异方差的存在将影响大宗商品区间价格模型的预测性能, 而消除条件异方差后的 TARIX 模型可以有效提高预测的准确性.

其次, 从预测结果可以看出两种门限区间模型 (TARIX, HTARIX) 的预测性能均优于一般线性区间回归模型 (ACIX) 和其他对比模型. 例如, 在预测原油价格时, 对于 2020 年 7 月 – 2021 年 9 月的预测结果, TARIX 和 HTARIX 模型的 w_2 分别为 0.0127 和 0.0113, 均小于其他四种模型的表现最好的 ACIX 模型, 即 0.0162, 其他指标亦然. 对此, 一种可能的解释是, 大宗商品价格的变化存在非线性特征, 切换机制或结构断点, 而门限区间模型可以有效捕捉这些特征, 进而提高模型的预测性能. 例如, 黄金因其独特的稀缺性和安全性等特征具有较强的避险属性, 其价格变化机制与政治, 经济环境的稳定性关系密切, 地缘政治、战争、政局不稳等动荡因素将会引发黄金价格的剧烈变化, 也会导致其价格变化机制发生改变, 因此采用经济政策不确定性指数作为门限变量有助于改进黄金价格的预测精度.

再者, 和基于点值型变量的区间回归模型 (CRX, AR, VARX) 相比, 直接对区间数据建模的模型 (ACIX, TARIX, HTARIX) 在区间型评价指标和点值型评价指标上都表现出更准确的预测效果. 例如, 从表 6 可以看出, 当预测期长度为 18 个月时 (2020 年 7 月 – 2021 年 12 月), ACIX 模型, TARIX 模型和 HTARIX 模型的 w_{NSD1} 分别为 0.6196, 0.5871 和 0.5539, 均小于 CRX 模型, ARX 模型和 VARX 模型的 0.6212, 0.6606 和 0.6308; 在区间价格中点的 RMSE 方面, 三种区间模型中表现最差的 ACIX 模型的 w_{mid} 为 0.0694, 仍然优于基于点值数据的区间模型中表现最好的 VARX 模型, 其 $w_{\mathrm{mid}} = 0.0700$. 对区间型变量直接建模的方

表 4　COMEX 黄金价格预测结果

预测期	模型	w_1	w_2	w_{NSD1}	w_{NSD2}	w_L	w_R	w_{mid}	w_{range}	w_{rate1}	w_{rate2}
	ACIX	0.0453	0.0099	0.6561	0.6573	0.0365	0.0473	0.0391	0.0316	0.5141	0.5276
	CRX	0.0582	0.0116	0.6549	0.6573	0.0478	0.0488	0.0425	0.0459	**0.4214**	0.5629
2020M7	AR	0.0509	0.0103	0.7193	0.7193	0.0390	0.0467	0.0381	0.0397	0.5653	0.5226
–2021M6	VARX	0.0495	0.0104	0.7336	0.7374	0.0383	0.0479	0.0397	0.0350	0.5803	0.5952
	TARIX	0.0399	0.0064	0.6138	0.6173	0.0364	0.0377	0.0346	**0.0266**	0.4735	0.4725
	HTARIX	**0.0396**	**0.0062**	**0.6029**	**0.6081**	**0.0358**	**0.0371**	**0.0339**	0.0268	0.4681	**0.4633**
	ACIX	0.0422	0.0088	0.6209	0.6218	0.0332	0.0442	0.0357	0.0318	0.4559	0.4879
	CRX	0.0529	0.0104	0.6184	0.6203	0.0431	0.0458	0.0386	0.0443	**0.3610**	0.5320
2020M7	AR	0.0472	0.0090	0.6840	0.6840	0.0359	0.0435	0.0350	0.0381	0.5138	0.4942
–2021M9	VARX	0.0470	0.0094	0.7073	0.7103	0.0349	0.0454	0.0367	0.0344	0.5304	0.5582
	TARIX	0.0378	0.0059	0.5869	0.5896	0.0330	0.0359	0.0316	**0.0275**	0.4231	0.4405
	HTARIX	**0.0375**	**0.0058**	**0.5781**	**0.5823**	**0.0324**	**0.0353**	**0.0310**	0.0276	0.4191	**0.4321**
	ACIX	0.0392	0.0078	0.6055	0.6063	0.0306	0.0415	0.0332	0.0300	0.4267	0.4741
	CRX	0.0498	0.0094	0.6024	0.6040	0.0396	0.0435	0.0357	0.0427	**0.3198**	0.5182
2020M7	AR	0.0438	0.0080	0.6481	0.6481	0.0329	0.0409	0.0324	0.0362	0.4576	0.4675
–2021M12	VARX	0.0427	0.0082	0.6685	0.6711	0.0321	0.0422	0.0339	0.0321	0.4758	0.5270
	TARIX	0.0353	0.0053	0.5797	0.5820	0.0305	0.0341	0.0296	0.0260	0.4040	0.4371
	HTARIX	**0.0349**	**0.0052**	**0.5745**	**0.5779**	**0.0301**	**0.0335**	**0.0291**	**0.0259**	0.4040	**0.4337**

表 5　布伦特原油价格预测结果

预测期	模型	w_1	w_2	w_{NSD1}	w_{NSD2}	w_L	w_R	w_{mid}	w_{range}	w_{rate1}	w_{rate2}
	ACIX	0.0674	0.0156	0.5908	0.6053	0.0651	0.0583	0.0576	**0.0451**	0.4389	**0.5037**
	CRX	0.1112	0.0628	0.7185	0.7401	0.0848	0.1173	0.0924	0.0880	0.6495	0.6655
2020M7	AR	0.0721	0.0214	0.6649	0.8801	0.0776	0.0637	0.0613	0.0551	0.6213	1.2598
–2021M6	VARX	0.0752	0.0211	0.5950	0.6630	0.0679	0.0652	0.0584	0.0624	0.6009	0.7393
	TARIX	0.0650	0.0146	0.5606	0.5704	0.0618	0.0537	0.0508	0.0555	0.4065	0.5575
	HTARIX	**0.0631**	**0.0132**	**0.5365**	**0.5436**	**0.0608**	**0.0505**	**0.0487**	0.0547	**0.3857**	0.5049
	ACIX	0.0726	0.0162	0.6219	0.6335	0.0761	0.0593	0.0642	**0.0463**	0.4934	0.5071
	CRX	0.0991	0.0501	0.6654	0.6831	0.0820	0.1049	0.0856	0.0781	0.5779	0.6049
2020M7	AR	0.0781	0.0209	0.6798	0.8578	0.0880	0.0625	0.0672	0.0585	0.6252	1.1116
–2021M9	VARX	0.0759	0.0204	0.6109	0.6700	0.0719	0.0641	0.0605	0.0610	0.5901	0.6058
	TARIX	0.0619	0.0127	0.5519	0.5594	0.0606	0.0504	0.0497	0.0507	0.4046	0.5020
	HTARIX	**0.0603**	**0.0113**	**0.5281**	**0.5337**	**0.0594**	**0.0468**	**0.0471**	0.0507	**0.3839**	**0.4583**
	ACIX	0.0727	0.0156	0.6150	0.6246	0.0785	0.0579	0.0649	**0.0467**	0.4786	0.5027
	CRX	0.0974	0.0446	0.6509	0.6653	0.0822	0.0983	0.0819	0.0775	0.5205	0.5847
2020M7	AR	0.0834	0.0200	0.6806	0.8241	0.0919	0.0600	0.0680	0.0649	0.5963	1.0210
–2021M12	VARX	0.0733	0.0179	0.5971	0.6424	0.0715	0.0602	0.0594	0.0570	0.5527	0.6245
	TARIX	0.0671	0.0127	0.5591	0.5657	0.0694	0.0487	0.0529	0.0565	0.4021	0.5007
	HTARIX	**0.0653**	**0.0115**	**0.5398**	**0.5446**	**0.0685**	**0.0460**	**0.0514**	0.0552	**0.3890**	**0.4591**

表 6　CBOT 玉米价格预测结果

预测期	模型	w_1	w_2	w_{NSD1}	w_{NSD2}	w_L	w_R	w_{mid}	w_{range}	w_{rate1}	w_{rate2}
	ACIX	0.0915	0.0500	0.6159	0.6166	0.0585	0.1027	0.0709	0.0885	0.4483	0.4508
	CRX	0.1131	0.0704	0.6017	0.6302	0.0953	0.1233	0.0988	0.0975	0.4185	0.6300
2020M7	AR	0.0951	0.0450	0.6130	0.6130	0.0731	0.0965	0.0733	0.0883	0.4272	0.4609
–2021M6	VARX	0.0893	0.0488	0.6294	0.6294	0.0594	0.1014	0.0706	0.0875	0.4462	0.4656
	TARIX	0.0819	0.0450	0.6206	0.6206	**0.0513**	0.0989	0.0688	0.0767	0.4738	0.4421
	HTARIX	**0.0797**	**0.0428**	**0.5819**	**0.5819**	0.0517	**0.0963**	**0.0675**	**0.0754**	**0.4163**	**0.4212**
	ACIX	0.1002	0.0537	0.6197	0.6202	0.0639	0.1057	0.0733	0.0950	0.4268	0.4629
	CRX	0.1269	0.0811	0.6324	0.7227	0.1039	0.1266	0.0958	0.1227	0.4545	0.6649
2020M7	AR	0.1115	0.0580	0.6541	0.6541	0.0802	0.1075	0.0777	0.1086	0.4723	0.4787
–2021M9	VARX	0.0984	0.0581	0.6207	0.6207	0.0587	0.1104	0.0740	0.0966	0.4329	0.4699
	TARIX	0.0914	0.0498	0.6194	0.6194	0.0583	0.1031	0.0720	0.0855	0.4396	0.4554
	HTARIX	**0.0894**	**0.0475**	**0.5883**	**0.5883**	**0.0583**	**0.1005**	**0.0705**	**0.0843**	**0.3952**	**0.4373**
	ACIX	0.0917	0.0467	0.6196	0.6200	0.0609	0.0988	0.0694	0.0876	0.4239	0.4709
	CRX	0.1158	0.0684	0.6212	0.6965	0.0983	0.1161	0.0891	0.1136	0.4187	0.6382
2020M7	AR	0.1009	0.0497	0.6606	0.6606	0.0755	0.0997	0.0731	0.0995	0.4783	0.4893
–2021M12	VARX	0.0929	0.0502	0.6308	0.6308	0.0580	0.1025	0.0700	0.0903	0.4360	0.4737
	TARIX	0.0812	0.0419	0.5871	0.5871	0.0545	0.0945	0.0664	0.0786	0.4050	0.4293
	HTARIX	**0.0798**	**0.0399**	**0.5539**	**0.5539**	**0.0544**	**0.0920**	**0.0648**	**0.0777**	**0.3667**	**0.3980**

法表现更好的原因可以解释为基于最小 D_K 距离估计方法的参数估计不仅考虑了区间的左右端点, 也考虑了区间内部点之间的关联, 更加充分地利用了区间的内部信息; 此外, 它们将区间看作不可分割的整体, 由此得到了更加简约的预测模型, 有助于提高模型的预测性能.

4 结束语

本文提出了一种检验 TARIX 模型中条件异方差的方法, 并建立了相关检验统计量的渐近理论, 进而提出了广义最小 D_K 距离估计来求解 HTARIX 模型的待估参数. 我们提出的方法最突出的优势在于可以捕捉区间数据中的非线性特征以及消除 TARIX 模型中条件异方差带来的影响, 在实际中有着更加广泛的应用价值. 和现有的预测模型相比, 当区间回归模型存在条件异方差时, HTARIX 模型在黄金、原油和玉米三种代表性大宗商品区间价格的预测方面, 给出了更准确的样本外预测结果, 同时在大宗商品的最低价, 最高价以及价格范围的预测上也表现出优异的预测能力. HTARIX 模型优异的样本外预测性能证实了基于广义最小 D_K 距离估计的区间模型可以有效利用区间值时间序列数据中的丰富信息, 同时提高参数估计的有效性以及模型的预测精度.

区间数据可以为投资者和决策者提供更加直观、丰富的信息, 并且降低信息获取的成本, 在现实生活中具有重要的应用前景. 例如, 基于 HTARIX 模型得到的更精确的预测结果可以帮助投资者及时调整投资策略. 另一方面, 基于区间数据的预测模型为政策制定提供了重要的理论支撑, 对相关部门建立大宗商品市场的监测预警机制和风险防范机制具有重要参考价值. 因此, HTARIX 模型在策略研究、政策制定、风险监控等领域具有潜在的重要意义.

在未来的研究中, 区间模型还存在许多值得深入研究的领域, 例如: 除了门限模型外, 区间型时间序列中结构性断点的检验和带有时变参数的区间模型也是识别和捕捉区间数据中非线性特征的重要方法; 此外, 基于区间数据的因果推断和变量筛选对提高模型的解释力度和预测性能具有重要意义. 另一方面, 信息技术的发展促进了区间数据等非结构化数据的诞生, 新闻, 社交媒体, 短视频等新型大数据也会对大宗商品市场造成冲击 (余乐安等, 2023), 合理, 有效地利用互联网数据有助于提高大宗商品价格预测的及时性和准确性.

参 考 文 献

何亚男, 汪寿阳, (2011). 世界经济与国际原油价格: 基于 Kilian 经济指数的协整分析 [J]. 系统工程理论与实践, 31(2): 221–228.

He Y N, Wang S Y, (2011). The Global Economy and World Crude Oil Price: An Analysis of the Cointegration with Kilian Economic Index[J]. Systems Engineering — Theory & Practice, 31(2): 221–228.

卢全莹, 柴建, 曹蒲菊, 魏照昊, 汪寿阳, (2022). 世界原油供给阻滞对中国宏观经济的冲击效应测算 —— 以美国对伊朗实施石油制裁为例 [J]. 系统工程理论与实践, 42(7): 1735–1754.

Lu Q Y, Chai J, Cao P J, Wei Z H, Wang S Y, (2022). Analysis of the Impact of World Crude Oil Supply Block on China's Economy: A Case Study of US Oil Sanctions Against Iran[J]. Systems Engineering — Theory & Practice, 42(7): 1735–1754.

卢全莹, 史惠婷, 汪寿阳, (2022). “黑天鹅” 和 “灰犀牛” 事件对原油市场的冲击效应测算: GSI-BN 研究

框架 [J]. 计量经济学报, 2(1): 194–208.
Lu Q Y, Shi H T, Wang S Y, (2022). Estimating the Shock Effect of “Black Swan” and “Gray Rhino” Events on the Crude Oil Market: The GSI-BN Research Framework[J]. China Journal of Econometrics, 2(1): 194–208.

王珏, 胡蓝艺, 齐琛, (2017). 基于网络关注度的大宗商品市场预测研究 [J]. 系统工程理论与实践, 37(5): 1163–1171.
Wang J, Hu L Y, Qi C, (2017). Prediction of Bulk Commodities Based on Internet Concerns[J]. Systems Engineering — Theory & Practice, 37(5): 1163–1171.

余乐安, 赵晨珊, 宋正阳, (2023). 融合网络新闻主题分布与主题分类下新闻情感的原油价格预测研究 [J]. 计量经济学报, 3(2): 443–463.
Yu L A, Zhao C S, Song Z Y, (2023). Crude Oil Price Forecasting with Online News Topic Distribution and News Sentiment Classified by Topics[J]. China Journal of Econometrics, 3(2): 443–463.

张翔, 刘璐, 李伦一, (2017). 国际大宗商品市场金融化与中国宏观经济波动 [J]. 金融研究, (1): 35–51.
Zhang X, Liu L, Li L Y, (2017). The Financialization of International Commodity Market and Chinese Macroeconomic Fluctuations[J]. Journal of Financial Research, (1): 35–51.

周浩, 张逸飞, 王震, 王珏, 汪寿阳, (2021). 一种改进的原油价格组合预测优化策略研究 [J]. 系统工程理论与实践, 41(10): 2660–2668.
Zhou H, Zhang Y F, Wang Z, Wang J, Wang S Y, (2021). An Improved Research on Optimization Strategy of Crude Oil Price Forecast Combination[J]. Systems Engineering — Theory & Practice, 41(10): 2660–2668.

Ahumada H, Cornejo M, (2016). Forecasting Food Prices: The Case of Corn, Soybeans and Wheat[J]. International Journal of Forecasting, 32(3): 838–848.

Akgiray V, (1989). Conditional Heteroscedasticity in Time Series of Stock Returns: Evidence and Forecasts[J]. Journal of Business, 62(1): 55–80.

Asai M, Gupta R, McAleer M, (2020). Forecasting Volatility and Co-volatility of Crude Oil and Gold Futures: Effects of Leverage, Jumps, Spillovers, and Geopolitical Risks[J]. International Journal of Forecasting, 36(3): 933–948.

Billard L, Diday E, (2000). Regression Analysis for Interval-valued Data[M]// Data Analysis, Classification, and Related Methods. Berlin, Heidelberg: Springer Berlin Heidelberg: 369–374.

Cheong C W, (2009). Modeling and Forecasting Crude Oil Markets Using ARCH-type Models[J]. Energy policy, 37(6): 2346–2355.

Costola M, Lorusso M, (2022). Spillovers Among Energy Commodities and the Russian Stock Market[J]. Journal of Commodity Markets, 28: 100249.

Diday E, (1989). Introduction à L’approche Symbolique en Analyse Des Données[J]. RAIRO-Operations Research, 23(2): 193–236.

González-Rivera G, Lin W, (2013). Constrained Regression for Interval-valued Data[J]. Journal of Business & Economic Statistics, 31(4): 473–490.

Han A, Hong Y M, Wang S Y, Yu X, (2016). A Vector Autoregressive Moving Average Model for Interval-valued Time Series Data[M]// Essays in Honor of Aman Ullah. Yorkshire: Emerald Group Publishing Limited: 417–460.

He Y N, Han A, Hong Y M, Sun Y Y, Wang S Y, (2021). Forecasting Crude Oil Price Intervals and Return Volatility via Autoregressive Conditional Interval Models[J]. Econometric Reviews, 40(6): 584–606.

Heath D, (2019). Macroeconomic Factors in Oil Futures Markets[J]. Management Science, 65(9): 4407–4421.

Kaucher E, (1980). Interval Analysis in the Extended Interval Space IR[J]. Fundamentals of Numerical Computation (Computer-Oriented Numerical Analysis), 33–49.

Lin W, González-Rivera G, (2016). Interval-valued Time Series Models: Estimation Based on Order Statistics Exploring the Agriculture Marketing Service Data[J]. Computational Statistics & Data Analysis, 100: 694–711.

Lu Q Y, Sun Y Y, Hong Y M, Wang S Y. (2022). Forecasting Interval-valued Crude Oil Prices Using Asymmetric Interval Models[J]. Quantitative Finance, 22(11): 2047–2061.

Näther W, Körner R, (2002). On the Variance of Random Fuzzy Variables[M]// Statistical Modelling, Analysis and Management of Fuzzy Data. Heidelberg: Physica-Verlag HD, 25–42.

Neto E A L, De Carvalho F D A T, (2008). Centre and Range Method for Fitting a Linear Regression Model to Symbolic Interval Data[J]. Computational Statistics & Data Analysis, 52(3): 1500–1515.

Neto E A L, De Carvalho F D A T, (2010). Constrained Linear Regression Models for Symbolic Interval-valued Variables[J]. Computational Statistics & Data Analysis, 54(2): 333–347.

Qiao K N, Liu Z Y, Huang B, Sun Y Y, Wang S Y, (2021). Brexit and Its Impact on the US Stock Market[J]. Journal of Systems Science and Complexity, 34(3): 1044–1062.

Rodrigues P M M, Salish N, (2015). Modeling and Forecasting Interval Time Series with Threshold Models[J]. Advances in Data Analysis and Classification, 9: 41–57.

Sun Y Y, Bao Q, Zheng J, Wang S Y, (2020). Assessing the Price Dynamics of Onshore and Offshore RMB Markets: An ITS Model Approach[J]. China Economic Review, 62: 101476.

Sun Y Y, Han A, Hong Y M, Wang S Y, (2018). Threshold Autoregressive Models for Interval-valued Time Series Data[J]. Journal of Econometrics, 206(2): 414–446.

Sun Y Y, Qiao K N, Wang S Y, (2021). Uncertainty Shocks of Trump Election in an Interval Model of Stock Market[J]. Quantitative Finance, 21(5): 865–879.

Sun Y Y, Zhang X, Hong Y M, Wang S Y, (2019). Asymmetric Pass-through of Oil Prices to Gasoline Prices With Interval Time Series Modelling[J]. Energy Economics, 78: 165–173.

Sun Y Y, Zhang X, Wan A T K, Wang S Y, (2022). Model Averaging for Interval-valued Data[J]. European Journal of Operational Research, 301(2): 772–784.

Wang J, Athanasopoulos G, Hyndman R J, Wang S Y, (2018). Crude Oil Price Forecasting Based on Internet Concern Using an Extreme Learning Machine[J]. International Journal of Forecasting, 34(4): 665–677.

Wang Y D, Hao X F, (2022). Forecasting the Real Prices of Crude Oil: A Robust Weighted Least Squares Approach[J]. Energy Economics, 116: 106405.

White H, (1980). A Heteroskedasticity-consistent Covariance Matrix Estimator and a Direct test for Heteroskedasticity[J]. Econometrica: Journal of the Econometric Society: 817–838.

White H, (1980). Nonlinear Regression on Cross-section Data[J]. Econometrica: Journal of the Econometric Society: 721–746.

Yang W, Han A, Hong Y M, Wang S Y, (2016). Analysis of Crisis Impact on Crude Oil Prices: A New Approach with Interval Time Series Modelling[J]. Quantitative Finance, 16(12): 1917–1928.

Yen-Ku K, Maneengam A, Cong P T, Quynh N N, Ageli M M, et al. (2022). Covid-19 and Oil and Gold Price Volatilities: Evidence from China Market[J]. Resources Policy, 79: 103024.

Yu L, Zhao Y Q, Tang L, Yang Z B, (2019). Online Big Data-driven Oil Consumption Forecasting with Google Trends[J]. International Journal of Forecasting, 35(1): 213–223.

Zagaglia P, (2010). Macroeconomic Factors and Oil Futures Prices: A Data-rich Model[J]. Energy Economics, 32(2): 409–417.

Zhang D B, Li Q, Mugera A W, Ling L W, (2020). A Hybrid Model Considering Cointegration for Interval-valued Pork Price Forecasting in China[J]. Journal of Forecasting, 39(8): 1324–1341.

Zhang X, Lai K K, Wang S Y, (2008). A New Approach for Crude Oil Price Analysis Based on Empirical Mode Decomposition[J]. Energy economics, 30(3): 905–918.

Zhang Y J, Ma F, Shi B S, Huang D S, (2018). Forecasting the Prices of Crude Oil: An Iterated Combination Approach[J]. Energy Economics, 70: 472–483.

Zhang Y, Ma F, Wang Y, (2019). Forecasting Crude Oil Prices with a Large Set of Predictors: Can LASSO Select Powerful Predictors?[J]. Journal of Empirical Finance, 54: 97–117.

Zhang Y J, Yao T, He L Y, Ripple R, (2019). Volatility Forecasting of Crude Oil Market: Can the Regime Switching GARCH Model Beat the Single-regime GARCH Models?[J]. International Review of Economics & Finance, 59: 302–317.

附录

附录 A

下面的 5 个条件可以在 Sun et al. (2018) 中找到类似的设定, 它们确保了 TARIX 模型参数估计的渐近正态性.

条件 1　$\{Y_t\}$ 是一个严平稳的遍历区间过程, 且满足 $E\|Y_t\|_K^4 < \infty$.

条件 2　(i) $\{\varepsilon_t\}$ 是一个区间鞅差分序列, 即: $E(\varepsilon_t|I_{t-1}) = [0,0]$, 且满足 $E\|\varepsilon_t\|_K^4 < \infty$. (ii) $\{\varepsilon_t\}$ 是绝对连续的, 并拥有一直连续且正的概率密度函数.

条件 3　存在 $\{\boldsymbol{Y}_t\}$ 的一个唯一不变测度 $\Pi(\cdot)$, 使得存在 $\eta > 0, \rho \in [0,1]$, 对任意 $y \in (I_{\mathcal{R}})^p$ 和 $n \in \mathcal{N}$, 我们有 $\|p^n(y,\cdot) - \Pi(\cdot)\|_v \le \eta(1 + \|y\|_K^2)\rho^n$, 其中 $I_{\mathcal{R}}$ 是 $\mathcal{R}$ 上的有序数对的闭集构成的空间, $\|\cdot\|_v$ 是全变差范数.

条件 4　对于 $Z_{pt} = (Y_{t-1}, \cdots, Y_{t-p})$ 和 $q_t = \gamma$, $P[Z_{pt}'(\boldsymbol{\theta}_{10} - \boldsymbol{\theta}_{20}) \neq 0] = 1$, 这里 p 是 Y_t 的滞后阶数.

条件 5　$E[\langle s_{\frac{\partial}{\partial\boldsymbol{\beta}}\varepsilon_t(\boldsymbol{\beta})}, s_{\frac{\partial}{\partial\boldsymbol{\beta}^T}\varepsilon_t(\boldsymbol{\beta})}\rangle_K]$ 和 $E[\langle s_{\frac{\partial}{\partial\boldsymbol{\beta}}\varepsilon_t(\boldsymbol{\beta})}, s_{\varepsilon_t(\boldsymbol{\beta})}\rangle_K \langle s_{\varepsilon_t(\boldsymbol{\beta})}, s_{\frac{\partial}{\partial\boldsymbol{\beta}}\varepsilon_t(\boldsymbol{\beta})}\rangle_K]$ 对真实参数 $\boldsymbol{\beta}_0$ 某个邻域内的所有 $\boldsymbol{\beta}$ 是正定的.

附录 B

定理 1 的证明: 令 $\boldsymbol{\theta} = (\boldsymbol{\beta}, \sigma)$, 其中 $\boldsymbol{\beta} = (\boldsymbol{\beta}^{(1)}, \boldsymbol{\beta}^{(2)})$, 记 $D_n^s(\boldsymbol{\theta}) = \frac{1}{n}\sum_{i=1}^n(\|Y_i - \boldsymbol{X}_i\boldsymbol{\beta}^{(1)}I_{1i} - \boldsymbol{X}_i\boldsymbol{\beta}^{(2)}I_{2i}\|_K^2 - \sigma^2)(\Psi_{is} - \bar{\Psi}_{ns})$, 其中, $I_{1i} = I(q_i \le \gamma)$, $I_{2i} = I(q_i > \gamma)$. 由 ε_i 的同方差性且独立于 X_i, 我们得到 $E[(\|\varepsilon_i\|_K^2 - \sigma_0^2)(\Psi_{is} - \bar{\Psi}_{ns})] = 0$. 定义矩阵 $\bar{B}_n(\boldsymbol{\theta})$, 其 (s,t) 位置上的元素为:

$$\bar{B}_n^{st}(\boldsymbol{\theta}) = \frac{1}{n}\sum_{i=1}^n E\{(\|Y_i - \boldsymbol{X}_i\boldsymbol{\beta}^{(1)}I_{1i} - \boldsymbol{X}_i\boldsymbol{\beta}^{(2)}I_{2i}\|_K^2 - \sigma^2)^2(\Psi_{is} - \bar{\Psi}_{ns})(\Psi_{it} - \bar{\Psi}_{nt})\}.$$

由假设 5 知, $\bar{B}_n(\boldsymbol{\theta}_0)$ 是非奇异的; 且由假设 4 以及 $\boldsymbol{X}_i$ 和 ε_i 的独立性可知 $\bar{B}_n(\boldsymbol{\theta}_0)$ 的元素是一致有界的. 对足够大的 n, 我们有 $\bar{B}_n(\boldsymbol{\theta}_0)^{-1} = [\bar{B}_n(\boldsymbol{\theta}_0)^{-1/2}]^2$. 令 $D_n(\boldsymbol{\theta}_0) =$

$(D_n^1(\boldsymbol{\theta}_0),\cdots,D_n^{p(p+1)/2}(\boldsymbol{\theta}_0))'$, 由 White (1980a) 中定理 2 的证明可知, 根据中心极限定理, 我们有:

$$\sqrt{n}\bar{B}_n(\boldsymbol{\theta}_0)^{-1/2}D_n(\boldsymbol{\theta}_0)\xrightarrow{d}N(\mathbf{0},I_{p(p+1)/2}). \tag{B.1}$$

下面, 我们首先证明下式成立:

$$\sqrt{n}|D_n^s(\hat{\boldsymbol{\theta}}_n)-D_n^s(\boldsymbol{\theta}_0)|\xrightarrow{p}0, \tag{B.2}$$

其中

$$D_n^s(\hat{\boldsymbol{\theta}}_n)=\frac{1}{n}\sum_{i=1}^n(\|Y_i-\boldsymbol{X}_i\hat{\boldsymbol{\beta}}_n^{(1)}I_{1i}-\boldsymbol{X}_i\hat{\boldsymbol{\beta}}_n^{(2)}I_{2i}\|_K^2-\hat{\sigma}_n^2)\Psi_{is},$$
$$\hat{\sigma}_n=\frac{1}{n}\sum_{i=1}^n\|Y_i-\boldsymbol{X}_i\hat{\boldsymbol{\beta}}_n^{(1)}I_{1i}-\boldsymbol{X}_i\hat{\boldsymbol{\beta}}_n^{(2)}.I_{2i}\|_K^2.$$

注意到 Ψ_{ns} 和 i 无关, 我们有 $\frac{1}{n}\sum_{i=1}^n(\|Y_i-\boldsymbol{X}_i\hat{\boldsymbol{\beta}}_n^{(1)}I_{1i}-\boldsymbol{X}_i\hat{\boldsymbol{\beta}}_n^{(2)}I_{2i}\|_K^2-\hat{\sigma}_n^2)\bar{\Psi}_{ns}=0$, 因此

$$D_n^s(\hat{\boldsymbol{\theta}}_n)=\frac{1}{n}\sum_{i=1}^n(\|Y_i-\boldsymbol{X}_i\hat{\boldsymbol{\beta}}_n^{(1)}I_{1i}-\boldsymbol{X}_i\hat{\boldsymbol{\beta}}_n^{(2)}I_{2i}\|_K^2-\hat{\sigma}_n^2)(\Psi_{is}-\bar{\Psi}_{ns}).$$

在同方差假定下, 由 Sun et al. (2018) 中的定理 5, 我们有 $(\hat{\boldsymbol{\beta}}_n^{(1)},\hat{\boldsymbol{\beta}}_n^{(2)},\hat{\sigma}_n)\xrightarrow{p}(\boldsymbol{\beta}_0^{(1)},\boldsymbol{\beta}_0^{(2)},\sigma_0)$, 即 $\hat{\boldsymbol{\theta}}_n\xrightarrow{p}\boldsymbol{\theta}_0$. 进而, 对足够大的 n, 由 Taylor 公式, 得到:

$$\begin{aligned}D_n^s(\hat{\boldsymbol{\theta}}_n)=&D_n^s(\boldsymbol{\theta}_0)+\sum_{j=1}^p(\hat{\beta}_{nj}^{(1)}-\beta_{0j}^{(1)})\frac{\partial D_n^s(\tilde{\boldsymbol{\theta}}_n)}{\partial\beta_j^{(1)}}+\sum_{j=1}^p(\hat{\beta}_{nj}^{(2)}-\beta_{0j}^{(2)})\frac{\partial D_n^s(\tilde{\boldsymbol{\theta}}_n)}{\partial\beta_j^{(2)}}+\\&(\hat{\sigma}_n^2-\sigma_0^2)\frac{\partial D_n^s(\tilde{\boldsymbol{\theta}}_n)}{\partial\sigma^2},\end{aligned}$$

其中, $\tilde{\theta}_n$ 在 $\hat{\theta}_n$ 和 θ_0 之间, 且位于 θ_0 的一个凸紧邻域内. 由三角不等式可得:

$$\begin{aligned}\sqrt{n}|D_n^s(\hat{\boldsymbol{\theta}}_n)-D_n^s(\boldsymbol{\theta}_0)|\le&\sum_{j=1}^p\sqrt{n}|\hat{\beta}_{nj}^{(1)}-\beta_{nj}^{(1)}|\cdot\left|\frac{\partial D_n^s(\tilde{\boldsymbol{\theta}}_n)}{\partial\beta_j^{(1)}}\right|+\sum_{j=1}^p\sqrt{n}|\hat{\beta}_{nj}^{(2)}-\beta_{nj}^{(2)}|\cdot\left|\frac{\partial D_n^s(\tilde{\boldsymbol{\theta}}_n)}{\partial\beta_j^{(2)}}\right|+\\&\sqrt{n}|\hat{\sigma}_n^2-\sigma_0^2|\cdot\left|\frac{\partial D_n^s(\tilde{\boldsymbol{\theta}}_n)}{\partial\sigma^2}\right|.\end{aligned} \tag{B.3}$$

由 Sun et al. (2018) 中的定理 3 可知: $\sqrt{n}|\hat{\beta}_{nj}^{(1)}-\beta_{0j}^{(1)}|=O_p(1)$ 以及 $\sqrt{n}|\hat{\beta}_{nj}^{(2)}-\beta_{0j}^{(2)}|=O_p(1)$, 据此容易得到 $\sqrt{n}|\hat{\sigma}_n^2-\sigma_0^2|=O_p(1)$. 由 D_n^s 的定义, 我们有:

$$\frac{\partial D_n^s(\tilde{\theta}_n)}{\partial\beta_j^{(1)}}=-\frac{2}{n}\sum_{i=1}^n\langle s_{Y_i-\boldsymbol{X}_i\tilde{\boldsymbol{\beta}}_n^{(1)}I_{1i}},s_{X_{ij}I_{1i}}\rangle_K(\Psi_{is}-\bar{\Psi}_{ns}),$$
$$\frac{\partial D_n^s(\tilde{\theta}_n)}{\partial\beta_j^{(2)}}=-\frac{2}{n}\sum_{i=1}^n\langle s_{Y_i-\boldsymbol{X}_i\tilde{\boldsymbol{\beta}}_n^{(2)}I_{1i}},s_{X_{ij}I_{1i}}\rangle_K(\Psi_{is}-\bar{\Psi}_{ns}),$$
$$\frac{\partial D_n^s(\tilde{\theta}_n)}{\partial\sigma^2}=-\frac{1}{n}\sum_{i=1}^n(\Psi_{is}-\bar{\Psi}_{ns}).$$

由假设 1, 2和 4 可知, $|\langle s_{Y_i-\boldsymbol{X}_i\boldsymbol{\beta}_0^{(1)}I_{1i}}, s_{X_{ij}I_{1i}}\rangle_K\Psi_{is}|$ 具有有限期望, 由 White (1980b) 中的引理 2.3, 我们得到:

$$\left|\frac{1}{n}\sum_{i=1}^{n}\langle s_{Y_i-\boldsymbol{X}_i\boldsymbol{\beta}_0^{(1)}I_{1i}}, s_{X_{ij}I_{1i}}\rangle_K(\Psi_{is}-\bar{\Psi}_{ns})-\frac{1}{n}\sum_{i=1}^{n}E[\langle s_{Y_i-\boldsymbol{X}_i\boldsymbol{\beta}_0^{(1)}I_{1i}}, s_{X_{ij}I_{1i}}\rangle_K(\Psi_{is}-\bar{\Psi}_{ns})]\right|\xrightarrow{\text{a.s.}}0. \tag{B.4}$$

由于 $\tilde{\boldsymbol{\beta}}_n\xrightarrow{p}\boldsymbol{\beta}_0$, 由 (A.4) 可得:

$$\begin{aligned}
&\left|\frac{1}{n}\sum_{i=1}^{n}\langle s_{Y_i-\boldsymbol{X}_i\tilde{\boldsymbol{\beta}}_n^{(1)}I_{1i}}, s_{X_{ij}I_{1i}}\rangle_K(\Psi_{is}-\bar{\Psi}_{ns})-\frac{1}{n}\sum_{i=1}^{n}E(\langle s_{Y_i-\boldsymbol{X}_i\boldsymbol{\beta}_0^{(1)}I_{1i}}, s_{X_{ij}I_{1i}}\rangle_K(\Psi_{is}-\bar{\Psi}_{ns}))\right|\\
=&\frac{1}{n}\left|\sum_{i=1}^{n}\langle s_{Y_i-\boldsymbol{X}_i\tilde{\boldsymbol{\beta}}_n^{(1)}I_{1i}}, s_{X_{ij}I_{1i}}\rangle_K(\Psi_{is}-\bar{\Psi}_{ns})-\sum_{i=1}^{n}\langle s_{Y_i-\boldsymbol{X}_i\boldsymbol{\beta}_0^{(1)}I_{1i}}, s_{X_{ij}I_{1i}}\rangle_K(\Psi_{is}-\bar{\Psi}_{ns})+\right.\\
&\left.\sum_{i=1}^{n}\langle s_{Y_i-\boldsymbol{X}_i\boldsymbol{\beta}_0^{(1)}I_{1i}}, s_{X_{ij}I_{1i}}\rangle_K(\Psi_{is}-\bar{\Psi}_{ns})-\sum_{i=1}^{n}E(\langle s_{Y_i-\boldsymbol{X}_i\boldsymbol{\beta}_0^{(1)}I_{1i}}, s_{X_{ij}I_{1i}}\rangle_K(\Psi_{is}-\bar{\Psi}_{ns}))\right|\\
\le&\frac{1}{n}\left|\sum_{i=1}^{n}\langle s_{Y_i-\boldsymbol{X}_i(\tilde{\boldsymbol{\beta}}_n^{(1)}-\boldsymbol{\beta}_0^{(1)})I_{1i}}, s_{X_{ij}I_{1i}}\rangle_K(\Psi_{is}-\bar{\Psi}_{ns})\right|+\\
&\frac{1}{n}\left|\sum_{i=1}^{n}\langle s_{Y_i-\boldsymbol{X}_i\boldsymbol{\beta}_0^{(1)}I_{1i}}, s_{X_{ij}I_{1i}}\rangle_K(\Psi_{is}-\bar{\Psi}_{ns})-\sum_{i=1}^{n}E(\langle s_{Y_i-\boldsymbol{X}_i\boldsymbol{\beta}_0^{(1)}I_{1i}}, s_{X_{ij}I(q_i\le\gamma)}\rangle_K(\Psi_{is}-\bar{\Psi}_{ns}))\right|\\
=&\Xi_1+\Xi_2,
\end{aligned}$$

由于 $|\hat{\boldsymbol{\beta}}_n^{(1)}-\boldsymbol{\beta}_0^{(1)}|=O_p(1/\sqrt{n})$ 且 $\tilde{\boldsymbol{\beta}}_n^{(1)}$ 位于 $\hat{\boldsymbol{\beta}}_n^{(1)}$ 和 $\boldsymbol{\beta}_0^{(1)}$ 之间, 因此 $\Xi_1\xrightarrow{p}0$, 另一方面由 (B.4), $\Xi_2\xrightarrow{\text{a.s.}}0$, 我们得到:

$$\left|\frac{1}{n}\sum_{i=1}^{n}\langle s_{Y_i-\boldsymbol{X}_i\hat{\boldsymbol{\beta}}_n^{(1)}I_{1i}}, s_{X_{ij}I_i}\rangle_K(\Psi_{is}-\bar{\Psi}_{ns})-\frac{1}{n}\sum_{i=1}^{n}E(\langle s_{Y_i-\boldsymbol{X}_i\boldsymbol{\beta}_0^{(1)}I_{1i}}, s_{X_{ij}I_{1i}}\rangle_K(\Psi_{is}-\bar{\Psi}_{ns}))\right|\xrightarrow{p}0. \tag{B.5}$$

由假设 1 可得:

$$E(\langle s_{Y_i-\boldsymbol{X}_i\boldsymbol{\beta}_0^{(1)}I_{1i}}, s_{X_{ij}I_{1i}}\rangle_K)=0.$$

因此可得 (B.5) 的第 2 项为 0, 继而得到 $|\partial D_n^s(\tilde{\boldsymbol{\beta}}_n^{(1)})/\partial\beta_j^{(1)}|\xrightarrow{\text{a.s.}}0$. 同理, 重复上述过程, 我们得到 $|\partial D_n^s(\tilde{\boldsymbol{\beta}}_n^{(2)})/\partial\beta_j^{(2)}|\xrightarrow{\text{a.s.}}0$. 由假设 2 和大数定律可得 $|\partial D_n^s(\tilde{\boldsymbol{\theta}}_n)/\partial\sigma^2|\xrightarrow{\text{a.s.}}0$. 进而结合公式 (B.3), 我们证明了 (B.2), 即:

$$|\sqrt{n}D_n^s(\hat{\boldsymbol{\theta}}_n)-\sqrt{n}D_n^s(\boldsymbol{\theta}_0)|\xrightarrow{p}0.$$

由于 $\bar{B}_n(\theta_0)^{-1/2}$ 是一致有界的, 因此我们有:

$$|\sqrt{n}\bar{B}_n(\boldsymbol{\theta}_0)^{-\frac{1}{2}}D_n^s(\hat{\boldsymbol{\theta}}_n)-\sqrt{n}\bar{B}_n(\boldsymbol{\theta}_0)^{-\frac{1}{2}}D_n^s(\boldsymbol{\theta}_0)|\xrightarrow{p}0.$$

定义

$$\begin{aligned}\hat{B}_n^{st} &= \frac{1}{n}\sum_{i=1}^{n}[\|Y_i - \boldsymbol{X}_i\hat{\boldsymbol{\beta}}_n^{(1)}I_{1i} - \boldsymbol{X}_i\hat{\boldsymbol{\beta}}_n^{(2)}I_{2i}\|_K^2 - \hat{\sigma}_n^2]^2(\Psi_{it} - \hat{\Psi}_{ns})(\Psi_{it} - \hat{\Psi}_{nt}) \\ &= \frac{1}{n}\sum_{i=1}^{n}[\|\hat{\varepsilon}_i\|_K^2 - \hat{\sigma}_n^2]^2(\Psi_{it} - \hat{\Psi}_{ns})(\Psi_{it} - \hat{\Psi}_{nt}),\end{aligned}$$

其中 $\hat{\Psi}_{ns} = n^{-1}\sum_{i=1}^{n}\Psi_{is}$, 将上式展开:

$$\begin{aligned}\hat{B}_n^{st} =& n^{-1}\sum_{i=1}^{n}[\|\hat{\varepsilon}_i\|_K^2 - \hat{\sigma}_n^2]^2(\Psi_{it} - \hat{\Psi}_{ns})(\Psi_{it} - \hat{\Psi}_{nt}) \\ =& n^{-1}\sum_{i=1}^{n}\|\hat{\varepsilon}_i\|_K^4\Psi_{is}\Psi_{it} - 2\hat{\sigma}_n^2 n^{-1}\sum_{i=1}^{n}\|\hat{\varepsilon}_i\|_K^2\Psi_{is}\Psi_{it} + \hat{\sigma}_n^4 n^{-1}\sum_{i=1}^{n}\Psi_{is}\Psi_{it} - \\ & \hat{\Psi}_{ns}n^{-1}\sum_{i=1}^{n}\|\hat{\varepsilon}_i\|_K^4\Psi_{it} + 2\hat{\sigma}_n^2\hat{\Psi_{ns}}n^{-1}\sum_{i=1}^{n}\|\hat{\varepsilon}_i\|_K^2\Psi_{it} - \hat{\sigma}_n^4\hat{\Psi}_{ns}n^{-1}\sum_{i=1}^{n}\Psi_{it} - \\ & \hat{\Psi}_{nt}n^{-1}\sum_{i=1}^{n}\|\hat{\varepsilon}_i\|_K^4\Psi_{is} + 2\hat{\sigma}_n^2\hat{\Psi}_{nt}n^{-1}\sum_{i=1}^{n}\|\hat{\varepsilon}_i\|_K^2\Psi_{is} - \hat{\sigma}_n^4\hat{\Psi}_{nt}n^{-1}\sum_{i=1}^{n}\Psi_{is} + \\ & \hat{\Psi}_{ns}\hat{\Psi}_{nt}n^{-1}\sum_{i=1}^{n}\|\hat{\varepsilon}_i\|_K^4 - 2\hat{\Psi}_{ns}\hat{\Psi}_{nt}n^{-1}\sum_{i=1}^{n}\|\hat{\varepsilon}_i\|_K^2 + \hat{\Psi}_{ns}\hat{\Psi}_{nt}\hat{\sigma}_n^4,\end{aligned}$$

在假设 1~4 和同方差假定下, 由大数定律, 易得 $|\hat{\Psi}_{ns} - \bar{\Psi}_{ns}| \xrightarrow{\text{a.s.}} 0$, $|\hat{\sigma}_n^4 - \sigma_0^4| \xrightarrow{p} 0$. 由区间门限回归模型参数估计的一致性, 即 $(\hat{\boldsymbol{\beta}}_n^{(1)}, \hat{\boldsymbol{\beta}}_n^{(2)}) \xrightarrow{p} (\boldsymbol{\beta}_0^{(1)}, \boldsymbol{\beta}_0^{(2)})$, 我们有 $\hat{\varepsilon}_i \xrightarrow{p} \varepsilon_i$, 其中 $\varepsilon_i = Y_i - \boldsymbol{X}_i\boldsymbol{\beta}_0^{(1)}I_{i1} - \boldsymbol{X}_i\boldsymbol{\beta}_0^{(2)}I_{i1}$. 当假设 1~6 成立时, $\bar{B}_n^{st}(\boldsymbol{\theta}_0)$ 中的期望是有界的, 因此我们有 $|\hat{B}_n^{st} - \bar{B}_n^{st}(\boldsymbol{\theta}_0)| \xrightarrow{p} 0$. 再由 (B.1), (B.2) 以及 White (1980b) 中的引理 3.3, 我们得到:

$$nD_n(\hat{\boldsymbol{\theta}}_n)'\hat{B}_nD_n(\hat{\boldsymbol{\theta}}_n) \sim \chi^2_{p(p+1)/2}. \tag{B.6}$$

推论 1 的证明: 由推论 1 的条件, 我们有:

$$\begin{aligned}\bar{B}_n^s(\boldsymbol{\theta}_0) &= \frac{1}{n}\sum_{i=1}^{n}E[(\|\varepsilon_i\|_K^2 - \sigma_0^2)(\Psi_{is} - \bar{\Psi}_{ns})(\Psi_{it} - \bar{\Psi}_{nt})] \\ &= (\mu_4 - \sigma_0^2)\cdot\frac{1}{n}\sum_{i=1}^{n}E[(\Psi_{is} - \bar{\Psi}_{ns})(\Psi_{it} - \bar{\Psi}_{nt})],\end{aligned}$$

其中 $\varepsilon_i = Y_i - \boldsymbol{X}_i\boldsymbol{\beta}_0^{(1)}I_{i1} - \boldsymbol{X}_i\boldsymbol{\beta}_0^{(2)}I_{i1}$ 是区间扰动项, $\sigma_0 = E(\|\varepsilon_i\|_K^2)$, $s, t = 1, \cdots, p(p+1)/2$. 注意到:

$$\begin{aligned}\frac{1}{n}\sum_{i=1}^{n}(\|\hat{\varepsilon}_i\|_K^2 - \hat{\sigma}_n^2)^2 =& \frac{1}{n}\sum_{i=1}^{n}(\|\hat{\varepsilon}_i\|_K^4 + \hat{\sigma}_n^4 - 2\|\hat{\varepsilon}_i\|_K^2\hat{\sigma}_n^2) \\ =& \frac{1}{n}\sum_{i=1}^{n}\|\hat{\varepsilon}_i\|_K^4 + \hat{\sigma}_n^4 - 2\hat{\sigma}_n^2\cdot\frac{1}{n}\sum_{i=1}^{n}\|\hat{\varepsilon}_i\|_K^2 \\ =& \frac{1}{n}\sum_{i=1}^{n}\|\hat{\varepsilon}_i\|_K^4 - \hat{\sigma}_n^4,\end{aligned}$$

其中 $\hat{\varepsilon}_i = Y_i - \boldsymbol{X}_i\hat{\boldsymbol{\beta}}_n^{(1)}I_{i1} - \boldsymbol{X}_i\hat{\boldsymbol{\beta}}_n^{(2)}I_{i2}$. 而在假设 2, 4 下, $n^{-1}\sum_{i=1}^n\|\hat{\varepsilon}_i\|_K^4$, $\hat{\sigma}_n^4$, $\hat{\Psi}_{ns}$ 和 $\hat{\Psi}_{nt}$ 分别是 μ_4, σ_0^2, $\bar{\Psi}_{ns}$ 和 $\bar{\Psi}_{nt}$ 的一致估计量, 因此可知 $\bar{B}_n^s(\theta_0)$ 的一致估计量具有形式:

$$\tilde{B}_n^{st} = \frac{1}{n}\sum_{i=1}^n(\|\hat{\varepsilon}_i\|^2 - \hat{\sigma}_n^2)^2 \cdot \frac{1}{n}\sum_{i=1}^n(\Psi_{is} - \hat{\Psi}_{ns})(\Psi_{it} - \hat{\Psi}_{nt}).$$

由定理 1 的证明可得:

$$nD_n(\hat{\boldsymbol{\beta}}_n, \hat{\sigma}_n^2)'\tilde{B}_n^{-1}D_n(\hat{\boldsymbol{\beta}}_n, \hat{\sigma}_n^2) \sim \chi_{p(p+1)/2}. \tag{B.7}$$

其中 $\tilde{B}_n$ 是以 $\tilde{B}_n^{st}$ 为元素构成的矩阵. 继而, 将 D_n 和 $\tilde{B_n}$ 的表达式代入上式左边, 我们有

$$\begin{aligned}
&nD_n(\hat{\boldsymbol{\beta}}_n, \hat{\sigma}_n^2)'\tilde{B}_n^{-1}D_n(\hat{\boldsymbol{\beta}}_n, \hat{\sigma}_n^2)\\
=&n\left(\frac{1}{n}\sum_{i=1}^n\Psi_i'(\|\hat{\varepsilon}_i\|_K^2 - \hat{\sigma}_n^2)\right)'\left(\frac{1}{n}\sum_{i=1}^n(\Psi_i - \hat{\Psi}_n)'(\Psi_i - \hat{\Psi}_n)\right)^{-1}\\
&\cdot\left(\frac{1}{n}\sum_{i=1}^n\Psi_i'(\|\hat{\varepsilon}_i\|_K^2 - \hat{\sigma}_n^2)\right)\Bigg/\left(\frac{1}{n}(\|\hat{\varepsilon}_i\|_K^2 - \hat{\sigma}_n^2)^2\right).
\end{aligned} \tag{B.8}$$

另一方面, 辅助回归 (5) 非截距项的估计系数 $\hat{\boldsymbol{\alpha}}_n$ 由 OLS 估计可得:

$$\hat{\boldsymbol{\alpha}}_n = \left(\frac{1}{n}\sum_{i=1}^n(\Psi_i - \hat{\Psi}_n)'(\Psi_i - \hat{\Psi}_n)\right)^{-1}\left(\frac{1}{n}\sum_{i=1}^n(\Psi_i - \hat{\Psi}_n)'(\|\hat{\varepsilon}_i\|_K^2 - \hat{\sigma}_n^2)\right).$$

注意到:

$$\frac{1}{n}\sum_{i=1}^n\hat{\Psi}_n(\|\hat{\varepsilon}_i\|_K^2 - \hat{\sigma}_n^2) = \hat{\Psi}_n\left(\frac{1}{n}\sum_{i=1}^n\|\hat{\varepsilon}_i\|_K^2 - \hat{\sigma}_n^2\right) = 0.$$

因此

$$\frac{1}{n}\sum_{i=1}^n\Psi'(\|\hat{\varepsilon}_i\|_K^2 - \hat{\sigma}_n^2) = \frac{1}{n}\sum_{i=1}^n(\Psi' - \hat{\Psi}_n)(\|\hat{\varepsilon}_i\|_K^2 - \hat{\sigma}_n^2).$$

将上式代入 (B.8) 式, 可得:

$$\begin{aligned}
&nD_n(\hat{\boldsymbol{\beta}}_n, \hat{\sigma}_n^2)'\tilde{B}_n^{-1}D_n(\hat{\boldsymbol{\beta}}_n, \hat{\sigma}_n^2)\\
=&n\hat{\boldsymbol{\alpha}}_n'\left(\frac{1}{n}\sum_{i=1}^n(\Psi_i - \hat{\Psi}_n)'(\Psi_i - \hat{\Psi}_n)\right)\hat{\boldsymbol{\alpha}}_n\Bigg/\left(\frac{1}{n}(\|\hat{\varepsilon}_i\|_K^2 - \hat{\sigma}_n^2)^2\right)\\
=&n\left(\frac{1}{n}\sum_{i=1}^n(\Psi_i\hat{\boldsymbol{\alpha}}_n - \hat{\Psi}_n\hat{\boldsymbol{\alpha}}_n)'(\Psi_i\hat{\boldsymbol{\alpha}}_n - \hat{\Psi}_n\hat{\boldsymbol{\alpha}}_n)\right)\Bigg/\left(\frac{1}{n}(\|\hat{\varepsilon}_i\|_K^2 - \hat{\sigma}_n^2)^2\right).
\end{aligned} \tag{B.9}$$

注意到 $\hat{\Psi}_n = n^{-1}\sum_{i=1}^n\Psi_i$, 且最小 D_K 距离回归过均值点, 可知 (B.9) 式最后一项的分子, 分母分别为回归平方和, 总离差平方和, 即 (B.9) $= nR^2$, 因此我们得到推论 1 的结论:

$$nD_n(\hat{\boldsymbol{\beta}}_n, \hat{\sigma}_n^2)'\tilde{B}_n^{-1}D_n(\hat{\boldsymbol{\beta}}_n, \hat{\sigma}_n^2) = nR^2 \sim \chi^2_{p(p+1)/2}. \tag{B.10}$$