DOI:10.16644/j.cnki.cn33-1094/tp.2025.07.006

基于Transformer的电力现货市场多步时序价格预测方法*

张　颖[1]，韩硕辰[1]，周辛南[1]，李辰曦[2]

（1. 国网冀北电力有限公司计量中心，北京 100032；2. 北京华电能源互联网研究院有限公司）

摘　要：精确预测电力现货市场价格对于指导发电和用电资源有效应对市场波动具有重要意义。随着人工智能和机器学习的迅速发展，当前电力价格预测研究已经能够达到高效且精确的水平。Long Short-Term Memory（LSTM）及其衍生模型作为该领域的代表性方法，已经取得了一定的成果，但其预测准确度仍有提升空间。因此，本文提出了一种基于Transformer架构的新型出清价格预测模型，该模型首先利用皮尔逊相关系数筛选出影响因素，然后利用Transformer进行高效的输入编码，并通过模型改进更好地捕捉长序列特征。通过对蒙西电力现货市场的历史数据进行分析，将多步时序实时市场出清价格的预测值与现有的LSTM和BiLSTM模型的预测结果进行比较，结果表明该方法在预测精准度和普适性方面具有优势。

关键词：皮尔逊相关系数；Transformer；电力现货市场；多步时序；实时市场；出清价格预测

中图分类号：TM73；F426　　**文献标识码：**A　　**文章编号：**1006-8228(2025)07-26-06

Transformer-Based Multi-step Time Series Price Prediction Method in the Electricity Spot Market

Zhang Ying[1], Han Shuochen[1], Zhou Xinnan[1], Li Chenxi[2]

(1. State Grid Jibei Electric Power Co., Ltd. Metorlogy Center, Beijing 100032, China; 2. Beijing Huadian Energy Internet Research Institute Co., Ltd.)

Abstract: Accurate forecasting of electricity spot market prices is of great significance for guiding the effective response of power generation and consumption resources to market fluctuations. With the rapid development of artificial intelligence and machine learning technologies, current research can conduct efficient and accurate electricity price predictions. Long Short-Term Memory (LSTM) and its derived models have achieved certain results as representative methods in this field, but there is still room for improvement in terms of prediction accuracy. Therefore, a new clearing price prediction model based on the Transformer architecture is proposed. This model first uses the Pearson correlation coefficient to select influencing factors, then uses the Transformer for efficient input encoding, and through model improvement, it can better capture the characteristics of long sequences. Through an in-depth analysis of the real-time market historical data of the Mengxi power spot market, and by comparing the predicted values of multi-step time series real-time market clearing prices with the prediction results of existing LSTM and BiLSTM models, the results show that this method has advantages in terms of prediction accuracy and universality.

Keywords: Pearson Correlation Coefficient; Transformer; Electricity Spot Market; Multi-step Time Series; Real-time Markets; Clearing Price Forecasting

0 引言

在当今的电力现货市场中，随着机器学习技术的不断发展，电力出清价格预测尤其是长周期预测成为了关注的焦点，而机器学习算法的兴起，为电力出清价格预测研究开辟了全新的思路。

基于此，神经网络方法被引入以应对这些挑战，尽管长短期记忆循环神经网络LSTM[1]、门控循环单元GRU[2]等变体相继出现，但这两种时间序列预测方法面临着诸多挑战。首要挑战在于序列长度较长以及存在并行问题，同时存在梯度消失和梯度爆炸问题。

收稿日期：2025-06-18

***基金项目：**国家电网有限公司科技项目资助（合同号：520185230006）

作者简介：张颖（1990—），女，河北廊坊人，硕士，工程师；主要研究方向：电力营销。

通讯作者：李辰曦（2000—），女，山西长治人，硕士，主要研究方向：电力市场，电价预测。

这些问题使得LSTM和GRU的训练面临较大困难，进而限制了它们的性能[3-5]。卷积神经网络（Convolutional Neural Networks，CNN）擅长特征提取，在时序预测任务中具有应用潜力[6]，但仅靠其解决任务仍然不充分，通常被用作一个功能模块，通过卷积操作提取局部特征提升模型预测性能。多层感知机（Multi-Layer Perceptron，MLP）可利用多个隐藏层学习时序数据复杂非线性关系及潜在规律[7]，但建模能力有限，难以分析复杂时间模式。

近年来，Transformer凭借自注意力机制，能够捕获序列中的长距离依赖关系，具备更强的时序建模能力，因而在处理时间序列数据时具有明显优势[8]。正因如此，基于Transformer的研究日益受到关注。文献[9]分析了Transformer模型在不同输入序列长度下的预测性能。文献[10]提出基于Transformer的股票价格预测模型，该模型利用因果自注意力机制挖掘股票价格与特征因子的时序关系，采用趋势增强模块捕捉一系列趋势指标，并利用特定编码器的输入提供先验信息。文献[11]在单变量电力负载预测任务中，对Transformer模型架构予以优化，通过将原模型中的解码器结构替换为中间聚合层和前馈层的组合，优化了Transformer 模型的结构，从而降低了模型的复杂性，使其更适合电力负荷预测任务。

通过上述研究可知，Transformer模型在价格预测以及电力领域均有着明显的研究成效。但是，将该模型应用于电力出清价格预测的情形却较为少见。鉴于此，本文提出一种基于Transformer的电力现货市场多步时序价格预测方法。

1 方法介绍

1.1 皮尔逊相关系数

皮尔逊相关系数在分析多因素交互影响的复杂数据时，具有较高的可靠性。因此，本文在电力现货市场出清价格长周期预测中，帮助剔除相关性低于0.2的弱影响因素，同时筛选出相关性高于0.8并且与电价高度相关的重要因素，提高模型性能和预测效果。在皮尔逊相关性分析里，针对两个变量的多组数据，记为$(x_i,y_i)(i = 1,2,\cdots,n)$，其数学表达式如式(1)所示：

$$r = \frac{\sum_{i=1}^{n}\left(x_i - \bar{x}\right)\left(y_i - \bar{y}\right)}{\sqrt{\sum_{i=1}^{n}\left(x_i - \bar{x}\right)^2}\sqrt{\sum_{i=1}^{n}\left(y_i - \bar{y}\right)^2}} \tag{1}$$

其中，$\bar{x},\bar{y}$分别为n个试验值的均值。

1.2 Transformer

如图1所示，Transformer是一种神经网络架构，基于自注意力机制构建，可对序列中不同位置的全局依赖关系进行捕捉。在电力现货市场出清价格预测问题的处理上，Transformer能够对输入的电力市场相关数据进行全局特征提取，进而捕捉到不同时间点与不同因素之间的隐含关系及复杂规律。

1.2.1 位置编码

Transformer架构本身无法捕捉序列的顺序信息，因此需要位置编码来为模型提供相对或绝对位置信息，帮助模型准确理解时间序列数据中的顺序关系。Transformer采用正弦和余弦函数的组合方式对序列进行位置编码。计算方式如式(2)和式(3)所示：

$$PE_{(\mathrm{pos},2i)} = \sin\left(\mathrm{pos}/10000^{2i/d_{\mathrm{model}}}\right) \tag{2}$$

$$PE_{(\mathrm{pos},2i+1)} = \cos\left(\mathrm{pos}/10000^{2i/d_{\mathrm{model}}}\right) \tag{3}$$

其中，pos为当前序列的位置；i为维度；d_{model}为输入特征的维度。

1.2.2 多头自注意力机制

Transformer中的核心技术是多头注意力机制。该机制可用于提取数据间的依赖关系特征，能够捕获数据之间的相关关系，进而建立上下文预测模型。这对于电力市场数据中不同特征的重要性评估非常有帮助，能够自动学习到对出清价格影响强的因素。计算公式如式(4)至式(9)所示：

$$\boldsymbol{Q} = \boldsymbol{W}_1 \times X \tag{4}$$

$$\boldsymbol{K} = \boldsymbol{W}_2 \times X \tag{5}$$

$$\boldsymbol{V} = \boldsymbol{W}_3 \times X \tag{6}$$

$$\mathrm{Attention}(Q,K,V) = \mathrm{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \tag{7}$$

$$\mathrm{MultiHead}(Q,K,V) = \mathrm{Concat}(\mathrm{head}_1,\ldots,\mathrm{head}_k)W^0 \tag{8}$$

$$\mathrm{head}_i = \mathrm{Attention}(QW_i^Q,KW_i^K,VW_i^V) \tag{9}$$

其中，$\boldsymbol{Q}$为查询矩阵；$\boldsymbol{K}$为键矩阵，$\boldsymbol{V}$为值矩阵，$\boldsymbol{W}_1,\boldsymbol{W}_2,\boldsymbol{W}_3$为可训练的参数矩阵，$X$为经过处理后的输入，$d_k$为键矩阵的维度，$\boldsymbol{W}^0,\boldsymbol{W}_i^Q,\boldsymbol{W}_i^K,\boldsymbol{W}_i^V$为可学习的参数矩阵。

1.2.3 前馈网络、求和与归一化

前馈网络通过特征提取与转换，增强模型表达能力并加速训练收敛，而求和与归一化操作通过残差连接确保信息有效流动，避免梯度消失，层归一化稳定训练过程，两者共同提升模型性能、训练效率和泛化能力。

前馈神经网络的计算公式如式(10)所示。其中，x

为输入，W_1,W_2,b_1,b_2为可通过训练得到的参数。

$$\mathrm{FFN(Feed\ Forward\ Network)}(x)=\max(0,xW_1+b_1)W_2+b_2 \quad (10)$$

求和与归一化的计算公式如式(11)所示。其中，x为输入，Sublayer表示在神经网络的一个子层，LayerNorm是对数据进行归一化处理的方法。

$$x = \mathrm{LayerNorm}(x + \mathrm{Sublayer}(x)) \quad (11)$$

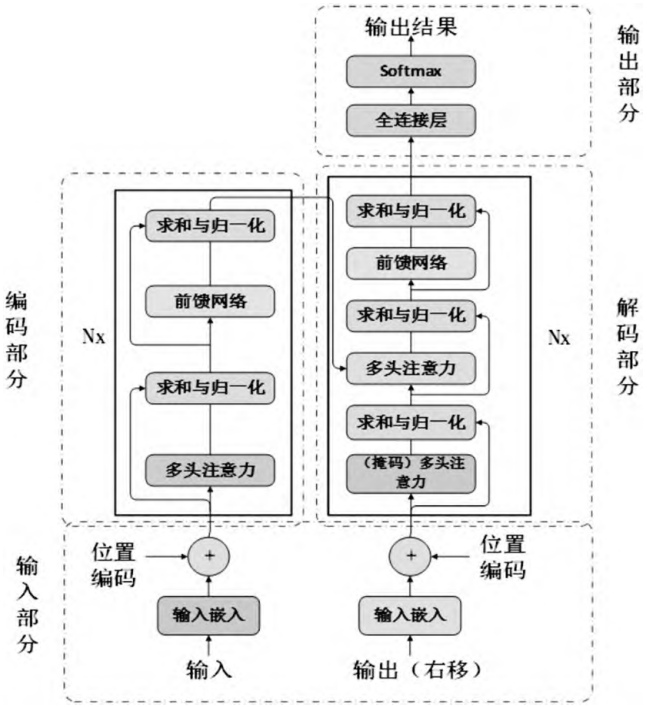

图1　Transformer结构图

2 模型介绍

2.1 Transformer电力出清价格预测任务

电力出清价格预测的目标是使用过去n个时刻的电价序列、历史负荷、风速、最低气温数据，通过函数f对未来时刻的电价进行预测，可表示如式(12)所示：

$$P_f=f(P_1,P_2,\cdots,P_n,L_1,L_2,\cdots,L_n,W_1,W_2,\cdots,W_n,T_1,T_2,\cdots,T_n) \quad (12)$$

其中，$P_1,P_2,\cdots,P_n$代表过去n个时刻的电价序列，$L_1,L_2,\cdots,L_n$代表过去n个时刻的负荷数据，$W_1,W_2,...,W_n$代表过去n个时刻的风速数据，$T_1,T_2,...,T_n$代表过去n个时刻的最低气温数据，P_f是目标时刻的电力出清价格预测值。

2.2 改进Transformer

在预测电价的过程中，需要通过模型实现三个主要功能：历史序列的特征提取、序列间的非线性依赖关系，以及历史负荷数据的整合。Transformer中的Self-Attention与Feed Forward结构可以有效实现前两个功能目标，而对历史负荷、风速、最低气温数据的整合需要额外设计。

2.2.1 输入端改进

电价、负荷、最低气温、风速数据原本就是以数字形式存在，因此可以直接采用求和与归一化处理，归一化公式如式(13)所示：

$$\mathrm{LayerNorm}(x) = \frac{x-\mu}{\alpha} \times \gamma + \beta \quad (13)$$

其中，x为要归一化的数据；α是x在对应维度上的标准差；γ是可学习的参数，用于对归一化后的数据进行缩放。μ是x在对应维度上的均值；β是可学习的参数，用于对归一化后的数据进行平移。

2.2.2 输出端改进

在原始的Transformer中，输出层通常使用Linear加Softmax函数。在电力出清价格预测任务中，由于输出和预测电价之间为数字转数字，因此可以简化为使用一个稳定的DRN（深度残差神经网络）结构，其神经元的激活函数使用LeakyReLU函数，如式(14)所示。其中，x为神经元的输入，a为缩放倍率。

$$h(x) = \begin{cases} x & if\ x \geqslant 0 \\ ax & if\ x < 0 \end{cases} \quad (14)$$

2.3 模型学习过程

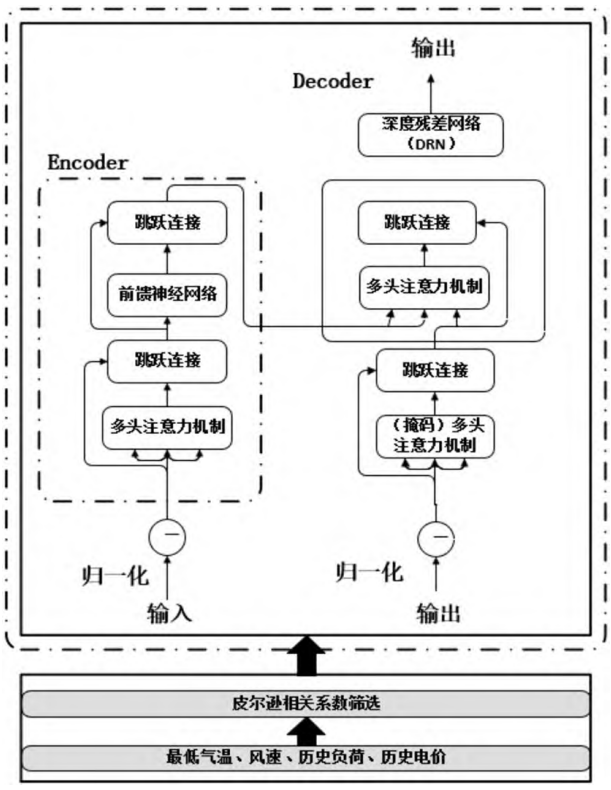

图2　模型框架图

如图2所示，在预测电价任务中，历史电价数据和

历史负荷数据会被分成全序列和按不同时间生成的多个分序列。全序列会被输入到模型的Encoder中，之后经过多次的Multi-Head Attention（多头注意力机制）、Skip Connection（跳跃连接）和Feed Forward操作，最终得到一个高维矩阵，该矩阵保留了输入序列的全局信息。然后，不同时间产生的多个分序列，会在不同时间依次进入Decoder中，并在Decoder的Encoder-Decoder Attention中根据全局特征进行关注度计算以提取时点特征，然后通过DRN将特征信息转化为预测电价。

3 算例分析

3.1 数据集构建

本文基于蒙西2023年1月—6月每日96个点实时出清价格数据，进行了模型训练和预测。实验模型是在Python 3.11环境下构建的，其中，90%的样本被分配为训练集，用于调整模型的权重和偏差；在这90%的数据里，再划分出10%作为验证集，用于超参数调优和防止过拟合；剩下的10%的样本则作为测试集，用于评估模型的最终性能，Transformer、BiLSTM、LSTM模型参数见表1。

表1 模型参数

超参数	数值
迭代次数（Epochs）	50
模型维度（D_model）	32
输入时间序列长度（Input len）	96
输出时间序列长度（Output len）	48
学习率（Learning Rate）	0.001
批次大小（Batch Size）	32

3.2 影响因素选择

如表2所示，最低气温与实时均价的相关系数为0.251，表示两者之间存在较弱的正相关关系，即最低气温上升时，实时均价也略有上升；风速与实时均价的相关系数为0.369，表示两者之间存在中等程度的正相关关系，即风速上升时，实时均价也倾向于上升；历史负荷、历史价格与实时均价的相关系数为0.836和0.886（标有**表示统计显著），表示两者之间存在非常强的正相关关系，即历史负荷和历史价格上升时，实时均价也显著上升。综上所述，历史负荷和历史电价不仅是影响实时均价的两个关键因素，而且它们与实时均价之间的强相关性为电力市场的分析和预测提供了坚实的数据支持。

表2 电价影响因素相关性分析

	最低气温	风速	历史负荷	历史价格	实时均价
最低气温	1				
风速	.157**	1			
历史负荷	.381**	.359**	1		
历史价格	.278**	.350**	.794**	1	
实时均价	.251*	.369**	.836**	.886**	1

注：**表示$p < 0.01$，相关性显著；*表示$p < 0.05$，相关性显著。

3.3 输入端归一化结果

如表3所示，历史电价的权重最高为0.41，说明其对电价的影响最为显著。历史负荷次之，权重为0.32，表明负荷的变化也对电价有着重要的影响。风速和最低气温的权重为0.15和0.12较为接近，虽然低于历史电价和历史负荷，但仍是不可忽视的因素。

表3 求和与归一化权重

影响因素	权重
历史电价	0.41
历史负荷	0.32
风速	0.15
最低气温	0.12

3.4 评价指标

评估指标包括均方根误差（RMSE）、平均绝对误差（mean absolute error，MAE）、决定系数（R-Square，R^2）。均方根误差（RMSE）和平均绝对误差（MAE）分别用于衡量预测值与实际值之间的平方误差和绝对误差的平均程度，反映预测误差的平均水平。决定系数（R^2）则体现模型对实际值变异的解释程度。计算公式如(15)至(17)所示：

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}\left(y_i - \hat{y}_i\right)^2} \tag{15}$$

$$\mathrm{MAE} = \frac{1}{n}\left|y_i - \hat{y}_i\right| \tag{16}$$

$$R^2 = 1 - \frac{\sum_{i=1}^{n}\left(y_i - \hat{y}_i\right)^2}{\sum_{i=1}^{n}\left(y_i - \bar{y}\right)^2} \tag{17}$$

其中，n为数据集大小，y_i为真实值，$\hat{y}_i$为预测值，$\bar{y}$为均值。

3.5 预测性能分析

3.5.1 模型拟合情况及误差表现

从图3中可以看出，大多数数据点都集中在拟合直线的周围，这表明模型的预测值与真实值之间呈现出显著的正相关性。数据点分布较为集中，意味着模型在多数情况下可以实现较为精确的预测。如图4所示，随着训练的推进，Transformer模型的训练误差与

验证误差呈现出逐步降低的态势，这反映出该模型在训练过程中具备强大的学习能力。误差的持续下降表明模型能够高效地掌握数据中蕴含的复杂规律，并且在不断提升其预测的精准度。

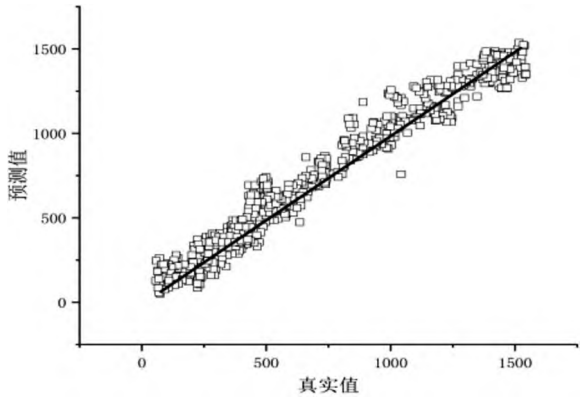

图3　真实值与预测值散点拟合图

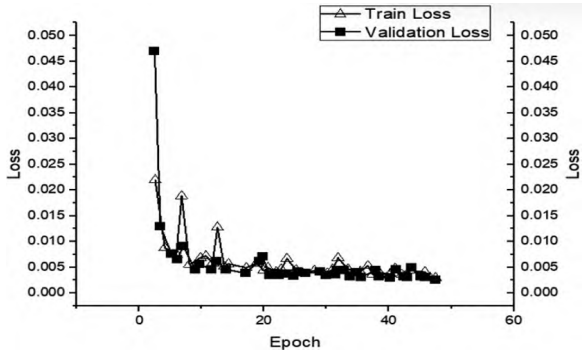

图4　Transformer训练集与验证集的误差图

3.5.2 模型效能对比

为了验证Transformer模型的有效性和预测精度，本文的算例将最后10%预测出的结果与LSTM模型、BiLSTM模型进行比较，从而验证预测精度。如表4所示，在RMSE、MAE和R^2方面，Transformer模型均有明显提升。对于R^2的表现，R^2接近1意味着模型能够解释因变量的大部分方差，这表明模型具有较高的预测精度和解释能力。

表4　评价指标对比

评价指标	MAE	RMSE	R^2
Transformer	35.54	56.73	0.98
BiLSTM	41.38	72.48	0.87
LSTM	45.59	87.02	0.83

3.6 模型日度表现

如表5所示，本文选取预测结果的同一天的2:00—4:00时段的预测结果进行比较。虽然Transformer预测值与实际值之间存在一定差异，但这种差异相对较为稳定。在不同的时点，其他模型的预测值与实际值的差异可能会随着时间的变化而大幅波动，这给实际应用带来了很大的不确定性。而Transformer模型的稳定差异使得我们可以更好地把握其预测特点，从而有利于市场主体进行更有针对性的调整和优化。

表5　不同模型日度数据对比

时点	实际值	Transformer预测值	BiLSTM预测值	LSTM预测值
2:00	304.48	292.49	317.61	326.57
2:15	303.75	294.49	320.82	333.44
2:30	303.58	296.49	320.78	324.58
2:45	305.42	300.49	321.31	334.35
3:00	323.16	327.32	349.69	372.32
3:15	322.05	324.12	355.08	362.28
3:30	325.73	326.62	344.01	355.26
3:45	321.48	322.84	351.87	361.41

3.7 模型预测结果对比

从图5、图6、图7中可以清晰地看出，在众多模型的表现中，Transformer模型预测展现出了显著的优势，相比BiLSTM模型和LSTM模型而言，其表现出更好的预测效果。在实际情况中，无论是在数据波动较为平缓的阶段，还是在面临复杂多变的情况时，Transformer模型都能够较为稳定地输出预测结果。即使在尖峰和低谷这种具有挑战性的时期，仍保持较高的准确率。

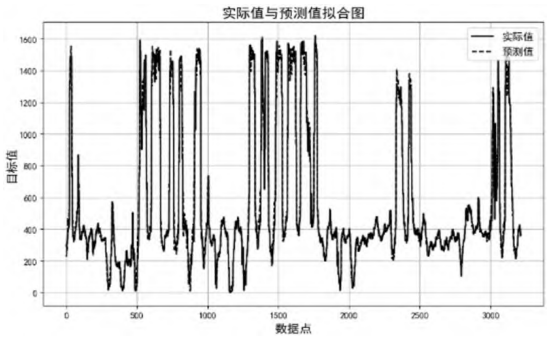

图5　Transformer预测结果图

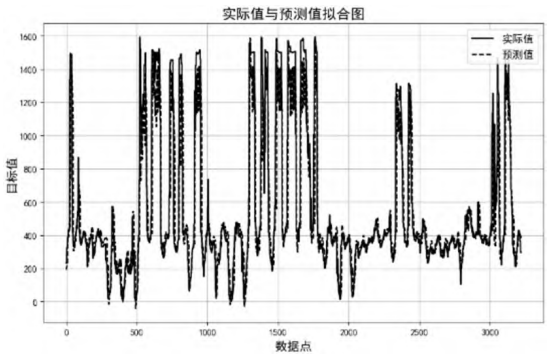

图6　BiLSTM预测结果图

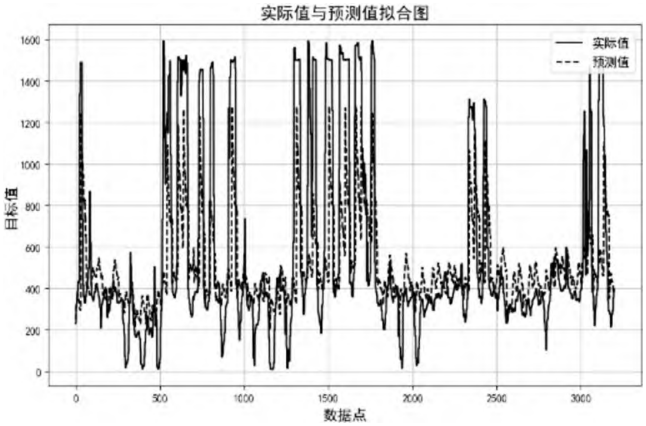

图7 LSTM预测结果图

正因如此，Transformer模型的预测结果有助于市场主体优化交易决策。从购电商角度，可根据预测结果提前规划购电计划，在电价低谷时增加购电，以满足高峰时段需求，降低购电成本；从售电商角度，依据预测结果合理安排发电计划，增加电价高峰时段的发电出力进行售电，提升收益，并对检修计划作出相应调整，避免在电价高峰时段停机。此外，新能源企业可依据电力出清价格预测合理安排发电计划，与常规能源优化组合，在电价高峰时段保障发电供应，并决定是否参与辅助服务市场以增加收益。

3.8 误差直方分布图

图8(a)、图8(b)、图8(c)分别表示Transformer、BiLSTM、LSTM模型的误差直方分布图。其中，Transformer模型的误差分布集中且对称，大多数误差值接近平均值，表明其在该数据集上的预测准确且稳定。相比之下，BiLSTM模型和LSTM模型的误差分布较为分散，虽然在平均值附近有明显峰值，但也存在较大误差值，暗示其预测存在波动，可能受到异常值影响或在某些情况下预测不够准确。

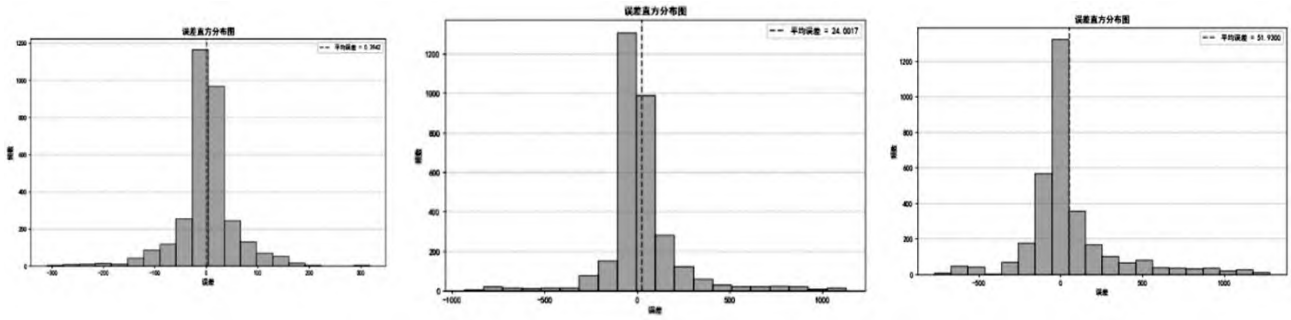

(a) Transformer误差分布直方图　(b) BiLSTM误差分布直方图　(c) LSTM误差分布直方图

图8 不同模型误差直方分布图

4 结论

在电力出清价格预测领域，传统的Transformer模型并非专为时序预测任务设计，因此它没有对时间模式和特征做出预设假设[10]，从而导致在尖峰或低谷时期会有一定误差。为了适应电力出清价格预测的需求，本文采用皮尔逊相关系数进行影响因素筛选，并对Transformer模型输入输出端进行改进，运用了Transformer捕捉多特征的功能，构建了捕捉长期依赖关系的通用网络，提高了模型的泛化能力，避免了过拟合现象，从而提升了预测的准确性。然而，电价波动幅度较大，并且容易受到政策等难以量化的因素影响。基于此，在未来的电力出清价格预测工作中，可先对政策等相关因素进行量化处理，量化后，可考虑将Transformer与其他神经网络方法组合开展电力出清价格预测，从而进一步提高电力出清价格预测的精准度。

参考文献(References):

[1] 相广俐，李林．基于主成分分析的LSTM神经网络聚乙烯价格预测研究[J]．计算机时代，2023(3):67-70，75.

[2] 张新宇．基于GRU神经网络的短期电价预测模型研究[D]．沈阳：沈阳工业大学，2024.

[3] 王彩玲，丁当．堆叠式LSTM组合模型的充电站用电量预测方法[J]．计算机时代，2025(1):1-4.

[4] HOCHREITER S, SCHMIDHUBER J. Long Short-Term Memory[J]. Neural Computation, 1997, 9(8):1735-1780.

[5] 邵云姝，张琳，周乃康，等．基于长短期记忆网络的电力市场价格预测研究[J]．动力工程学报，2025，45(5):733-737.

[6] 陆徐丹，沈宏晔．基于改进型CNN-LSTM神经网络的光伏功率预测[J]．计算机时代，2025(2):16-20.

[7] 李文源．基于深度学习的电力市场电价预测研究[D]．青岛：山东科技大学，2020.

（下转第37页）

能力。同时，MSCA模块通过在频域中自适应地调整通道权重，使得模型能够更专注于火灾目标的细微特征。

4 结论

针对传统森林火灾检测方法存在的响应速度慢、难以准确检测微小火灾等问题，本文提出了一种基于频域特征的轻量级森林火灾检测算法。通过引入ConvNeXtV2模块，有效降低了模型的参数量和计算量，提升了模型的推理速度；同时，利用MSCA模块提取特征图的不同频率信息，增强了模型对微小火灾目标的感知能力。通过消融实验和对比实验，充分验证了YOLOv8-CM模型在森林火灾检测任务上的优越性能。该模型为实现森林火灾的早期预警和快速响应提供了可靠的技术支持。

参考文献(References):

[1] TALUKDAR N R, AHMAD F, GOPARAJU L, et al. Forest Fire Estimation and Risk Prediction Using Multispectral Satellite Images: Case Study[J]. Natural Hazards Research,2024,4(2):304-319.

[2] THAI H D, YOON C W, HUH J H. Recent Development of Drone Technology Software Engineering: A Systematic Survey[J]. IEEE Access,2024,12:128729-128751.

[3] IMTEAJ A, THAKKER U, WANG S, et al. A Survey on Federated Learning for Resource-Constrained IoT Devices[J]. IEEE Internet of Things Journal, 2021, 9(1): 1-24.

[4] ZHANG J, MENG Y, YU X, et al. Mbab-Yolo: A Modified Lightweight Architecture for Real-Time Small Target Detection[J]. IEEE Access,2023,11:78384-78401.

[5] CAO L, SHEN Z, XU S. Efficient Forest Fire Detection Based on An Improved Yolo Model[J]. Visual Intelligence,2024,2(1):20.

[6] YAR H, KHAN Z A, RIDA I, et al. An Efficient Deep Learning Architecture for Effective Fire Detection in Smart Surveillance[J]. Image and Vision Computing, 2024,145:104989.

[7] YANG Z, SHAO Y, WEI Y, et al. Precision-Boosted Forest Fire Target Detection Via Enhanced Yolov8 Model[J]. Applied Sciences,2024,14(6):2413.

[8] REN D, ZHANG Y, WANG L, et al. FCLGYOLO: Feature Constraint and Local Guided Global Feature for Fire Detection in Unmanned Aerial Vehicle Imagery[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2024, 17: 5864-5875.

[9] HAO X, LUO S, CHEN M, et al. Infrared Small Target Detection with Super-Resolution and Yolo[J]. Optics & Laser Technology,2024,177:111221.

[10] LI B, XU F, LI X, et al. Early Stage Fire Detection System Based on Shallow Guide Deep Network[J]. Fire Technology,2024,60:1803-1821.

[11] JIN L, YU Y, ZHOU J, et al. SWVR: A Lightweight Deep Learning Algorithm for Forest Fire Detection and Recognition[J].Forests,2024,15(1):204.

[12] YUN B, ZHENG Y, LIN Z, et al. FFYOLO: A Lightweight Forest Fire Detection Model Based on Yolov8[J].Fire,2024,7(3):93.

[13] WANG G, LI H, YE S, et al. RFWNet: A Multi-Scale Remote Sensing Forest Wildfire Detection Network with Digital Twinning, Adaptive Spatial Aggregation, And Dynamic Sparse Features[J]. IEEE Transactions on Geoscience and Remote Sensing,2024,62:1-23.

[14] WOO S, DEBNATH S, HU R, et al. ConvNeXt V2: Co-Designing and Scaling Convnets with Masked Autoencoders[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition,2023:16133-16142.

[15] QIN Z, ZHANG P, WU F, et al. FCANet: Frequency Channel Attention Networks[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision,2021:783-792.

（上接第31页）

[8] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems,2017:5998-6008.

[9] 孙一平. 基于Transformer的侵炎肽预测[J]. 计算机时代, 2025(4):11-14,19.

[10] 任佳纯,王爱银. 融合因果注意力Transformer模型的股价预测研究[J]. 计算机工程与应用,2023,59(13):325-334.

[11] 沈尚义,沈煜宾,冯立. 基于Transformer的400V分压供电量预测优化研究[C]//浙江省电力学会2023年度优秀论文集. 湖州:国网浙江省电力有限公司湖州供电公司,2024.