中国管理科学
Chinese Journal of Management Science
ISSN 1003-207X,CN 11-2835/G3

《中国管理科学》网络首发论文

题目：　基于 KANsLTformer 的黄金期货价格预测研究
作者：　江雨燕，黄体臣，甘如美江，王付宇
DOI：　10.16381/j.cnki.issn1003-207x.2024.1868
网络首发日期：　2025-08-20
引用格式：　江雨燕，黄体臣，甘如美江，王付宇．基于 KANsLTformer 的黄金期货价格预测研究[J/OL]．中国管理科学.
https://doi.org/10.16381/j.cnki.issn1003-207x.2024.1868

网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

网络首发时间：2025-08-20 16:28:17　网络首发地址：https://link.cnki.net/urlid/11.2835.G3.20250820.1606.001

DOI：10.16381/j.cnki.issn1003-207x.2024.1868

基于 KANsLTformer 的黄金期货价格预测研究

江雨燕[1,2]，黄体臣[1,2]，甘如美江[2,3]，王付宇[1,2]

（1.安徽工业大学管理科学与工程学院，安徽 马鞍山 243032; 2. 复杂系统多学科管理与控制安徽普通高校重点实验室，安徽 马鞍山 243002; 3. 安徽工业大学电气与信息工程学院，安徽 马鞍山 243032）

摘要：黄金作为兼具商品、金属与货币多重属性的金融资产，其价格波动对全球经济与金融活动影响深远。黄金期货价格时间序列呈现非线性非平稳特性，高效特征提取是提高预测精度的关键挑战。本研究提出了一种改进的卷积门控单元模块 TCGLU，用于增强复杂时间序列特征提取能力。在此基础上，通过优化 Transformer 并融合 TCGLU 以捕获多尺度特征和处理复杂时间依赖结构，同时结合 KAN 网络的特征表达能力与 LSTM 捕捉长期依赖的优势，构建了基于 Transformer 的创新预测模型 KANsLTformer。横纵向对比实验结果表明，所提出的 KANsLTformer 模型在 MAE、SMAPE、RMSE、MedAE 和 DA 等评估指标上均优于现有模型，尤其在市场剧烈波动期间展现出更强的稳健性与泛化能力，为黄金期货价格预测提供了一种新的技术路径与决策参考。

关键词：黄金期货价格预测；Transformer；KAN 网络；长短期记忆网络；时间卷积门控单元

1 引言

黄金被广泛认为是最古老与重要的贵金属之一，它常被用作价值储藏、避险资产以及衍生工具和风险分散证券[1]。其中，黄金期货凭借其交易服务持续时间长、资金结算持续时间短、可有效抵御通胀和货币贬值风险等诸多优势，在国际金融秩序遭受冲击和金融市场剧烈动荡的时期内仍可保持其战略投资价值，被公认为一种重要的风险对冲工具[2]。然而，因其独具的对冲风险功能，在危机时期受到投资者的青睐，常因大量买入黄金避险以致其价格在市场动荡时期显著走高[3]。因此，黄金期货价格的未来走势受到广泛关注，提供准确且可靠的黄金期货价格预测方法能够挖掘黄金期货投资潜力、实现资产配置优化以及确保稳健收益的关键和基础。

针对黄金期货价格的预测研究，已有研究主要集中于变量分析、计量经济与机器学习等方法。变量分析多以宏观经济指标为基础，如 Christian 等[4]基于大量宏观与金融变量构建黄金期货波动的实时预测模型，实证表明宏观经济因素对美国黄金期货市场的长期波动具有显著影响。然而，部分变量存在非平稳性与不确定性，传统线性模型难以有效刻画其复杂关系，影响预测精度。

计量经济方法通过构建反映经济理论的数学模型，从而揭示黄金价格与相关变量的统计关系。Mishra 等[5]采用户田–山本模型进行格兰杰因果检验，发现印度金价与 BSE 30 指数之间存在双向因果关系，表明两者均包含对方未来走势的重要信息。考虑到跳跃分量可能有助于预测中国黄金期货市场波动性，Li 等[6]通过使用考虑异质自回归实现波动率(HAR-RV)对中国黄金期货市场波动率进行预测，试验结果表明 HAR-RV 可有效预测黄金期货价格波动率。鉴于 HAR-RV 是混频抽样模型(MIADS)的扩展，对模型预测能力产生一定局限性，而 MIDAS 可较好

基金项目：国家自然科学基金资助项目（72274001，71872002），复杂系统多学科管理与控制安徽省教育厅重点实验室开放课题（CS2022-ZD02，CS2023-ZD02）。

通讯作者介绍：黄体臣（2001-），男，汉族，山东菏泽人，安徽工业大学管理科学与工程学院，硕士研究生，研究方向：商务智能与机器学习，Email：tichenhuang@163.com。

地弥补其不足。郭杨莉等[7]将马尔可夫机制与MIDAS 融合，提出 MS-MIDAS 模型，相比于基准模型有着更高的预测进度。计量经济学方法虽在黄金期货价格预测上取得一定成效，但面对非线性高复杂的黄金期货价格时间序列，其并不能很好地提取变量特征信息，导致预测精度受限。而机器学习方法包括传统机器学习模型以及深度学习模型，它相比于变量分析方法与计量经济方法有着更高的预测精度。传统机器学习模型利用自身非线性结构以及数据驱动学习的过程可较好地捕捉到特征间的依赖关系，从而实现理想的预测精度。考虑到 Lasso 回归和弹性网络(Elastic)对金融市场波动率具有较好的预测表现。梁超等[8]通过 Lasso 与 Elastic Net 提出 Lasso-All 与 Elastic-All 缩减模型，在多项评价指标上均优于对比模型。传统计量经济模型依赖解析结构，难以捕捉复杂噪声动态，因而在建模非线性关系与未知机制时存在局限。而传统机器学习则通过数据驱动提升特征提取，弥补其不足[9]。Gil 等[10]构建高维金融指标数据集，使用梯度提升回归树(GBDT)、随机森林(RF)、极端梯度提升树(XGBOOST)等模型对金价进行建模，结果表明 GBDT 与 XGBOOST 具有更高的预测精度。

近年来，随着计算机与人工智能技术的快速发展，数据间的关联关系日益复杂，传统机器学习在特征提取上受限。相比之下，深度学习通过多层非线性映射提升特征表达能力，因而广泛应用于时间序列预测。Grudnitski 等[11]首次将神经网络应用于黄金期货价格预测，开拓了深度学习在该领域的研究方向。Zhang 等[12]提出一种用于金价预测的改进 LSTM 模型(LSTM-P)，消融试验结果表明，相对于传统 LSTM，预测精度更高。Liu 等[13]则引入 TextCNN 提取新闻文本情感特征，并结合 BiLSTM 进行建模，有效提升了中国市场黄金期货的短期预测精度。

随着研究的深入，部分学者结合各模块的优势，构建用于黄金期货价格的组合预测模型。Werner 等[14]将人工神经网络(ANN)与 GARCH 耦合，提出 ANN-GARCH 模型，显著提升了波动率预测精度。Livieris 等[15]融合 CNN 与 LSTM，利用 CNN 高效特征提取，CNN-LSTM 模型预测效果优于传统机器学习和单一 LSTM。针对高维数据复杂性，Gao 等[16]结合传统计量模型与深度学习，提出 GARCH-ATT-LSTM 模型，显著提升苹果股价、道琼斯指数及黄金期货价格预测精度。蒋超宇[17]使用 XGBOOST 筛选出与金价最相关的变量构建预测数据集，最后将 CNN 与 Transformer 结合，提出一种 CNN-Transformer 混合预测模型，实证结果表明所提模型可有效预测黄金期货价格。

总体来说，上述模型虽在黄金期货价格预测中取得了一定成果，但仍存在一些问题：(1)部分学者虽从不同角度构建多维数据集，但直接进行预测可能由于不相关或不稳定的解释变量，从而导致模型复杂度过高，影响训练效率。(2)通过 CNN 可对特征进行提取，但由于金价时序数据复杂度过高；传统卷积难以更好地捕捉到金价时序特征间的依赖关系。(3)尽管 Transformer 可较好地处理时序数据，但面对极端市场波动和外部影响，捕捉特征长时间依赖能力仍有限。

针对上述存在的问题，本文提出全新预测框架 KANsLTformer，主要创新与贡献包括：

(1)针对黄金期货价格受多重因素影响且特征冗余较多的问题，本研究从宏观经济、市场交易、技术指标等维度选取 39 个关键变量，充分考虑影响因素。同时，本文采用特征递归消除(RFE)与交叉验证递归消除(RFECV)相结合的方法，有效去除冗余变量，提取最具预测价值的特征集，提高模型稳健性与计算效率。

(2)为应对黄金期货价格的复杂非线性和非平稳特性，本文充分考虑市场价格波动的多尺度特征，结合扩张因果卷(DCC)和卷积门控线性单元(CGLU)的优势，提出时间卷积门控线性单元(TCGLU)。该模块在卷积操作中引入动态门控机制，使模型能够自适应地调节特征提取力

度，以精准捕捉短期剧烈波动。同时，DCC 的因果卷积结构能够确保信息传递的时间一致性，可更好地增强模块对长期依赖关系的捕捉能力，从而提升黄金期货价格预测的准确性与稳健性。

(3)为解决黄金期货价格的长短期依赖问题，本文对 Transformer 进行改进，提出融合 LSTM、KAN 网络(KANs)和 TCGLU 的 KANsLTformer 预测模型。该模型以 KANs 连接层替代传统多层感知机(MLPs)层，增强特征表达能力并提高可解释性；同时，在 Encoder 输出端引入 LSTM 和 TCGLU，以协同捕捉长期趋势与短期波动特征，从而显著提升黄金期货价格预测的精度与稳健性。

2 模型方法

2.1 预测模型

2.1.1 LSTM

循环神经网络(RNN)擅长捕捉短期依赖关系，但难以学习长距离依赖。为此，Jürgen 于 1997 年提出 LSTM，其通过输入门、遗忘门和输出门等机制控制信息传递。LSTM 可保留关键信息，防止长期传播中的信息丢失，增强模型对长期依赖的捕捉能力，并有效缓解梯度消失与梯度爆炸问题。

2.1.2 KANs

MLPs 由 Hornik 等人提出，是对原始感知机的扩展。受通用逼近定理的启发，该理论指出，包含有限数量神经元的单隐藏层前馈网络(FFN)能够在紧凑子集上逼近任意连续函数[18]。

与 MLPs 类似，KANs 也是由多层神经元构成的前馈网络，其设计思想源于 Kolmogorov-Arnold 定理。该定理证明，任何有界的多元连续函数都可以表示为若干单变量函数与二元加法运算符的组合[19,20]。因此，KANs 通过自适应的单变量激活函数来提高模型的表示能力，在一定程度上克服传统 MLPs 依赖固定激活函数的局限性。此外，受 Kolmogorov-Arnold 定理作用，KANs 能够揭示输入特征与输出之间的内在关系，从而提供更直观的特征映射和更有效的特征提取能力，同时在复杂函数逼近时具有更强的可解释性。

2.1.3 TCGLU

门控线性单元(GLU)是一种能够并行处理的 CNN 网络结构，它不仅可以帮助网络更好地捕捉序列数据中的长期依赖关系，减少过拟合的可能性，以更好的在处理时序数据时严格按时序位置保留信息同时增强模型泛化能力，从而提升了模型整体性能[21]。SE 机制[22]是一种通道门控注意力机制，它使用激活函数网络模块对输出进行门控，实现了最大的感受野，以更好地决策。受其启发，Dai[23]提出了一种卷积线性门控单元(CGLU)，CGLU 在门控分支激活函数模块前加入一个 3×3 深度卷积模块，将其转化为基于最近邻特征的门控通道注意机制，它使每个令牌能够基于其最近邻特征获得通道注意力，解决了 SE 机制中全局平均池过于粗粒度的缺点，同时增强了低局部建模能力和模型鲁棒性。

时间卷积网络(TCN)作为 CNN 的改进结构，通过引入扩张因果卷积(DCC)，确保时序数据的因果性，不泄露未来信息的同时扩大感受野，使其在时序特征提取方面优于传统 CNN。受此启发，本文在 CGLU 中融合独立的 DCC 模块，并进一步优化深度可分离卷积(DWC)后的输出，通过 DCC 处理，提出一种专用于复杂非线性时序数据特征提取的模块 TCGLU。该模块具体数学表达式如下：

输入张量记为 $X \in \mathbb{R}^{N\times F}$，其中 N 是样本数量，F 为特征维度。首先通过全连接层 $W_1 \in \mathbb{R}^{F\times 2H}$ 和偏置项 b_1 可得到：

$$Z_1 = XW_1 + \mathrm{b}_1 \tag{1}$$

将式(6)沿最后一个维度分为两部分记作 Z_x 和 Z_v，其中 $Z_x, Z_V \in \mathbb{R}^{N\times H}$。

对 Z_x 应用 DWC，则有：

$$X_{dw} = DW\mathrm{Conv}(Z_x, K_{dw}) \tag{2}$$

式中，K_{dw} 为 DWC 卷积核。

对 Z_v 应用扩张因果卷积可得：

$$X_{dc} = DCConv(Z_v, K, r) \tag{3}$$

式中，K 代表 DCC 卷积核；r 则为膨胀率。

将式(7)应用门控机制与式(8)逐项相乘得到：

$$X_{out} = GELU(DCC(X_{dc})) \square X_v \tag{4}$$

最终由 dropout 和全连接层 W_2 可得到最终结果：

$$Y = Dropout(X_{out})W_2 + b_2 \tag{5}$$

2.1.4 Transformer

2017 年，Google 团队提出了 Transformer 模型，该模型利用自注意力机制有效解决了 RNN 在处理长序列时的遗忘问题，并充分发挥并行计算的优势，大幅提升计算效率。Transformer 架构[24]主要由编码器和解码器两部分组成。编码器的输入由节点嵌入和位置嵌入构成，并经过自注意力层处理，使模型能够同时捕捉整个序列中的全局信息。为防止网络退化，编码器采用残差连接并结合层归一化进行标准化处理，随后通过前馈神经网络进一步优化特征表示，最终生成编码结果。

2.1.5 KANsLTformer

结合上述模块的优势，本文对在传统 Transformer 模型基础上进行创新性改进。具体而言，传统 Transformer 主要依赖自注意力机制建模长程依赖，而忽视了局部时间信息。KANsLTformer 在编码器结构中引入 LSTM 模块，使模型能够更有效地捕捉长期依赖信息，同时结合 Transformer 的自注意力机制，提升对长时间序列的建模能力。其次，传统卷积模型在时序数据处理时存在感受野受限的问题，而 SE 机制的全局池化容易导致特征过度平滑。为此，KANsLTformer 采用 TCGLU 模块，该模块融合 DCC 以扩大感受野，同时结合 CGLU 机制，利用局部特征门控提升模型对非线性时序数据的处理能力。最后，传统 Transformer 的 MLPs 层采用固定激活函数，限制了模型的表达能力。KANsLTformer 将 KANs 替换 MLPs 层，使模型能够通过自适应激活函数动态调整特征映射方式，提高特征表示能力。此外，KANs 具有较强的可解释性，有助于揭示输入特征与输出之间的内在关系。综上，KANsLTformer 通过结合 LSTM、TCGLU 和 KANs 模块，提升了对长短期依赖的建模能力，增强了对复杂非线性时序数据的特征提取能力，并提高了模型的可解释性 KANsLTformer 的结构图如图 1 所示。

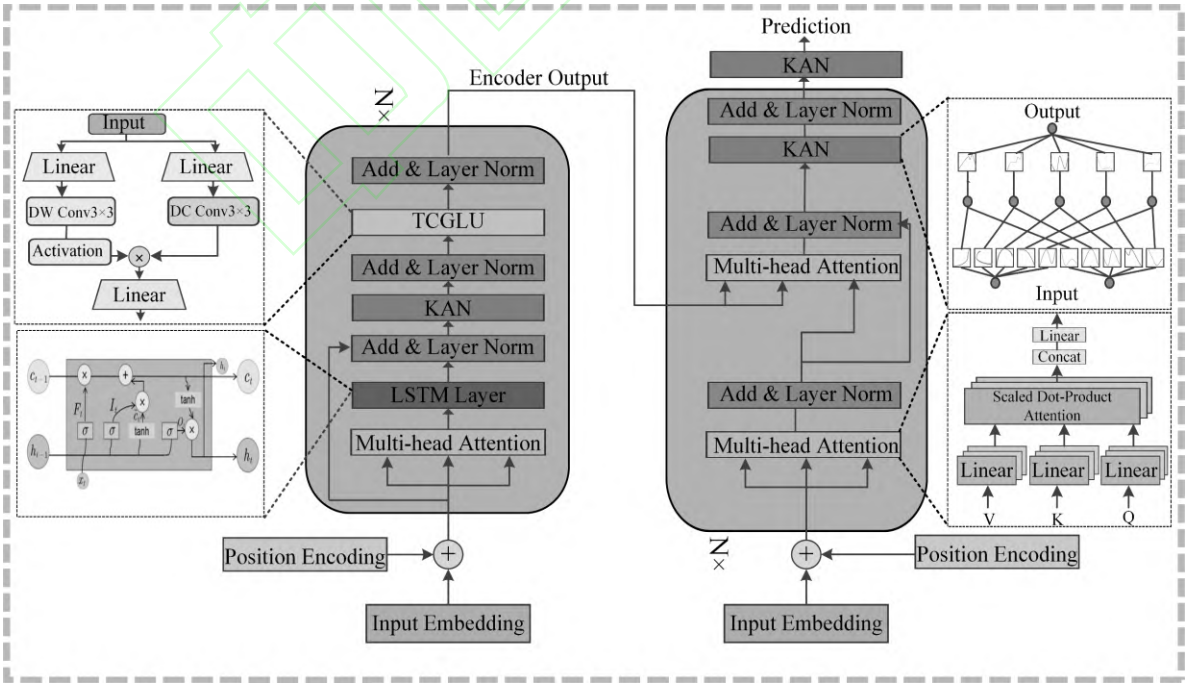

图 1　KANsLTformer 结构图

2.2 特征筛选算法

RFECV 是一种高效的特征选择方法，能够自动筛选最优特征子集，减少冗余特征带来的计算负担，并提升模型性能。该方法结合 RFE 和交叉验证(CV)，通过外部估计器为特征赋予权重，并递归剔除影响较小的特征，同时利用交叉验证评估不同特征子集的预测性能，最终选出最优特征组合。RFECV 既能降低模型复杂度、提高计算效率，又能确保模型在特征筛选后的稳健性和预测准确性。

2.3 评价指标

为全面评估本文模型的预测性能，本文选取了平均绝对误差(MAE)、对称平均绝对百分比误差(SMAPE)、均方根误差(RMSE)、中值绝对误差(MedAE)以及方向性精度(DA)五种评价指标进行评价，相关计算公式见式(6-10)。其中，MAE直接反映了模型的平均预测偏差，提供了整体误差的直观衡量。SMAPE则考虑了实际值与预测值之间的对称性，可有效避免标准百分比误差在数据较小时出现过大偏差的问题。RMSE衡量预测误差的平方根平均值，能够放大较大的误差，进而有助于评估模型对大幅度误差的响应能力。而MedAE对离群值的敏感性较低，提供更具代表性的误差值的同时不受极端值影响，从而进一步评估模型预测的稳健性。而DA则衡量预测值与实际值的趋势一致性，反映模型对数据变动方向的感知能力，从而增强决策支持，提供更为全面的模型性能评估方式。

$$\mathrm{MAE}=\frac{\sum_{i=1}^{n}\left|y_i-y_i\right|}{n} \tag{6}$$

$$\mathrm{SAMPE}=\frac{1}{n}\sum_{i=1}^{n}\frac{2\left|y_i-y_i\right|}{\left|y_i\right|+\left|y_i\right|} \tag{7}$$

$$\mathrm{RMSE}=\sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i-y_i)^2} \tag{8}$$

$$\mathrm{MedAE}=(\left|y-y_1\right|,\ldots,\left|y-y_n\right|) \tag{9}$$

$$\mathrm{DA}=\frac{1}{n}\sum_{i=1}^{n}\alpha_i,\alpha_i=\begin{cases}1,(y_i-y_{i-1})\times(y_i-y_{i-1})\geq 0;\\ 0,\text{otherwise.}\end{cases} \tag{10}$$

式中：y_i 表示真实值，y_i 表示模型输出的预测值，n 表示测试的次数。其中，MedAE 取值为[0,∞)；而 MAE、SMAPE、RMSE 与 DA 取值均为[0,1]。其中，MedAE、MAE、SMAPE 和 RMSE 越接近 0 表示模型预测误差越小，预测精度越高；而 DA 则取值越大，模型方向性精度越高。

3 实证分析

3.1 试验环境与参数设置

本研究在 Windows10 操作系统下使用 i5-12600KF 处理器，NVIDIA Geforce 4060Ti 16GB 显存显卡，32GB 内存计算机，基于 Python 3.9.18 运行环境进行试验。其中神经网络由 Tensorflow 搭建，数据处理通过 Numpy、Pandas 计算，而可视化部分由 R 语言与 Matplotlib 库实现。

3.2 实验数据与描述性分析

本文选取的数据样本为 2022 年 1 月 3 日至 12 月 30 日上海黄金期货交易日的 5 分钟高频交易数据，共计 26863 条记录。考虑到黄金期货价格受多种因素影响，为降低随机性并减少模型复杂性，本文从黄金市场、股票市场、宏观政策及相关市场中选取了具有代表性的中国期货合约，作为黄金期货价格的主要解释变量。

其中，黄金市场变量涵盖了开盘价、最高价、最低价、收盘价、交易量及持仓量等基础行情数据，同时引入多种技术指标。技术指标的选择基于其在捕捉价格趋势、波动性及动量等方面的有效性，旨在增强模型对黄金价格复杂非线性动态特征的表达与学习能力。所采用的技术指标包括指数移动平均线(EMA)、多周期简单移动平均线(SMA)、相对强弱指数(RSI)、随机指标(KDJ)、布林带(Bollinger Bands)及顺势指标(CCI)等。这些指标能够综合反映市场情绪与价格行为特征，从而有效提炼出核心信息，提升模型预

测能力。

股票市场变量选取沪深 300、上证 50、上证 100、中证 100 及中证 500 等权重指数，基于其在反映整体经济与风险偏好变化中的作用，捕捉股票市场波动对黄金避险需求的传导效应。关联市场方面，白银期货价格作为贵金属市场的重要参考变量，与黄金存在高度同向波动性；原油现货价格则体现全球经济状况及通胀压力，其变动通过成本和预期渠道影响黄金需求，增强模型对宏观经济传导机制的捕捉能力。

而宏观政策通过影响市场风险偏好、资金流动和货币价值，对黄金期货价格产生直接或间接的作用。本研究选取的宏观政策变量包括中国经济不确定性指数(EPU)、地缘政治风险指数(GPR)以及美元兑人民币汇率(USD_CNY)，以全面评估宏观政策对黄金期货价格的影响。

其中，黄金市场行情数据、股票市场与关联市场数据来源于聚宽量化交易平台；而宏观政策中 GEPU 数据来源于 https://cbade.hkbu.edu.hk/epu-mainland-china/；GPR 数据来源于 http://www.policyuncertainty.com/；USD_CNY 来源于 Wind 数据库。变量间的描述性统计分析见附表 1。

3.3 结果分析与评价

3.3.1 不同预测方法结果对比分析

为评估本文所提预测框架的有效性与优越性，将其与预测黄金价格的 5 种主流方法进行单步预测对比，包括 XGBOOST、LSTM、Transformer、ANN-GARCH 以及 CNN-Transformer。同时将 KANs 与 Transformer 结合构建 KANsformer 预测模型进行对比，以验证 LSTM 与 TCGLU 在特征提取以及处理非线性高复杂性金价时序上的优势。在测试集上，本文所提模型相比其他模型的黄金期货预测结果如图 2 所示。

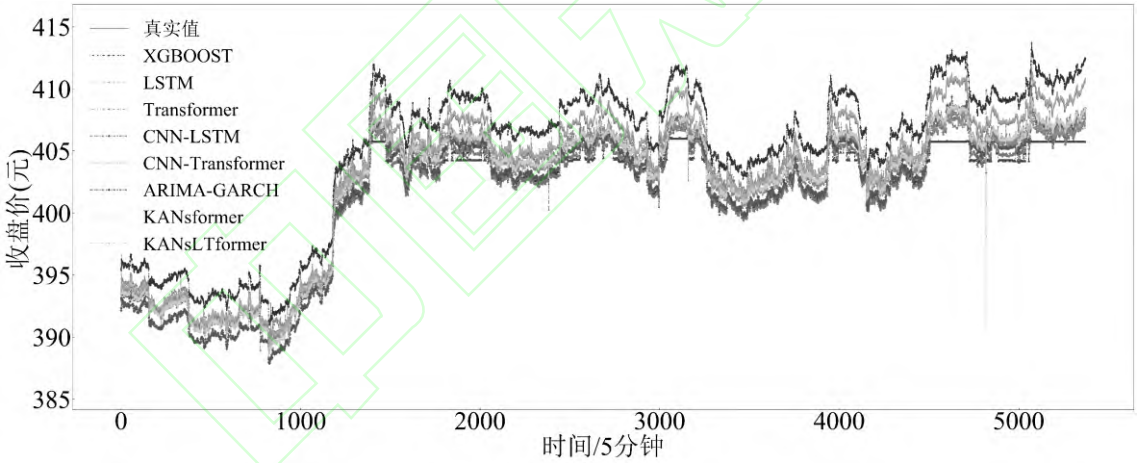

图 2　不同模型预测结果

由图 2 可看出，黄金期货价格测试集具有非线性非平稳等特点，单一模型如 XGBOOST 直接进行预测虽能大致预测出期货价格整体趋势，但由于未进行特征提取，使得整体预测偏差较大；预测精度不理想。而传统组合模型虽结合了不同模型优点进行构建进一步提高预测精度，如 CNN-LSTM 相比于 LSTM 在预测曲线上表现更接近真实值且在高峰值预测时误差更小。但 CNN 常用于提取图像中的空间特征，如边缘、纹理等，使得在提取时序特征时不能更好地捕捉长期依赖关系，进而使得整体模型预测精度受限。相比之下，KANsLTformer 得益于 KANs 的特征增强能力、LSTM 对时序数据长期依赖关系的捕捉能力以及 TCGLU 模块对复杂非线性特征的处理能力，使其在测试集上的预测结果显著优于其他 5 种模型。

为更直观地呈现各模型间的对比，将各模型评价指标汇总为表 1。

表 1　所有模型评价指标结果

模型	模型参数	参数含义	MAE	SMAPE	RMSE	MedAE	DA
XGBOOST	{100,100,0.1}	节点数,最大深度,正则化项	2.0204	0.2495	2.3181	1.9952	52.96%
LSTM	{32,64,30,0.00001}	神经元,批次,迭代次数,学习率	1,8688	0.2308	2.0812	2.1709	53.38%
Transformer	{32,32,64,30,0.00001}	嵌入维度,隐含层,批次,迭代次数,学习率	0.9884	0.1218	1.2501	0.8344	52.08%
CNN-LSTM	{3,32,64,30.0.00001}	卷积核,神经元,批次,迭代次数,学习率	1.6732	0.2070	1.7783	1.7784	52.49%
CNN-Transformer	{3,32,32,64,30,0.00001}	卷积核,嵌入维度,隐含层,批次,迭代次数,学习率	0.8669	0.1069	1.1614	0.6094	52.76%
ARIMA-GARCH	{1,1,1}	自回归阶数,差分次数,移动平均阶数	1.8765	0.2323	1.8863	1.8790	54.17%
KANsformer	{32,32,64,30,0.00001}	嵌入维度,隐含层,批次,迭代次数,学习率	0.9484	0.1169	1.1218	0.9394	53.34%
KANsLTformer	{32,32,64,30,0.00001}	嵌入维度,隐含层,批次,迭代次数,学习率	**0.1709**	**0.0211**	**0.2710**	**0.1676**	**63.69%**

结合上表进一步可观察到：首先，与其他模型相比，KANsLTformer 各项误差指标最低，表明它在捕捉黄金期货价格数据的长期依赖性和复杂的非线性关系方面具有突出优势。

其次，与传统计量经济模型相比，ARIMA-GARCH 模型由于依赖于线性假设和有限的自回归结构，在建模复杂时序数据时表现较为局限，尤其在处理多维特征和长短期依赖方面较为乏力。相比之下，KANsLTformer 的 MAE、SMAPE、RMSE 以及 MedAE 分别降低了 91.5%、91.5%、88.3%和 88.7%而在 DA 上提高了 10.73%充分表明 KANsLTformer 在应对复杂金价时序数据时，优于传统的计量经济方法。

再次，在机器学习方法对比上，传统机器学习模型 XGBOOST 尽管在处理部分非线性关系和高维数据上具有一定的优势，但在捕捉时间序列特征及长距离依赖方面的能力仍不及 KANsLTformer。实证结果表明，KANsLTformer 在各项评价指标上均显著优于 XGBOOST，尤其在 DA 上，KANsLTformer 的准确率高出 10.73%。此外，LSTM 作为传统深度学习模型，虽在捕捉长短期依赖上具备较强的能力，但其在提取全局特征方面有所不足。而 KANsLTformer 不仅继承了 LSTM 在时间序列建模方面的优势，还通过 Transformer 机制增强了全局特征的提取能力。实验结果显示，KANsLTformer 在各项指标上均优于 LSTM，尤其在 SMAPE 上，误差减少了 90.9%，同时在 DA 上提升了 10.31%，进一步证明了其在趋势预测上的有效性。

最后，在混合深度学习模型的对比中，尽管 CNN-LSTM 和 CNN-Transformer 通过将卷积层与 LSTM 或 Transformer 相结合，增强了对局部特征和时间依赖的处理能力，但其在全局特征捕捉方面仍存在不足。相比之下，KANsformer 在建模局部特征和全局依赖方面表现出一定的优势，然而其对长短期依赖的处理能力较为欠缺。而 KANsLTformer 基于 KANsformer，通过引入 LSTM 和 TCGLU 模块，旨在进一步提升模型对长短期依赖的捕捉能力。实证结果表明，KANsLTformer 相较于 KANsformer，在各项误差评价指标上分别降低 82%、82%、75.8%和 82.2%，同时在 DA 上提升 10.35%。这进一步验证了 KANsLTformer 在应对高频黄金期货价格时间序列中的波动性和非平稳性问题时，不仅能够减少误差显著提高预测精度，还能更准确地预测价格变动的方向，从而增强模型的实际

应用价值。

然而，黄金期货价格时间序列在实际中常受到政策变动等突发事件引发的剧烈波动，进而呈现出一定的不确定性。为此，噪声试验通过人为增加白噪声来模拟数据中的不确定性，旨在验证模型在面对突发市场变动等非理想数据时的表现是否稳定，从而检验其在实际预测中的性能与稳健性。附图 4 左侧子图展示了人为添加 3%噪声幅值后的数据可视化效果；右侧子图则对比了原始数据与加入噪声后的测试集数据。可以看出，噪声的能量较大，噪声的加入覆盖了测试集的较大部分，导致数据波动明显加剧，特征变得模糊不清，增加了模型提取有效信息的难度，从而对预测精度产生了一定影响。将噪声扰动后的测试集用于各模型进行噪声试验。为确保试验的科学性和有效性，试验过程中各项参数均与前述实验保持一致。各模型的评价指标如表 2 所示。

表 2　噪声环境下不同模型评价结果

模型	MAE	SMAPE	RMSE	MedAE	DA
XGBOOST	2.1095	0.2606	2.4228	2.1053	52.85%
LSTM	2.7434	0.3407	3.3506	2.4289	53.64%
Transformer	2.4066	0.2988	3.2316	1.9194	53.64%
CNN-LSTM	1.8116	0.2254	2.1401	1.7074	53.81%
CNN-Transformer	1.6174	0.2008	2.0634	1.3453	53.21%
ARIMA-GARCH	1.8797	0.2327	1.9207	1.8805	50.20%
KANsformer	1.5190	0.1884	1.9401	1.2565	53.60%
KANsLTformer	**0.9314**	**0.1156**	**1.1866**	**0.7704**	**58.03%**

从表 2 可以看出，噪声对各模型的预测性能均产生不同程度的影响。然而，KANsLTformer 在噪声条件下表现较为优异，各项评价指标显著优于其他模型，展现出较强的噪声鲁棒性。此外，CNN-Transformer 和 CNN-LSTM 等模型在噪声环境下也有较好表现，但其 SMAPE 和 MedAE 指标相对较高，表明在应对较大噪声干扰时，这些模型的处理效果仍有不足。综上所述，KANsLTformer 在处理非线性、非平稳且含有噪声的金价时序数据时，表现出较强的鲁棒性和优越的预测能力。

除了评价指标对比以及噪声试验衡量模型预测性能外，Diebold-Mariano(DM)检验可更加全面地检验模型间的预测差异，本文以 KANsLTformer 作为目标模型，将其余 7 个模型作为对比模型进行 DM 检验。DM 检验的原假设为 KANsLTformer 与其他模型具有相同的预测性能，备择假设为 KANsLTformer 的预测性能与其他模型存在显著差异。表 3 显示了 DM 检验的结果。从表中可见，KANsLTformer 在原始试验和噪声试验中，DM 统计量均在 1%显著性水平上显著，表明原假设被拒绝，证明 KANsLTformer 的预测能力优于其他模型。进一步验证了 KANsLTformer 在不同环境下具有较强的预测性能和稳健性。

表 3　KANsLTformer 对比其他模型 DM 检验结果

被检验模型	DM 统计量	
	未加噪声	加入噪声
XGBOOST	-77.4402***	-56.0749***
LSTM	-113.5347***	-51.4074***
Transformer	-54.8297***	-28.9163***
CNN-LSTM	-181.4867***	-41.3144***
CNN-Transformer	-38.5674***	-28.0977***
ARIMA-GARCH	-71.6243***	-31.9823***
KANsformer	-23.0117***	-20.1548***

注：样本 N=5373;*表示 $P<0.1$,**表示 $P<0.05$,***表示 $P<0.01$

3.3.2 消融试验

为验证本文创新点的有效性，并进一步评估各模块在 KANsLTformer 模型中的重要性，本

文分别进行消融试验。具体操作为依次去除 KANsLTformer 模型中的 TCGLU、LSTM 和 KAN 模块，构建简化版本的模型进行对比。同时，为检验 TCGLU 相较于 CGLU 的优越性，本文构建了 KANsLCformer 模型进行对照实验。试验结果如表 4 所示。

表 4　消融试验评价结果

消融试验模型	模型名称	MAE	SMAPE	RMSE	MedAE	DA
去除 TCGLU	KANsLformer	0.6517	0.0808	0.6889	0.6579	57.42%
去除 LSTM	KANsformer	0.9484	0.1169	1.1218	0.9394	53.34%
去除 KAN	Transformer	0.9884	0.1218	1.2501	0.8344	52.08%
融合 CGLU 的 KANsLformer	KANsLCformer	0.3025	0.0375	0.3652	0.2879	60.21%
本文模型	KANsLTformer	**0.1709**	**0.0211**	**0.2710**	**0.1676**	**63.69%**

根据上表，可看出每个模型在去除不同模块后的性能变化，同时得出以下结论：(1)去除 TCGLU 模块后的 KANsLformer 在整体性能上明显退化，DA 下降至 57.42%，说明 TCGLU 在局部特征提取与时序依赖建模中具有关键作用，对趋势方向识别尤为重要。(2)去除 LSTM 模块后的 KANsformer 性能进一步下降，MAE 与 SMAPE 分别升至 0.9484 与 0.1169，DA 降至 53.34%，表明 LSTM 在捕捉长短期依赖方面不可或缺，其缺失显著弱化了模型对价格波动的响应能力。(3)去除 KAN 模块后的 Transformer 性能最差，MAE 为 0.9884，SMAPE 增加至 0.1218，RMSE 和 MedAE 也显著升高，同时 DA 进一步下降至 52.08%，表明 KANs 在复杂时序数据中有效提取特征，并在与其他模块的结合下显著提高了模型的预测精度和趋势判断能力。(4)通过对比融合 CGLU 的 KANsLCformer 和本文的 KANsLTformer 可看出，TCGLU 相较于 CGLU 在局部特征提取中的表现更为优越。尽管 KANsLCformer 在 DA 上有所提升，但仍低于 KANsLTformer，说明 CGLU 机制能够进一步增强模型的时序依赖建模能力，使其在趋势预测方面表现更为精准。同时，相比于 KANsLCformer，KANsLTformer 的各项误差指标均进一步降低，进一步表明 TCGLU 在提取多层次特征方面表现出更强的能力，并对方向判断的准确性贡献更大。

3.3.3 泛化性对比分析

为全面评估所提模型的泛化性与稳健性，本文选取受地缘政治与宏观经济扰动影响显著的 COMEX 黄金价格与埃及黄金价格作为实验对象。前者反映国际黄金市场动态，后者则更具区域特征，受中东局势与埃及国内经济影响较大。通过在多个具有代表性的数据集上开展预测实验，结合逐日频率建模，不仅验证了 KANsLTformer 模型在不同市场环境下的适应能力，也体现其对突发事件下价格波动的鲁棒性。埃及黄金期货数据来源于(https://egypt.gold-price-today.com)，而 COMEX 黄金价格数据来自(http://finance.yahoo.com)。基于本文提出的数据处理与建模流程，进一步将 KANsLTformer 模型与对比模型进行泛化性评估与性能对比分析。

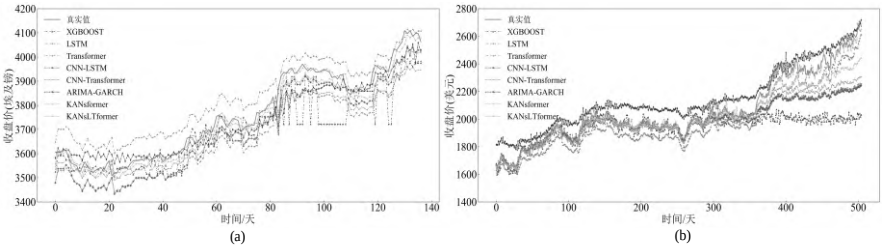

图 3　不同模型在泛化性试验数据预测结果

图 3(a)和图 3(b)分别展示了埃及当地市场黄金期货价格和COMEX黄金价格的预测趋势。从图中可以看出，相较于其他模型，KANsLTformer 在不同数据集上的预测表现最优，能够准确捕捉金价未来的波动趋势。同时，通过图 3(a)可看出，2024 年 5 月至 10 月期间，埃及黄金价格稳步上涨，特别是在 8 月中旬后，由于中东局势不稳和全球经济不确定性增加，黄金需求大幅上升，从而推高了价格。而通过图 3(b)可观察出，2024 年 8 月，地缘政治风险和宏观经济因素驱使部分投资者转向黄金等避险资产，推动金价突破每盎司 2500 美元，创下历史新高。2024 年 9 月美联储宣布降息 0.5%，这一决定导致债券收益率下降以及削弱无风险资产的吸引力，进一步促使投资者转向无收益的黄金，推高金价。这些突发因素增加了黄金期货价格的波动性，增强了其非平稳和难以预测的特性，可能是导致实际价格走势与预测结果之间误差扩大的主要原因。

表 5　不同模型泛化性试验评价结果

数据集	模型	MAE	SMAPE	RMSE	MedAE	DA	DM 检验
埃及黄金价格	XGBOOST	69.7318	2.5413	98.9720	38.5051	62.50%	-6.4079***
	LSTM	92.0865	1.2347	95.6364	89.3962	58.09%	-21.2106***
	Transformer	72.1662	0.9653	78.2811	75.5867	58.82%	-14.5686***
	CNN-LSTM	64.4458	0.8716	68.7717	63.8050	57.35%	-15.8823***
	CNN-Transformer	66.5865	0.8775	70.4068	56.5352	56.62%	-10.3537***
	ARIMA-GARCH	43.9879	0.5813	56.0312	36.6803	57.66%	-6.4780***
	KANsformer	31.6444	0.4153	39.7640	26.8520	56.62%	-5.9914***
	KANsLTformer	**16.6275**	**0.2205**	**23.8333**	**11.3333**	**66.18%**	**对比方法**
COMEX	XGBOOST	132.4153	3.0624	220.2748	41.6613	47.82%	-11.6701***
	LSTM	79.1351	1.9552	82.7390	79.2719	48.21%	-37.1149***
	Transformer	80.6978	1.8140	130.9899	29.7590	45.44%	-11.0576***
	CNN-LSTM	77.0082	1.7364	106.0356	43.1638	49.44%	-10.8653***
	CNN-Transformer	64.1437	1.4339	107.0781	22.5243	49.80%	-9.9197***
	ARIMA-GARCH	93.8118	2.3014	102.3941	93.5258	53.57%	-27.5524***
	KANsformer	47.2512	1.0591	72.3237	22.6538	49.80%	-10.0566***
	KANsLTformer	**18.3397**	**0.4411**	**24.5911**	**13.5664**	**62.30%**	**对比方法**

注：埃及黄金价格数据集样本 N=137,COMEX 数据集样本 N=505;*表示 $P<0.1$,**表示 $P<0.05$,***表示 $P<0.01$

表 5 展示了各模型在埃及与 COMEX 黄金价格数据集上的预测结果。KANsLTformer 在所有评价指标上均优于对比模型，展现出卓越的泛化能力与稳健性。其在两个市场中均有效捕捉了复杂时序特征，显著提升了预测精度。尽管组合模型在特征提取方面具有一定优势，但由于时序依赖建模不足，整体表现不及 KANsLTformer。以 SMAPE 为例，COMEX 数据集中 CNN-LSTM 为 77.0082，而 KANsLTformer 仅为 18.3397，差异明显。同时，KANsLTformer 在趋势预测能力方面亦表现优越，DA 在埃及与 COMEX 数据集中分别达到 66.18%与 62.30%，均明显高于其他模型。进一步，DM 检验结果在 1%显著性水平上均拒绝原假设，表明 KANsLTformer 在不同市场条件下具备更强的预测优势与泛化能力。

4 结论

随着全球经济环境日益复杂及金融市场不确定性加剧，黄金作为重要避险资产，其期货价格波动备受关注。精准预测黄金期货价格不仅为投资者提供科学决策依据，也为政府和金融机构的政策制定提供数据支持。本文基于沪金 5 分钟高频交易数据，综合多因素构建预测数据

集。首先，采用 RF 进行多重插补，提升数据完整性与可用性；其次，利用基于 RFECV 方法筛选关键特征，降低模型复杂度并提升训练效率。最后，提出 KANsLTformer 模型用于黄金期货价格预测。通过横向和纵向实验设计，与多种经典预测模型对比，验证了所提模型的优越性，研究结论如下：

(1)KANsLTformer 通过融合 LSTM 的长期依赖建模能力、KANs 的深度特征表达优势及 TCGLU 对短期波动的敏感性，实现了多尺度时序特征的高效捕捉，在黄金期货价格预测中展现出优越的准确性与稳健性，预测误差最小、性能最优。

(2)消融实验验证了 TCGLU 在短期特征提取方面优于传统 CGLU，能更有效识别价格的剧烈波动模式；同时，其引入未显著增加模型复杂度，保持了良好的计算效率，进一步证明了该结构的有效性与实用性。

(3)本文系统评估了 KANsLTformer 在黄金期货预测中的适用性与优势，选取 XGBOOST、ARIMA-GARCH、CNN-LSTM 等主流模型为对比基准，结合 MAE、SMAPE、RMSE、MedAE 与 DA 等多指标评估体系，并辅以 DM 检验与消融试验，结果表明 KANsLTformer 在预测精度与跨市场泛化能力方面均明显优于其他模型。

需要指出的是，基于实证研究的结论，本研究能够为上海黄金期货市场的参与者提供一定的辅助决策支持。然而，本研究仍存在一些不足之处。首先，尽管本文所采用的模型在多个评估指标上表现优异，但数据的局限性可能会影响模型在更广泛市场环境中的适用性。其次，本文虽验证了所提模型在短期交易以及逐日期货价格的预测性能，但在中期时段的预测研究中仍存在空白，尤其是在时间尺度的拓展方面。例如，现有研究主要集中于 5 分钟单步预测，未来可以进一步拓展至多步预测模型，以捕捉更长时段的价格趋势和波动规律。这不仅能够提升预测的广度，还能为投资者提供更精准和及时的决策支持。此外，通过结合实时数据更新和短期市场波动因素，未来的研究还可以加强模型的动态适应性，从而提高模型在不同市场环境中的泛化能力和实用性。

参考文献：

[1] Collins G. N, John E, Jacinta N, Wang Y, On the efficiency of the global gold markets[J]. International Review of Financial Analysis, 2015,41:218-236.

[2] 贺毅岳, 陈倩倩, 高妮, 等.基于 MEMD-WGAN-GP 的黄金期货价格集成预测研究[J/OL]. 系统工程理论与实践. http://kns.cnki.net/kcms/detail/11.2267.n.20240827.1442.004.html.
He Y Y, Chen Q Q, Gao N, et al. An ensemble model for forecasting gold futures price based on MEMD-WGAN GP[J/OL]. Systems Engineering-Theory & Practice. http://kns.cnki.net/kcms/detail/11.2267.n.20240827.1442.004.html.

[3] 钟美瑞, 石越, 尹力博, 等. 高频视角下投资者关注度对黄金期货市场的影响研究[J]. 系统科学与数学, 2020,40(11):1935-1949.
Zhong M R, Shi Y, Yin L B, et al. Research on the Impact of Investor Attention on Gold Futures Market from the Perspective of High Frequency[J]. Journal of Systems Science and Mathematical Sciences, 2020,40(11):1935-1949.

[4] Christian Pierdzioch, Marian Risse, Sebastian Rohloff,On the efficiency of the gold market: Results of a real-time forecasting approach[J]. International Review of Financial Analysis, 2014,32:95-108.

[5] Mishra, P. K. Gold Price and Capital Market Movement in India: The Toda–Yamamoto Approach[J]. Global Business Review, 2014,15(1), 37-45.

[6] Li X Q, Ma X Q. Jumps and gold futures volatility prediction[J]. Finance Research Letters, 2023,58(C):104492.

[7] 郭杨莉, 马锋. 基于马尔科夫和混频数据模型的黄金期货市场波动率预测研究[J]. 中国管理科学, 2024, 32(01):13-22.
Guo Y L, Ma F. Forecasting the Chinese Gold Futures Market Volatility Using Markov-Switching Regime and Mixed Data Sampling Model[J]. Chinese Journal

of Management Science, 2024, 32(01):13-22.

[8] 梁超,魏宇,马锋,等.我国黄金期货价格波动率预测研究:来自模型缩减方法的新证据[J].中国管理科学, 2022, 30(04):30-41.
Liang C, Wei Y, Ma F, et al. Forecasting Volatility of China Gold Futures Priee. New Evidence from Model Shrinkage Methads[J]. Chinese Journal of Management Science, 2022, 30(04):30-41.

[9] 欧阳红兵, 黄亢, 闫洪举. 基于LSTM神经网络的金融时间序列预测[J]. 中国管理科学, 2020, 28(04):27-35.
Ouyang H B, Huang K, Yan H J. Prediction of Financial Time Series Based on LSTM Neural Network[J]. Chinese Journal of Management Science, 2020, 28(04):27-35.

[10] Gil C, Avishay A, Forecasting gold price using machine learning methodologies[J]. Chaos, Solitons & Fractals, 2023,175(2): 114079.

[11] Grudnitski G., Osburn L. Forecasting S&P and gold future prices: An application of networks[J]. Futures Mark, 1993,13(6): 631-643

[12] Zhang X, Zhang L, Zhou Q, et al. A Novel Bitcoin and Gold Prices Prediction Method Using an LSTM-P Neural Network Model[J]. Comput Intell Neurosci. 2022,5:1643413.

[13] Liu Y C, Zhang Y, Peng X Y. Textual analysis and gold futures price forecasting: Evidence from the Chinese market[J]. Finance Research Letters,2024,69(A):106116.

[14] Werner K, Marcel C. M, Gold price volatility: A forecasting approach using the Artificial Neural Network – GARCH model,Expert Systems with Applications[J], 2015,42(15):7245-7251.

[15] Livieris, I.E., Pintelas, E. & Pintelas, P. A CNN–LSTM model for gold price time-series forecasting[J]. Neural Computing and Applications, 2020,32:17351–17360.

[16] Gao, Z D, Kuruoglu, E. E. Attention based hybrid parametric and neural network models for non-stationary time series prediction[J]. Expert Systems, 2024,41(2): e13419.

[17] 蒋超宇. 基于 CNN-Transformer 的黄金期货价格预测[D]. 上海财经大学, 2021.
Jiang C Y. Gold Futures Price Prediction Based on CNN-Transformer[D]. SHANGHAI UNIVERSITY OF FINANCE AND ECONOMICS, 2021.

[18] Hugo I, Remi G. SigKAN: Signature-Weighted Kolmogorov-Arnold Networks for Time Series [DB/OL]. https://arxiv.org/abs/2406.17890

[19] Liu Z M, Wang Y X, Vaidya et al. KAN：Kolmogorov-Arnold Networks [DB/OL]. https://arxiv.org/abs/2404.19756

[20] William Knottenbelt, Zeyu Gao, Rebecca Wray, et al. CoxKAN: Kolmogorov-Arnold Networks for Interpretable, High-Performance Survival Analysis [DB/OL]. https://arxiv.org/abs/2409.04290

[21] Saoud L S, Ibrahim H, Aljarah A, et al. Improving Knee Joint Angle Prediction through Dynamic Contextual Focus and Gated Linear Units [DB/OL]. https://arxiv.org/abs/2306.06900

[22] Hu J, Li S, Samuel A, et al. Squeeze-and-Excitation Networks[J], IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020,42(8): 2011-2023.

[23] Dai S. TransNeXt: Robust Foveal Visual Perception for Vision Transformers [DB/OL]. https://arxiv.org/abs/2311.17132

[24] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.

Gold Futures Price Prediction Based on KANsLTformer

Jiang Yuyan[1,2]，*Huang Tichen*[1,2]，*Gan Rumeijiang*[2,3,*]，*Wang Fuyu*[1,2]

(1. School of Management Science and Engineering, Anhui University of Technology, Ma'anshan 243032, China; 2. Key Laboratory of Multidisciplinary Management and Control of Complex Systems of Anhui Higher Education Institutes, Ma'anshan 243002, China; 3. School of Electrical and Information Engineering, Anhui University of Technology, Ma'anshan 243032, China.)

Abstract: Gold, possessing the dual characteristics of a commodity and a monetary asset, has assumed an increasingly pivotal role in global financial markets. Its price dynamics are profoundly influenced by a wide array of macroeconomic indicators and geopolitical developments, rendering the gold futures time series highly volatile, nonlinear, and non-stationary. These intrinsic properties

present significant challenges for accurate short-term forecasting. In response to these challenges, this study proposes an advanced deep learning framework, termed KANsLTformer, aimed at effectively capturing the intricate temporal dynamics and multi-scale structures inherent in gold futures price series. The objective is to enhance both prediction accuracy and model robustness in the face of complex market behaviors. At the core of KANsLTformer lies a novel Temporal Convolutional Gated Linear Unit (TCGLU), which combines temporal convolution with a gating mechanism to selectively extract and emphasize relevant short-term features. This design enhances the model's capacity to focus on local temporal patterns crucial for high-frequency market fluctuations. Building upon this foundation, the framework integrates a customized Transformer architecture that learns global dependencies and dynamic attention patterns across time, enabling the model to capture long-range interactions effectively. Furthermore, the inclusion of the Kolmogorov-Arnold Networks (KANs) module facilitates the modeling of nonlinear feature interactions through KANs, while Long Short-Term Memory (LSTM) units are employed to retain and utilize long-term historical information, further enriching the temporal representation. Together, these components form a synergistic hybrid architecture capable of modeling both high-frequency and low-frequency patterns and adapting to abrupt market changes. The model is empirically validated using real-world gold futures data, encompassing core trading variables such as open, high, low, and close prices, trading volume, and open interest. The evaluation framework encompasses diverse market conditions, including both stable and highly volatile regimes, and employs time-series-specific validation techniques along with robustness assessments under artificially introduced noise. Comparative experiments benchmark KANsLTformer against several comparative models, including ARIMA-GARCH, XGBOOST, LSTM, and CNN-Transformer. Results demonstrate that KANsLTformer significantly outperforms these baselines, achieving reductions in Mean Absolute Error (MAE), Symmetric Mean Absolute Percentage Error (SMAPE), Root Mean Square Error (RMSE), and Median Absolute Error (MedAE) by approximately 91.5%, 91.5%, 88.3%, and 88.7%, respectively. Moreover, the model enhances Directional Accuracy (DA) by 10.73%, reaching 63.69%. The superiority of KANsLTformer is further validated through Diebold-Mariano (DM) tests, which confirm the statistical significance of its predictive improvements over competing models at the $p < 0.001$ level under both noise-free and noisy conditions. Notably, under noisy conditions, the model maintains a DA of 58.03%, consistently outperforming benchmarks with statistically significant DM test values. Ablation studies underscore the indispensable contributions of the TCGLU and LSTM components in capturing short-term volatility and long-term dependencies, respectively. The complete configuration of KANsLTformer demonstrates superior stability, robustness, and generalization performance, particularly in volatile market scenarios. In conclusion, this study introduces a robust and generalizable framework for financial time series forecasting, offering practical implications for investors, financial analysts, and policymakers engaged in gold futures trading. Beyond its application to the gold market, the methodological advancements presented herein contribute to the broader domain of deep learning-based time series modeling, opening new avenues for future research in financial prediction and decision support systems.

Keywords: Gold Futures Price Prediction; Transformer; KANs; LSTM; TCGLU

附录

A1 预测框架流程

KANsLTformer 黄金期货价格预测网络框架如附图 1 所示，具体步骤为：

1)数据处理与特征筛选：首先，对数据集进行初步处理，构建多维黄金期货价格数据集并利用 RF 多重插补填补数据缺失值。此外，采用 RFECV 方法进行特征选择，提取最优特征子集，确保模型输入数据的有效性和优化模型复杂度。

2)模型训练与对比分析：将数据集按 7:1:2 比例划分为训练集、验证集和测试集，并对比本文所提 KANsLTformer 模型与传统单一模型 XGBOOST、LSTM、Transformer；组合计量模型 ARIMA-GARCH；组合深度学习模型 CNN-Transformer、CNN-LSTM 和 KANsformer 在 MAE、SMAPE、RMSE、MedAE 以及 DA 等多项指标上的预测性能。

3)稳健性与泛化性试验：在对比分析的基础上，首先进行噪声试验，通过向数据中引入噪声来评估模型在噪声干扰下的稳健性。随后，采用 DM 检验方法比较各模型预测误差的显著性差异。最后，基于不同数据集进行泛化性测试，全面评估模型在不同应用场景下的适应性和推广能力。

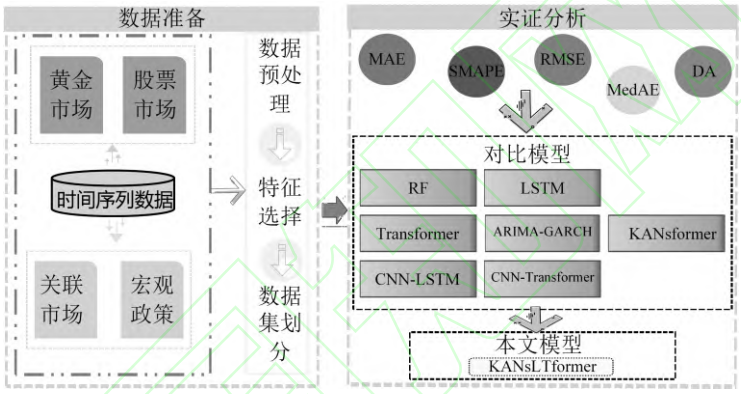

附图 1　预测框架流程图

A2 变量间的描述性统计表

附表 1　变量描述性统计

变量名	变量类别	变量解释	平均值	最小值	最大值	标准差	偏度	峰度	J-B 统计量
Close	黄金市场行情指标	收盘价(被解释变量)	392.59	367.34	420.54	10.61	-0.34	-0.70	1065.76***
Open	黄金市场行情指标	开盘价	392.59	367.36	420.44	10.61	-0.34	-0.70	1068.07***
High	黄金市场行情指标	最高价	392.72	368.24	420.7	10.62	-0.34	-0.68	1052.65***
Low	黄金市场行情指标	最低价	392.46	367.14	419.4	10.60	-0.34	-0.70	1077.30***
Volume	黄金市场行情指标	交易量	901.64	2	34657	987.16	5.16	76.32	6638573.03***
Atm	黄金市场行情指标	持仓价	120468.72	19791	169604	39641.73	-0.99	-0.38	4640.32***
EMA_12	黄金市场技术指标	12 日指数平均移动值	392.58	368.21	418.82	10.60	-0.34	-0.71	1083.37***
SMA_5	黄金市场技术指标	5 日平均移动线	392.59	368.15	419.24	10.61	-0.34	-0.70	1070.31***
SMA_15	黄金市场技术指标	15 日平均移动线	392.58	368.25	418.49	10.60	-0.34	-0.71	1080.83***
SMA_30	黄金市场技术指标	30 日平均移动线	392.57	368.35	417.72	10.59	-0.34	-0.71	1097.65***
RSI_6	黄金市场技术指标	6 日相对强弱指数	50.59	4.31e-05	99.99	18.57	-0.01	-0.47	254.02***
RSI_12	黄金市场技术指标	12 日相对强弱指数	50.57	0.07	99.97	14.05	-0.02	-0.06	5.45*
Low_14	黄金市场技术指标	14 日最低价	391.98	367.14	416.76	10.56	-0.35	-0.71	1118.52***
High_14	黄金市场技术指标	14 日最高价	393.18	368.50	420.70	10.66	-0.33	-0.68	1001.76***
RSV	黄金市场技术指标	相对强弱指标	50.91	0	100	28.78	-0.03	-1.24	1711.43***
K	黄金市场技术指标	随机指标 K 值	50.93	0.11	99.95	24.56	-0.03	-1.22	1657.65***
D	黄金市场技术指标	随机指标 D 值	50.92	0.11	99.95	22.62	-0.03	-1.12	1403.93***
J	黄金市场技术指标	随机指标 J 值	50.94	-44.76	201.71	33.93	-0.03	-1.18	1557.19***

MOM	黄金市场技术指标	动量线	0.01	-12.46	7.72	0.86	-0.74	20.37	466644.78***
Bupper	黄金市场技术指标	布林带上轨	393.29	368.55	423.93	10.68	-0.32	-0.67	965.56***
Bmiddle	黄金市场技术指标	布林带中轨	392.58	368.25	418.54	10.60	-0.34	-0.71	1086.36***
Blower	黄金市场技术指标	布林带下轨	391.87	367.30	417.02	10.56	-0.35	-0.71	1119.64***
CCI	黄金市场技术指标	顺势指数	2.74	-666.67	666.67	117.15	-0.04	1.49	2499.62***
OBV	黄金市场技术指标	能量潮	166182.34	-16529	309940	78028.90	-0.56	-0.46	1624.23***
Williams	黄金市场技术指标	威廉指标	-49.15	-100	0	28.83	-0.03	-1.24	1723.07***
NVI	黄金市场技术指标	负成交量指标	1008.65	999.76	1014.68	3.77	-0.87	-0.13	3386.53***
PPO	黄金市场技术指标	价格震荡百分比指数	0.00	-0.83	0.61	0.08	-0.27	9.98	111728.97***
TRIX	黄金市场技术指标	三重指数平滑线	0.00	-0.11	0.08	0.01	-0.23	9.19	94719.39***
CSI_300	股票市场	沪深 300 指数	4145.90	3500.03	4930.92	242.52	0.49	0.73	1670.44***
SSE_50	股票市场	上证 50 指数	2771.48	2292.22	3283.65	180.82	0.39	0.15	700.51***
SSE_100	股票市场	上证 100 指数	6817.62	5594.59	8310.07	449.32	0.46	0.28	1049.59***
CSI_50	股票市场	中证 50 指数	4014.79	3367.92	4972.71	255.93	0.44	0.52	1185.63***
CSI_500	股票市场	中证 500 指数	6220.25	5167.43	7376.79	303.57	0.60	1.86	5480.95***
Ag_price	关联市场	白银现货价格	4752.31	4018.14	5445.10	345.42	-0.04	-0.97	1060.16***
Oil_price	关联市场	原油现货价格	641.97	489.84	804.27	66.21	-0.41	-0.66	1256.06***
EPU	宏观政策	中国经济不确定性指数	190.10	9.79	1011.31	158.39	2.66	8.57	113983.22***
GPR	宏观政策	地缘政治风险指数	224.90	38.28	542.66	116.12	0.71	0.02	2279.64***
USD_CNY	宏观政策	美元兑人民币汇率	6.43	6.28	7.26	0.14	1.48	0.63	10275.91***

注：*表示 $P<0.1$,**表示 $P<0.05$,***表示 $P<0.01$;J-B 统计量表示 Jarque-Bera 统计量

A3 数据预处理

在构造数据集时，由于 EPU、GPR 及 USD_CNY 均为日度数据，与其他解释变量的时频不一致，直接使用可能无法准确反映其对黄金期货价格的影响。为此，本文通过 Pandas 库对这些变量进行了插值处理，将其转换为 5 分钟的高频数据。同时，由于部分检测数据存在缺失情况，为确保数据可用性本文使用随机森林(RF)进行插补，附图 2 左侧子图为对应特征缺失值比例，右侧子图为插补结果，从图中可观察出，原始数据集存在一定的数据集缺失，NVI 缺失比例最高，而经多重插补后，所有变量都完整无缺失的观测数据条目所占的比例，说明绝大部分数据都没有缺失，插补后数据质量较好。

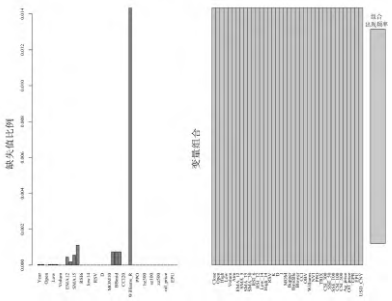

附图 2　多重插补可视化图

A4 特征选择

为降低模型复杂度，本文利用 RFECV 进行特征选择，以剔除解释力较弱的变量。具体而言，RFECV 的评估器设为支持向量机回归(SVR)，CV 次数为 10，损失函数采用 MAE，以此筛选最优特征并确定特征数量。

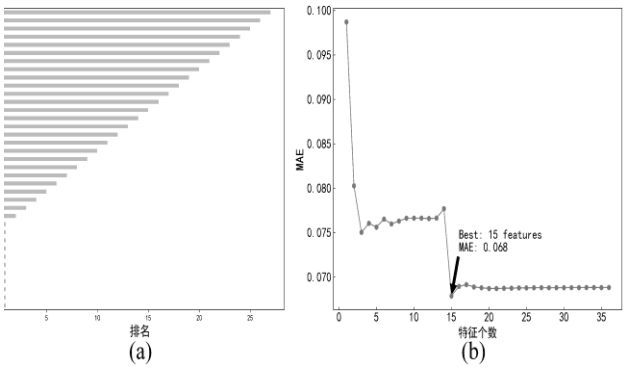

附图 3　RFECV 变量最优排名与个数选择

附图 3(a)展示了 RFE 计算的特征重要性排序，附图 3(b)显示了最优特征数量的选择结果。从附图 3(b)可见，当输入特征数为 15 时，评估器性能最佳。结合附图 3(a)的特征排序，最终筛选出的特征详见附表 2。

附表 2　变量筛选结果

变量编号	筛选变量
1	Bupper
2	High
3	Low
4	PPO
5	EMA_12
6	Blower
7	SMA_15
8	Bmiddle
9	MOM
10	High_14
11	Low_14
12	TRIX
13	Open
14	J
15	SMA_30

A5 数据可视化效果图

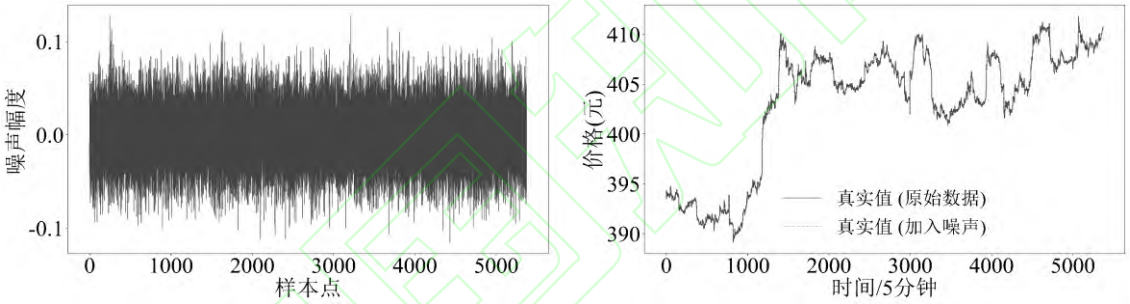

附图 4　噪声测试集对比

A6 噪声环境下的评价指标箱线图分析

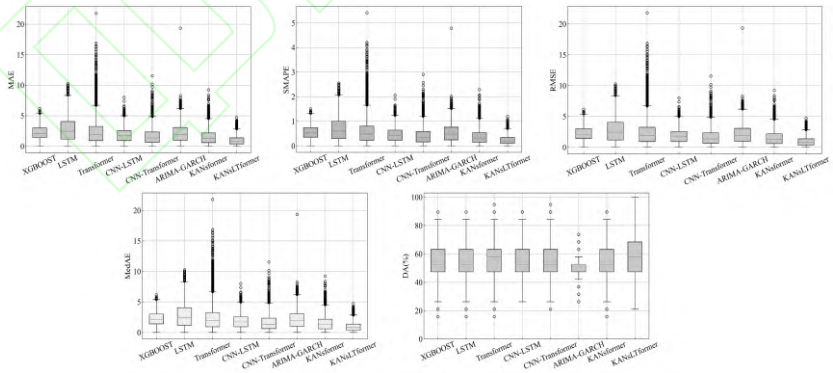

附图 5　噪声环境下各模型评价指标箱线图

附图 5 展示了各模型在噪声环境下的评价指标箱线图。从图中可看出，KANsLTformer 在误差指标上的中位数相对较低，表明其整体预测误差较小，表现优异。尽管存在部分离群值，但数量较少且分布较为集中，表明个别情况下的误差对整体影响有限。相比之下，Transformer 和 KANsformer 的离群值较多，反映出 KANsLTformer 在噪声干扰环境下对数据的处理更稳定。此外，KANsLTformer 的箱体高度较低，显示其误差波动范围较小。与 CNN-

Transformer 和 CNN-LSTM 相比，KANsLTformer 的误差波动性显著减少，进一步证明其在面对噪声干扰时具有更强的鲁棒性，不易受到异常样本的干扰。而在 DA 上，KANsLTformer 中位数更高，且具有更稳定的分布及更优的性能区间，表明其预测能力和稳健性更。强综上所述，KANsLTformer 具备较低的中位误差、较小的误差波动及较少的离群值，表明其在复杂噪声环境下的预测稳定性显著优于其他模型。