中国管理科学
Chinese Journal of Management Science
ISSN 1003-207X,CN 11-2835/G3

《中国管理科学》网络首发论文

题目： 黄金价格的混合多元回归预测研究：基于分解-重构-集成方法论
作者： 黄兆荣，宋正阳，杨博，曾能民，余乐安
DOI： 10.16381/j.cnki.issn1003-207x.2024.2305
网络首发日期： 2025-08-08
引用格式： 黄兆荣，宋正阳，杨博，曾能民，余乐安．黄金价格的混合多元回归预测研究：基于分解-重构-集成方法论[J/OL]．中国管理科学．
https://doi.org/10.16381/j.cnki.issn1003-207x.2024.2305

网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

网络首发时间：2025-08-08 08:48:50　　网络首发地址：https://link.cnki.net/urlid/11.2835.g3.20250807.1446.012

DOI：10.16381/j.cnki.issn1003-207x.2024.2305

黄金价格的混合多元回归预测研究: 基于分解-重构-集成方法论

黄兆荣[1], 宋正阳[1], 杨博[1,2], 曾能民[3,4], 余乐安[1,2]

1. 四川大学商学院, 四川 成都 610065;

2. 科技金融四川省重点实验室（四川大学）, 四川 成都 610065;

3. 哈尔滨工程大学经济管理学院，黑龙江 哈尔滨 150001;

4. 大数据与商务智能技术工业和信息化部重点实验室（哈尔滨工程大学）, 黑龙江 哈尔滨 150001;）

摘要：黄金资产的价格形成机制错综复杂，难以通过单变量时间序列分析框架全面揭示其内在特征空间中所蕴含的丰富多维信息。为此，本文基于分解-重构-集成思想，提出一种稳健分解和分层集成策略的混合回归模型用于黄金价格预测，有效地挖掘多种金融影响因素在不同时间尺度间的协同作用。首先，开发了一种稳定变分模式分解（Stable variational mode decomposition, SVMD）技术，以提取黄金价格序列的稳定中心频率分量边界，用于连续的特征学习。接着，运用 Hurst 指数作为记忆性重构指标，将分解分量重构成短期、中期和长期尺度分量。其次，利用缩放主成分分析回归和最小最大凹度惩罚回归的特征选择优势构建混合线性回归（Hybrid linear regression, HLR）模型，在不同时间尺度上提取重要金融特征用于预测，从而提高整体预测泛化能力。最后，分层集成方法将原始层、重构层和分量层的预测结果进行综合，得到调和的黄金价格预测值。该模型采用两个国际黄金价格数据进行实证分析，研究结果验证了所提出的模型在分解、重构和集成三个步骤的有效性，并且对比已有研究的多种预测模型和分解建模策略验证了所提出模型的优势。

关键词：黄金价格预测; 混合线性模型; 分解集成; 变分模态分解; 分层集成

中图分类号：F832.51　　**文献标识码：**A

1 引言

黄金作为高流动性和高储值性的战略性资源，兼具商品、金融和货币三种属性，向来视作应对各种不确定性的天然对冲工具和重要的避险资产[1]。自 2008 年金融危机以来，黄金是盈余外汇储备进行分散投资管理的主要对象，在发展中经济体的储备资产中呈现动态上涨积累的趋势[2]。后疫情时代下，全球经济增速放缓、债务高企、地缘政治冲突加剧等因素，进一步推动普通投资者和各国央行主动配置黄金资产的浪潮[3]。在全球金融调整背景下，精准的黄金市场价格预测是助力衍生品市场定价机制完善及套期保值策略优化的关键支撑，也是维护国家金融安全的防波堤[4]。

黄金价格的形成机理复杂，易受国际政治政策变化、外部金融市场冲击和投资者的心理等多种因素的影响[5]。这些错综复杂的因素交织在一起，使黄金价格序列显现出非平稳、高噪声、长记忆、尖峰厚尾的复杂特性，决定了准确预测其变动趋势的难度[6-7]。面对此类具有多复杂特征耦合的时序数据，建立多尺度模型挖掘时频规律，提炼复杂系统中的场景要素和降低数据维度，是预测其演化方向的前沿方法[8-9]。Yu 等[10]提出的分解-重构-集成的预测范式从数据特征驱动的角度为研究此类复杂金融系统提供了落地的方法指导。其核心思想是依据样本的数据特征匹配预测模型，对具有相似数据特征的序列进行重构预测，最终以权重或机器学习的方式进行集成[11]。迄今，这种分解-重构-集成的建模范式在空气质量[12]、零售量[13]、港口吞吐量[14]、能源市场[15]等时间序列领域得到较广泛的应用。

具体到黄金价格预测领域，杨晨和陈贵词[16]提出了基于经验模态分解（EMD）集成模型，发现在国际黄金期货价格的预测上比单个机器学习模型更优。Yang 等[17]采用 Hurst 指数分析 EEMD（集合 EMD）分解序列的多重分形性，以指导序列的重构和机器学习方法的使用。何林芸[18]和 Lu 等[19]使用基于 ICEEMDAN（自适应白噪声完备 EEMD）与重构技术的组合模型，改善了黄金期货价格在水平和方向两方面的预测性能。Liang 等[20]开发 LSTM-CNN-CBAM 的联合深度模型预测 ICEEMDAN 分解的各子序列，结果表明联合深度

资助项目: 国家自然科学基金重点项目 （72331007）

通讯作者简介: 余乐安 （1976—）, 男 （汉族）, 湖南常德人, 四川大学商学院教授, 博士生导师, 研究方向: 大数据挖掘、商务智能、金融管理, E-mail: yulean@amss.ac.cn. 杨博 （1988—）, 男 （汉族）, 吉林长春人, 四川大学商学院副研究员, 研究方向: 大数据挖掘、能源需求预测、时间序列分析, E-mail: yangbo_1@scu.edu.cn.

模型增强了建模能力，并且分解算法可以进一步提高预测精度。除类 EMD 的时域分解外，具有精确频域带宽分割的变分模态分解（VMD）也是实现多分辨率的模态分解较佳方案[21]。陈凯杰[22]等运用 EEMD 和 VMD 两种分解技术对贵金属市场价格进行级联分解，并将所有分量预测结果线性叠加，能更全面地捕捉原始收益率序列的特征。E 等[23]从变分模态（VM）重构出独立分量并采用 GRU 得到黄金独立分量预测并加总集成，有效的改善因长期趋势、周期性循环因素和随机事件对金价波动预测带来的干扰。

但是，当前分解-重构-集成的预测流程仍存在以下三个不足之处：（1）已有研究仅注重解决模态混淆效应以提升周期性的分解性能，而忽视因分解算法的边界效应导致的数据失真问题。这隐含地假设了未来数据的分解结果与历史分解结果一致，致使预测性能被高估[24-26]。（2）数据特征驱动的分解-重构-集成模型在单变量数据集上已有大量实践[27-29]，但针对受混杂多变量影响的多尺度黄金分量而言，预测子模型选择仍缺乏指导准则。（3）传统分量集成方案结合机器学习的历史误差加权进行非线性整合时，由于实时分解的分量变化大，集成映射易产生过拟合现象而难以外推。

针对以上研究不足，本文提出一种基于稳定 VMD 分解-重构-分层集成的多元线性混合预测方法，并以国际黄金市场价格为例进行预测分析。首先，采用稳定 VMD 对原始黄金价格序列进行逐步分解，从分解边界建模的角度，解决边界效应导致由数据失真到模型失真的问题。其次，将衡量记忆性的 Hurst 指数[30]用于重构判定和预测子模型的指导准则，其中子模型采用缩放主成分分析（SPCA）和最小最大凹度惩罚（MCP）增强的线性回归，以契合稳定分解序列的光滑特性[31]。两种回归依照记忆性的强弱的指示分别对长期趋势分量、中期循环分量和短期随机分量建模，形成了基于降维回归和收缩回归的分解指派式混合模型，有效地剔除冗杂的协变量。最后，引入分层集成策略[32]，该集成过程仅依赖于各层次样本内的结构化信息，无需额外的监督学习步骤，从而避免了集成模块可能出现的过拟合问题。主要研究贡献体现在以下三点：（1）修正 VMD 分解的优化求解过程以改善分解边界效应，确保实时分解得到的分量边界作为监督学习目标具备稳定性。（2）构建了记忆性特征驱动的指派式混合线性预测模型，充分发挥不同多变量线性预测器的特征学习性能。（3）首次提出用于分量聚合的分层集成方案，将分解层、重构层、原始层的分量结构信息嵌入集成过程中，有效地将多层次差异化的预测整合成一致性预测，为解决以往集成策略带来的过拟合问题提供新思路。

2 相关理论基础

2.1 变分模态分解

由于时域求解的困难，变分模态分解（VMD）通过希尔伯特变换将目标序列转换到频域，并假设分解得到的变分模态（VM）是集中在各自中心频率附近的窄带模态 $\{\mu_k | k=1,2,...,K\}$，K 是 VM 分量的个数。最小化所有 VM 估计带宽之和的优化目标可以通过一个变分问题的泛函来表示。具体来说，将模态函数 μ_k 的频谱调制到以中心频率为 $\omega_k\left(k=1,2,...,K\right)$ 基准的基带，并计算模态梯度的平方范数用来估计各模态信号带宽之和；同时保证所有 VM 分量之和等于原始序列 $f\left(t\right)$。构造约束性变分表达式[33]如下：

$$\begin{aligned}&\min_{\{\mu_k,\omega_k\}}\left\{\sum_K\left\|\partial_t\left[\left(\delta\left(t\right)+\frac{j}{\pi t}\right)\otimes\mu_k\left(t\right)\right]e^{-j\omega_k t}\right\|_2^2\right\}\\&s.t.\sum_K\mu_k\left(t\right)=f\left(t\right)\end{aligned}\tag{1}$$

引入拉格朗日乘子 $\lambda(t)$，该约束性变分问题转变为增广拉格朗日函数：

$$\begin{aligned}&L\left(\{u_k\},\{\omega_k\},\lambda\right)\\&=\alpha\sum_K\left\|\partial_t\left[\left(\delta\left(t\right)+\frac{j}{\pi t}\right)\otimes u_k\left(t\right)\right]\right\|_2^2\\&+\left\|f\left(t\right)-\sum_K u_k\left(t\right)\right\|_2^2+\left\langle\lambda\left(t\right),f\left(t\right)-\sum_K u_k\left(t\right)\right\rangle\end{aligned}\tag{2}$$

使用交替方向乘子法（ADAM）对模态函数 u、中心频率 ω 和拉格朗日乘子 λ 进行交替搜索求解，第 $l+1$ 步对三个变量的更新公式为：

$$\begin{aligned}&u_k^{l+1}=arg\min_{u_k}L\left(\left\{u_{i<k}^{l+1}\right\},\left\{\omega_k^l\right\},\lambda^l\right);\\&\omega_k^{l+1}=arg\min_{\omega_k}L\left(\left\{u_k^l\right\},\left\{\omega_{i<k}^{l+1}\right\},\lambda^l\right);\\&\lambda_k^{l+1}=\lambda_k^l+\rho\left(f\left(t\right)-\sum_k u_k^{l+1}\left(t\right)\right)\end{aligned}\tag{3}$$

2.2 缩放主成分分析回归（SPCA）

缩放主成分分析（SPCA）是 Huang 等[34]提出的新颖的降维回归方法，它在构建扩散指标之前，根据每个预测因子在目标序列上的预测能力对其进行缩放。在含大量噪声的弱因子数据结构下，SPCA 模型相对流行的 PCA 模型，更能识别出对统计目标有用的预测因子，在预测通货膨胀、市场价格和收益率波动方面得到验证[35-36]。

SPCA 回归分两步从预测因子 $x_{i,t}$ 中提取扩散指数。首先，构造标度修正的预测指标面板，$\left(\beta_1 x_1,...,\beta_N x_N\right)$，其中 N 是预测因子的总数量，标

度系数 β_i 是对标准化预测指标的黄金价格进行回归得到的斜率。

$$p_{t+1} = \alpha_i + \beta_i x_{i,t} + \varepsilon_{t+1} \tag{4}$$

第二步，标度修正的预测指标面板中提取 PCA 扩散指标 F_t 作为新的黄金价格预测指标，其形式如下：

$$\beta_i S_{i,t} = \lambda_i^{'} F_t + e_{i,t} \tag{5}$$

其中，F_t 是降维后的 R 维向量，表示 SPCA 扩散指标。$\lambda_i^{'}$ 是待估计的 R 维参数，$e_{i,t}$ 是特质噪声项。

在样本外分析中，SPCA 回归做出 t+1 天的黄金价格预测为：

$$p_{t+1} = \beta_0 + \sum_{r=1}^{R} \beta_r F_{r,t}^{SPCA} + \sum_{i=1}^{Q} \varphi_i p_{t-1} \tag{6}$$

其中，p_{t+1} 是预测的黄金价格，β_0 为截距，β_r 为标度系数，$\sum_{i=1}^{Q} \varphi_i p_{t-1}$ 为自回归项，当 R=0 时退化成单变量线性预测。

2.3 最小最大凹度惩罚回归（MCP）

最小最大凹度惩罚[37]是 Zhang 改进 Lasso 罚函数的折叠凹罚函数，其回归产生的估计量同时具有稀疏性、无偏性、连续性和性[38]，因而模型预测和偏差具有良好的稳定性。MCP 惩罚函数的引入可以有效地剔除不重要的协变量，同时避免对相关特征的过度压缩，变量选择结果往往更合理。MCP 变量选择惩罚函数的基本形式为：

$$L(\boldsymbol{\beta};\lambda) = \frac{\|\boldsymbol{y} - \boldsymbol{X\beta}\|^2}{2T} + \sum_{j=1}^{p} \rho\left(|\beta_j|;\lambda\right) \tag{7}$$

其中 $\sum_{j=1}^{p} \rho\left(|\beta_j|;\lambda\right)$ 为罚函数；T 为样本数；p 为待估计参数个数。

$$\rho\left(|\beta_j|;\lambda\right) = \begin{cases} \lambda|\beta_j| - \dfrac{|\beta_j|^2}{2\gamma}, 0 \le |\beta_j| < \gamma\lambda, \\ \dfrac{\gamma\lambda^2}{2}, |\beta_j| > \gamma\lambda, \end{cases} \tag{8}$$

其中，λ 和 γ 为调整参数，$\lambda > 0$，$\gamma \ge 1$。

2.4 分层集成

分解序列和重构序列与原始序列之间存在天然的聚合层级结构。在分层预测集成框架中，所有序列首先使用预定的独立预测方法进行预测，从而产生基本预测。然后，寻求最佳调和集成方法，提供所有级别预测具有一致性的最终预测[39]。考虑一个具有线性分层结构约束的多维时间序列，存在以下关系：

$$y_t = \mathbf{S} b_t \tag{9}$$

其中，b_t 是底层时间序列的观测值，在本文中是分解后的 VM 分量；y_t 是包含顶层、中间层、底层序列的观测值；$\mathbf{S}$ 是维数为 $M \times K$ 的求和矩阵。在三层分层预测结构中，M=K+C+1，K 是底层序列个数，C 是中间层序列的聚合个数。

为了确保每一级的基本预测也能以与观测值相同的方式聚合起来，需要对预测进行调整，所有线性调和方法均可表示为：

$$\tilde{\mathrm{y}}_t = \mathbf{SP}\hat{\mathrm{y}}_t \tag{10}$$

其中，$\hat{\mathrm{y}}_t$ 是基本预测，$\tilde{\mathbf{y}}_t$ 是调和后的预测。求和矩阵 $\mathbf{S}$ 的结构决定序列的聚合结构，$\mathbf{P}$ 为协调矩阵，$\mathbf{P}$ 的结构决定了不同的分层预测方法。例如，分解集成中常见的直接加总法，只在最底层生成预测，等价于 $\mathbf{P} = \left[0_{K\times(M-K)} \mid I_K\right]$，也就是分层预测中的自底向上（BU）方法[40]。

由于各层次序列存在不同数据模式和预测不确定性，无法像观察值保持聚合一致性，固有因调和预测偏离基本预测而产生的调和误差项 ε：

$$\tilde{\mathrm{y}}_t = \mathbf{S}\hat{b}_t + \varepsilon \tag{11}$$

通过广义最小二乘估计可得 $\mathbf{P}$ 的封闭解：

$$\mathbf{P} = \left(\mathbf{S}^T \Sigma^{\dagger} \mathbf{S}\right)^{-1} \mathbf{S}^T \Sigma^{\dagger} \tag{12}$$

由于 Σ 计算困难，本文采用样本的最小迹（minT-simple）法估计[41]，它与各层次的预测和预测误差无关。该方法使用各层次序列观测值 y 的样本协方差估计为：

$$\Sigma = Cov(y, y) \tag{13}$$

3 稳定分解-重构-分层集成模型

3.1 稳定分解过程

VMD 求解过程被认为具有数据驱动的自适应性和完全非递归性[22]，但是这种分解特性不适宜用于处理金融市场的实时信息流。因为在每一时刻求解出不同的最佳中心频率的基准模态会产生边界效应，实时分解的分解边界发生了分布偏移。如图 1 所示，用虚线和虚框表示的历史分解结果与未来分解结果的偏差会逐渐累积，这也是为什么不能使用全部数据集进行分解代替逐步分解的根本原因。

为得到稳定的分解边界，本文提出稳定变分模态分解（Stable Variational Mode Decomposition, SVMD），先根据在训练集数据上进行 VMD 的自适应求解得到优化中止的迭代次数 L 和中心频率

ω_k^L，具体公式如下：

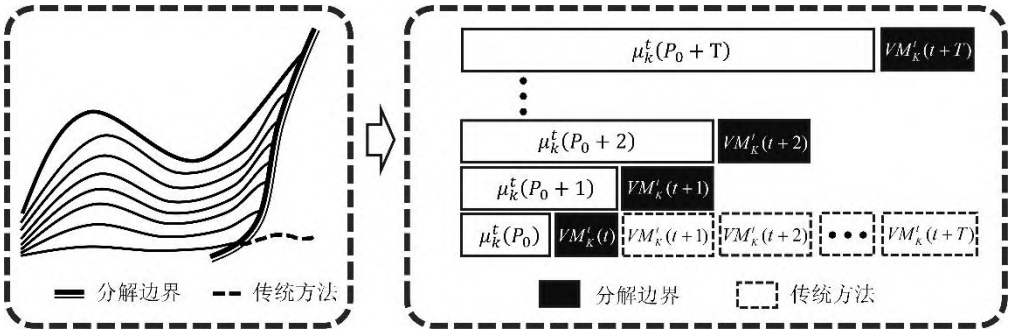

图 1 SVMD 算法逐步分解示意图

$$\omega_k^{l+1}(t)=\frac{\int_0^\infty \omega(t)\left|\hat{\mu}_k^{l+1}(\omega(t))\right|^2 \mathrm{d}\omega}{\int_0^\infty \left|\hat{\mu}_k^{l+1}(\omega(t))\right|^2 \mathrm{d}\omega} \tag{14}$$
$$(l=1,2,\ldots,L,t=1,2,\ldots,T_{train})$$

将训练集逐步分解的多次结果进行平均得到平均迭代次数 $\bar{L}$ 和平均中心频率 $\bar{\omega}_k$：

$$\bar{\omega}_k=\frac{\sum_1^{T_{train}}\omega_k^L(t)}{T_{train}},\bar{L}=\frac{\sum_1^{T_{train}}L(t)}{T_{train}} \tag{15}$$

在测试集中，ADAM 优化过程中锚定 $\bar{L}$ 和 $\bar{\omega}_k$ 不变，提取时不变的中心频率分量，模态函数的更新公式修正为：

$$\hat{\mu}_k^{l+1}(t)=\frac{\hat{f}(\omega(t))-\sum_{i\neq k}\hat{\mu}_i(\omega(t))+0.5\hat{\lambda}(\omega(t))}{1+2\alpha(\omega(t)-\bar{\omega}_k)^2} \tag{16}$$
$$(l=1,2,\ldots,\bar{L},t=1,2,\ldots,T)$$

在 SVMD 实时分解过程中，仅有分解模态的最后一个点作为待监督学习的对象。根据自回归的框架，重新组织实际的黄金价格分解分量为：

$$y_k(t)=VM_k^t(t)=\mu_k^t(P_0+t-1)(t=1,2,\ldots,T) \tag{17}$$

其中，μ_k^t 是第 t 次分解的第 k 个分解模态，P_0 是初始的分解时间窗口大小。结合公式（6）对 $y_k(t)$ 建模方案称为基于分解边界的建模范式。它预测第 t 期的点所使用的信息来自于前 Q 次分解过程中的最末端的样本点 $\{VM_k^{t-Q}(t\text{-}Q),\ldots,VM_k^{t-1}(t\text{-}1)\}$，并非来自于第 t 期的分解分量，因此边界建模方案能杜绝将待预测点信息提前纳入了分解和预测过程的数据泄露问题。

3.2 模型构建

黄金价格受众多外部金融因素的冲击影响，其作用机制的时间尺度和层次复杂。本文提出稳定分解-重构-分层集成预测框架，多层次地解析黄金样本数据的多维变化特征。首先，采用 SVMD 分解方法和记忆性重构方法，可以准确识别黄金序列中互不耦合的不同频率分量特征。然后，在原始序列层面（原始层）、分解后的分量序列层面（分解层）、重构分量序列层面（重构层）分别刻画金价序列和其他特征之间的关系。其中，依照分量波动的随机性和记忆性强弱的指示，使用不同的特征学习预测器对不同分量进行针对性的多变量预测。最后，根据分层集成方法，调整三个层次的预测以符合已知的聚合结构形成最终的预测结果。模型的框架如图 2 所示，建模步骤如下：

步骤 1：原始层构建。收集黄金价格相关的历史数据，对相关数据和黄金价格序列进行归一化。采用格兰杰因果检验进行初步筛选得到预测指标面板 $\{x_1,\ldots,x_N\}$。

步骤 2：分解层构建。确定 SVMD 优化过程平均迭代次数 $\bar{L}$ 和平均中心频率 $\bar{\omega}_k$。然后使用 SVMD 技术逐步地将黄金价格序列分解为模态分量集合，取模态分量集合的边界值作为真实的变分分解模态结果，记为 $\{\mathrm{VM}_1,\ldots,\mathrm{VM}_K\}$。将原始价格序列减去各 VM 得到残差序列 RES 分量。

步骤 3：重构层构建。采用 Hurst 指数归结分量内部的随机性和记忆性的相似程度。设置 Hurst 指数的长记忆性、短记忆性、反记忆性的区间临界值，Hurst 指数落在同一个区间的 VM 分量和 RES 分量重构为一项。为使重构序列有一定的经济物理含义，Hurst 指数从小到大的分量分别定义为长期尺度模态（LTM）、中期尺度模态（MTM）和短期尺度模态（STM）。LTM、MTM 和 STM 的重构结果记为重构层分量。

步骤 4：混合回归预测。在重构层中，LTM 分量和 MTM 分量是具有长期趋势或中期周期的记忆性分量，受序列自身滞后期影响较大，采用 SPCA 的缩放降维回归方法将外在金融变量重组为相关扩散指标，再与自回归项结合进行预测。而 STM 分量表现为黄金价格的短期波动，其高频震荡现象呈现出反记忆性，受序列自身滞后期影响较小而受特定外在金融变量影响较大，采用 MCP

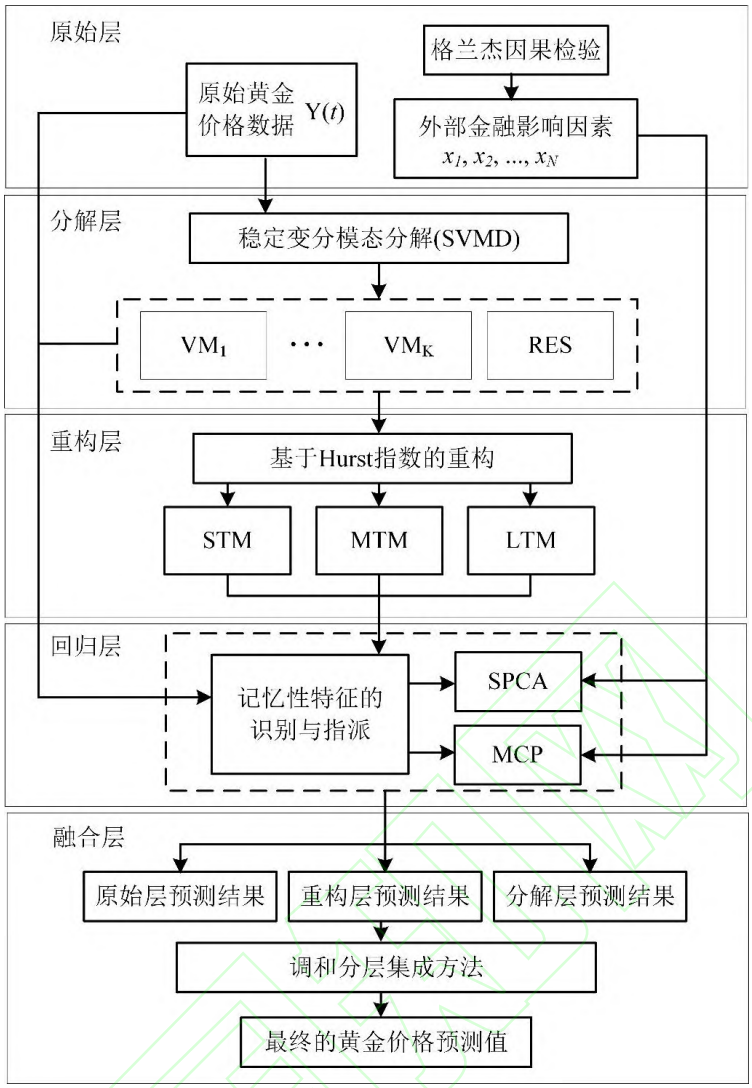

图 2 SVMD 分解-记忆性重构-分层集成预测框架

回归进行高效嵌入式特征选择以实现稳健预测。原始层和分量层的分量预测方案类似，落入与重构层对应的 Hurst 指数区间采用相应的回归方法。

步骤 5：分层集成。根据步骤 3 的分量重构关系，确定求和矩阵 **S** 。根据对调和协方差的估计计算协调矩阵 **P** 。根据式（14），对步骤 4 得到三个层次预测 $\hat{y}_t$ 进行调和集成，得到最优黄金价格的分层预测结果。

3.3 评判标准

本文运用均方误差（MSE）、平均绝对误差（MAE）、方向统计量（D_{stat}）和 D_{stat} 与平均绝对百分比误差比值（D/M）的四种误差评判指标，以及 DM 统计检验的衡量黄金价格的预测性能，计算方式为：

$$\mathrm{MSE}=\frac{1}{T}\sum_{t=1}^{T}\left(y(t)-\hat{y}(t)\right)^2 \tag{18}$$

$$\mathrm{MAE}=\frac{1}{T}\sum_{t=1}^{T}\left|y(t)-\hat{y}(t)\right| \tag{19}$$

$$D_{stat}=\frac{1}{n}\sum_{i=1}^{n}d_i$$
$$d_i=\begin{cases}1,\left(y(t)-y(t-1)\right)\left(\hat{y}(t)-y(t-1)\right)\geqslant 0\\ 0,\left(y(t)-y(t-1)\right)\left(\hat{y}(t)-y(t-1)\right)\leqslant 0\end{cases} \tag{20}$$

$$D/M=\frac{D_{stat}}{T}\sum_{t=1}^{T}\left|\frac{y(t)-\hat{y}(t)}{y(t)}\right| \tag{21}$$

$$DM=\frac{\sum_{t=1}^{n}g_t/T}{\sqrt{\left(\gamma_0+2\sum_{l=1}^{\infty}\gamma_l\right)/T}} \tag{22}$$

其中，MSE 和 MAE 为反向指标，表示预测误差越小越好。D_{stat} 和 D/M 为正向指标，表示预测准确性越大越好。$y(t)$ 和 $\hat{y}(t)$ 表示第 t 时刻的真实值和预测值，T 表示样本数量，$\gamma_l=\mathrm{cov}(g_t,g_{t-l})$，$g_t$ 是两个对比模型对应损失函数的差分序列取绝对值。

4 实证研究

4.1 数据描述

由于国际市场在全球黄金定价中的核心作用和影响力，选取芝加哥商品交易所黄金期货连续价和伦敦场外交易市场的黄金现货价格作为研究对象，研究考察日期范围中不包括公共节假日和周末。然后，按 85%:15%的比例将原始数据划分为训练集和测试集。在芝加哥黄金数据集中，将 2011 年 6 月 1 日-2021 年 7 月 27 日的 2560 个数据作为训练集，2021 年 7 月 27 日-2023 年 4 月 21 日的 452 个数据作为测试集。在伦敦黄金数据集中，将 2011 年 6 月 1 日-2021 年 7 月 7 日的 2553 个数据作为训练集，2021 年 7 月 7 日-2023 年 4 月 21 日的 451 个数据作为测试集。

影响因素包括全球主要的股票市场、国债市场、汇率市场、商品市场和日度不确定性共同用于预测黄金价格的每日价格变化[42]。股票指数是经济投资的晴雨表，选取金砖国家、OECD 和 APEC 经合组织的国家和地区的股指作为全球股票波动的主要数据，排除了在 2011 之后发行的股票指数。国债市场和汇率市场可以表征财政政策和货币政策，影响或反映金融资产间流动情况。国债市场采用中国、美国、英国、德国、法国等十余主要经济体的十年期国债利率数据。汇率市场选择的经济体与国债市场类似，其中芝加哥黄金数据集选取以美元为基准的汇率，而伦敦黄金数据集选取以英镑为基准的汇率。大宗商品期货包括白银、石油、天然气和小麦，代表能源、贵金属、能源和食品四大大宗商品部门。芝加哥黄金数据集使用纽交所上市的期货品种，而伦敦黄金数据集使用欧洲洲际交易所上市的期货品种。

此外，加入了标准普尔高盛商品指数和路透商品研究局指数代表国际期货的整体情况，以表征通货膨胀和经济复苏的情况。以上金融市场数据来自于 WIND 数据库。此外，还纳入了恐慌指数（VIX）和推特文本经济不确定性指数（美国地区和英文地区）[43]，以提供衡量市场不确定性和经济不确定性预期的指标。通过格兰杰因果检验[44]初步筛选得到能在统计上显著影响黄金价格相关因素，在芝加哥黄金数据集为 46 个，在伦敦黄金数据集为 39 个，主要差别体现在影响伦敦金现货的股票指数较少。两个市场的筛选后的影响因素情况如表 1 所示。

4.2 分解与重构设置

使用 SVMD 分解技术对原始序列进行分解时，必须预设模态分量数量 K。传统采用的一些先验性的信号特征统计方法可能与预测性能无关，因此本研究使用计算成本较小的线性回归（LR）进行参数试错搜索，以判断是否过度分解。K 取不同值情况下分解预测性能如图 3 所示，横坐标为分解模态数量 K，纵坐标为 D/M 统计量。当 K 值为 3 和 8 时，两个黄金价格序列的水平和方向综合预测指标为局部最大值，因此，对于两个国际黄金价格序列，最佳的 VMD 分解模态数量设定为 8，重构模态数量设定为 3。根据设定的 K=8、平均迭代次数 $\bar{L}$ 和平均中心频率 $\bar{\omega}_k$，执行逐步的 SVMD 分解，SVMD 分解的结果如图 4 所示。

本文通过 Hurst 指数算法识别频率从低到高的 VM1 到 VM8 和 RES 九个分量的记忆性特征，表 2 展示了两个黄金数据集的分解层的各分量 Hurst 指数和类别划分结果。参照 Yu 等的 Hurst 指数区间临界值设置[30]，对模态分量进行类别划分。具体来说，前三个分量的 Hurst 指数大于 0.85，表明 VM1-VM3 分量具有长记忆性，聚合为长期尺度模态（LTM）；中间三个分量 Hurst 指数大于 0 且小于 0.85，表明 VM4-VM6 分量具有短记忆性，聚合为中期尺度模态（MTM）；最后三个分量 Hurst 指数小于 0，表明分量具有反记忆性，因此 VM7，VM8 和 RES 聚合为短期尺度模态（STM），如图 4 所示。

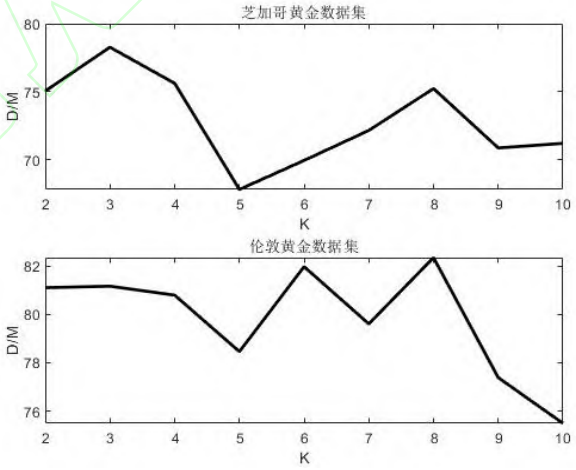

图 3 不同 K 值分解预测性能

根据表 2 的聚合情况，可知原始分量、分解分量、记忆性分量组成了三层分层预测结构，用于分层集成的求和矩阵 **S** 表示为：

$$\mathbf{S}=\begin{bmatrix}1&1&1&1&1&1&1&1&1\\1&1&1&0&0&0&0&0&0\\0&0&0&1&1&1&0&0&0\\0&0&0&0&0&0&1&1&1\\&&&&I_9&&&&\end{bmatrix} \tag{23}$$

表 1 筛选得到的影响因素与被选中的因素

影响因素	芝加哥黄金数据集		伦敦黄金数据集	
	是否通过格兰杰因果检验	有无被 MCP 回归选中	是否通过格兰杰因果检验	有无被 MCP 回归选中
恒生股指	是	RES,STM	是	无
印度股指	是	无	否	无
泰国股指	是	VM7	是	STM
韩国股指	是	RES,STM	否	VM7,VM8,RES,STM
俄罗斯股指	否	无	是	RES,STM
巴西股指	是	VM7,RES,STM	是	VM6,VM7,VM8,RES,STM
墨西哥股指	是	RES	是	无
意大利股指	是	RES	否	无
西班牙股指	是	无	否	无
土耳其股指	是	VM7,RES,STM	是	VM7,VM8,RES,STM
立陶宛股指	是	无	否	VM7,VM8,STM
捷克股指	是	VM7,RES,STM	否	无
加拿大股指	是	RES	是	无
哥伦比亚股指	是	无	是	无
菲律宾股指	是	无	否	无
法国股指	是	RES	否	无
比利时股指	是	RES,STM	是	VM7,VM8,RES,STM
澳大利亚股指	是	VM7,RES,STM	否	无
爱沙尼亚股指	是	无	是	RES
冰岛股指	是	RES	是	无
沙特阿拉伯股指	否	无	是	RES,STM
瑞士股指	否	无	是	VM7,VM8,RES,STM
立陶宛股指	否	无	是	VM7,VM8,STM
原油期货价格	是	无	是	无
铜期货价格	是	RES,STM	是	STM
白银期货价格	是	VM8,RES,STM	是	VM7,VM8,RES,STM
标准普尔高盛商品指数	是	无	是	VM7,VM8,RES,STM
路透商品研究局指数	是	RES	是	VM7,VM8,RES,STM
美元（英镑）对港币汇率	是	无	否	无
美元（英镑）对人民币汇率	是	VM7,RES,STM	是	RES,STM
美元（英镑）对印度卢比汇率	是	无	是	无
美元（英镑）对日元汇率	是	RES,STM	否	无
美元（英镑）对加拿大元汇率	是	无	否	无
美元（英镑）对澳大利亚元汇率	是	无	是	VM7,RES,STM
美元（英镑）对瑞典克朗汇率	是	无	是	VM7,VM8,RES,STM
美元（英镑）对新西兰元汇率	是	无	是	无
美元（英镑）对欧元汇率	是	无	否	无
美元（英镑）对丹麦克朗汇率	是	无	是	RES
美元（英镑）对挪威克朗汇率	是	无	是	VM7,VM8,RES,STM
美元（英镑）对瑞士法郎汇率	是	RES,STM	是	无
美元（英镑）对英镑（美元）汇率	否	无	是	VM7,VM8,STM
中国香港 10 年期政府债收益率	是	VM7,RES,STM	是	VM7,VM8,RES,STM
中国 10 年期国债收益率	否	无	是	STM
俄罗斯 10 年期国债收益率	否	无	是	VM7,VM8,RES,STM
加拿大 10 年期国债收益率	是	RES,STM	是	RES,STM
法国 10 年期国债收益率	是	无	是	无
德国 10 年期国债收益率	是	VM7,RES,STM	是	VM7,VM8,RES,STM
英国 10 年期国债收益率	是	RES,STM	是	VM7,VM8,RES,STM
美国 10 年期国债收益率	是	VM7,RES,STM	是	VM6,VM7,VM8,RES,STM
韩国 10 年期国债收益率	是	RES,STM	是	无
英文地区推特文本经济不确定性指数	是	VM7,RES,STM	是	VM7,VM8,STM
美国地区推特文本经济不确定性指数	是	无	是	RES,STM
恐慌指数	是	RES,STM	否	无

注：两个数据集均未通过的因素未列出

其中，**S** 矩阵第一行全 1 行向量，表示原始层分量表示可由分解层的所有分量直接加和得到。第二到四行表示重构层的分量是由分解层的哪些分量聚合而成。倒数后九行的单位矩阵表示底层预测的结构。

4.3 模型设置

运用 Hurst 指数算法识别两个黄金数据集的原始层和重构层中四个分量的记忆性，如表 2 所示。本研究引入数据特征驱动的分解混合预测思想，对具有记忆性的分量即原始分量、LTM 和 MTM 分量指派 SPCA 回归进行预测。SPCA 回归保留与黄金价格序列自身影响相相契合的主要外部市场的金融信息，从而简化模型并提高预测精度；具有反记忆性的分量即 MTM 分量指派 MCP 回归进行预测，MTM 分量包含大量噪声或与某些特征高度相关。MCP 回归的罚函数可以通过减少不相关特征来降低过拟合的风险。分解层的分量的回归方法也按照该分量 Hurst 指数的正负性所指派。

MCP 回归在不同分量上的选择的特征情况如

表 2 分解层 Hurst 指数和分类结果

Hurst 指数	VM1	VM2	VM3	VM4	VM5	VM6	VM7	VM8	RES
芝加哥黄金	0.9937	0.9940	0.9651	0.8438	0.4142	0.1364	-0.0767	-0.0953	-0.0078
分类结果	长期尺度模态（LTM）			中期尺度模态（MTM）			短期尺度模态（STM）		
伦敦黄金	0.9922	0.9952	0.9758	0.8436	0.5993	0.2051	-0.0653	-0.0840	-0.0121
分类结果	长期尺度模态（LTM）			中期尺度模态（MTM）			短期尺度模态（STM）		

表 3 原始层和重构层 Hurst 指数和子模型指派结果

Hurst 指数	原始序列	LTM	MTM	STM
芝加哥黄金	0.4781	0.9735	0.5651	-0.0328
预测子模型	SPCA 回归	SPCA 回归	SPCA 回归	MCP 回归
伦敦黄金	0.4745	0.9794	0.6420	-0.0391
预测子模型	SPCA 回归	SPCA 回归	SPCA 回归	MCP 回归

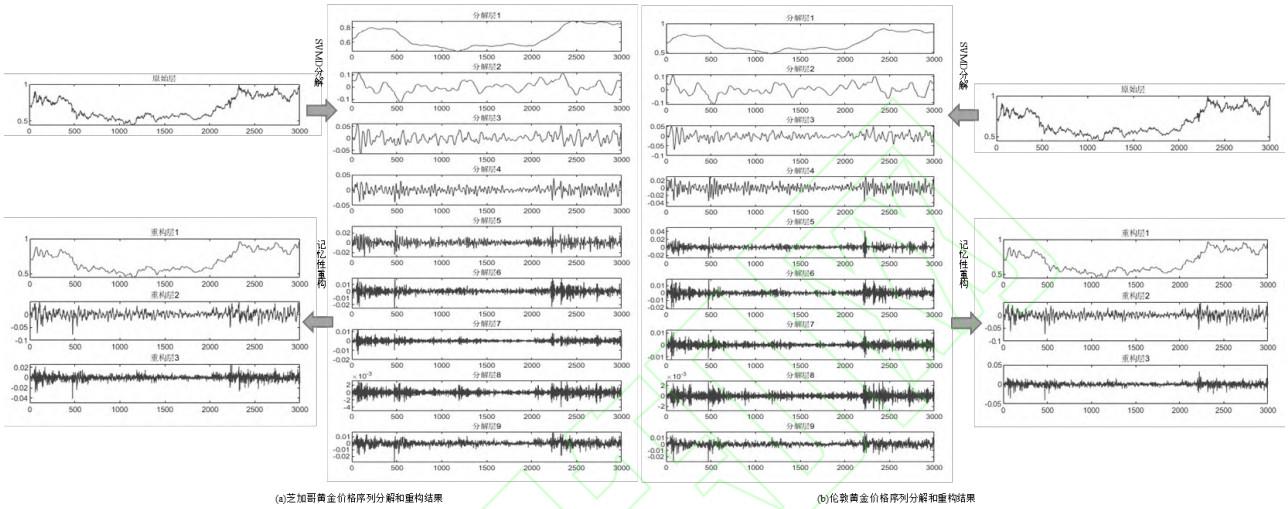

图 4 SVMD 分解和记忆性重构结果

表 1 所示，可以看出在绝大部分情况下 MCP 回归仅在含有反记忆性特征的 MTM、VM8、VM9 和 RES 分量成功地筛选相关特征，印证所提出的混合回归模型差异化特征选择方法的必要性。

为验证所提出分解-重构-集成模型各个步骤的有效性，基于以下考虑将其与各种基准黄金价格预测模型进行纵向比较。为了检验引入外部金融因素的有效性，引入单变量的线性回归（UV-LR）、单变量分解线性回归（SVMD-UV-LR）、单变量分解分层集成回归（LR-HC-minT）与多变量模型进行比较。在多变量的情形下，为了检验 SVMD 分解技术和记忆性重构（MR）的有效性，将 SPCA 和 MCP 两个单模型与分解层模型（SVMD-SPCA、SVMD-MCP）和重构层模型（VMDR-MR-MCP、VMDR-MR-SPCA）模型进行比较。为了检验混合回归的记忆性准则的有效性，引入了分解层的混合回归模型（SVMD-HLR）和重构层的混合线性回归模型（SVMD-MR-HLR）。为了说明样本最小迹（minT-simple）法的分层集成（HE）策略的有效性和混合模型的结合效果，引入基于 SPCA 回归的分层集成模型（SPCA-HE-minT）和基于混合线性回归的分层集成模型（HLR-HE-minT），以及对分量结果使用支持向量机回归（SVR）的非线性集成模型（HLR-SVR）[45]。SVR 结构参数均通过贝叶斯优化取得。对于选对于线性回归和 SPCA 回归的模型，通过网格搜索方法设置各个分量的滞后时间窗口 Q 和降维后主成分个数 R 参数。MCP 回归的正则化参数 λ 和控制凹性参数 γ 通过自适应交叉验证优化取得[46]。上述模型采用 Matlab2023b 和 R 语言进行程序编写。

4.4. 对比实验

4.4.1 分解-重构-分层集成模型结果分析

将本文方法与其他 13 种相关预测模型进行对比分析，表 4 记录两个黄金数据集所有预测模型的评价指标，实证结果显示提出的 HLR-HE-minT 模型在两个黄金数据集的 MAE 为 11.7 左右，方向性预测的准确率达到 60%以上，具有最高的预测精度。表 5 构建了以 UV-LR 为基准模型的 DM 检验，清晰揭示了各模型的优劣，图 6 展示了部分分解混合回归模型和分解分层集成模型与基准模型的预测结果。通过这些结果，具有以下发现：

（1）比较未采用分解技术的单回归模型和分解集成回归模型可以发现，采用分解技术不一定

表 4 各模型黄金价格预测性能评价

数据集	芝加哥黄金				伦敦黄金			
预测模型	MSE	MAE	D_{stat}(%)	D/M	MSE	MAE	D_{stat} (%)	D/M
UV-LR	296.8443	12.8515	53.78	76.28	274.7381	12.3111	52.44	77.61
SVMD-UV-LR	292.1239	12.8125	52.89	75.23	273.7696	12.2915	52.22	77.39
MV-MCP	297.8840	12.8130	51.11	72.74	277.8917	12.3349	46.89	69.29
MV-SPCA	271.4506	12.8347	58.41	82.85	259.1138	12.5937	58.67	84.66
SVMD-MCP	287.3581	12.6657	56.00	80.55	259.1964	11.9655	56.89	86.54
SVMD-SPCA	278.3768	12.7978	56.22	80.04	266.1858	12.1785	58.00	86.71
SVMD-HLR	268.7421	12.3836	57.78	85.05	254.4346	11.9089	59.78	91.38
SVMD-MR-MCP	296.8475	13.0529	50.89	71.07	269.2959	12.2898	55.33	82.05
SVMD-MR-SPCA	269.4559	12.5037	56.67	82.59	257.7426	11.9982	56.44	85.65
SVMD-MTD-HLR	260.2057	12.1709	58.67	87.87	249.7207	11.8350	59.56	91.64
HLR-SVR	334.6570	14.0353	59.56	77.08	291.7949	13.0435	58.89	82.11
LR-HE-minT	295.2399	12.8258	53.11	67.44	274.6680	12.2752	54.89	81.44
SPCA-HE-minT	244.5891	11.8052	61.50	92.95	239.7896	**11.6965**	61.56	95.81
HLR-HE-minT	**242.1298**	**11.7271**	**62.44**	**97.07**	**236.9659**	11.7071	**62.00**	**96.43**

注:加粗代表最优结果;下划线代表次优结果,下同.

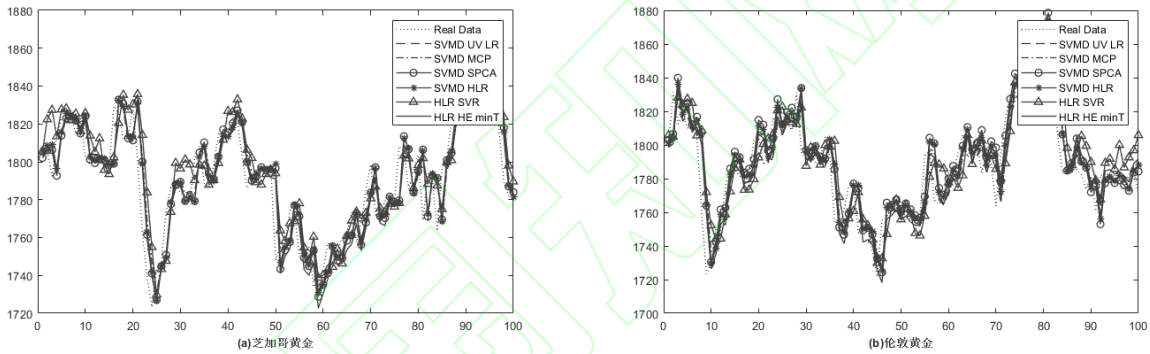

图 5 黄金价格预测结果

会获得更高的预测精度。在单变量情形下，SVMD-UV-LR 在水平精度上略优于 UV-LR 模型，但是在方向精度下略差。在考虑金融因素多变量的范式下，SVMD 的引入改善了 MCP 回归的预测结果。因为从表 1 可以看出 MCP 回归并没有在原始分量成功筛选出相关因素，而在某些复杂的分解分量展现了嵌入式特征选择的能力。以芝加哥黄金价格预测结果为例，MV-SPCA 回归的 D/M 指标为 76.28，而 SVMD-SPCA 的 D/M 指标为 75.23，表明使用 SVMD 后预测效果变差。因此，分解层预测并不一定比原始层预测表现更佳，从而使得采用分层集成联合多层的预测结果具有必要性。

（2）比较记忆性驱动的混合回归模型和单分解回归模型可以发现，在两个黄金价格数据集中，采用基于记忆性的指派回归模型均可以提升预测精度。在分解层的预测结果，混合回归的使用使 SVMD-HLR 的平均 MSE 误差相较 SVMD-MCP 和 SVMD-MCP 分别改善 4.17%和 4.03%；在重构层的预测结果，SVMD-HLR 的平均 MSE 误差相较 SVMD-MCP 和 SVMD-MCP 分别改善 10.09%和 3.32%。

（3）比较使用记忆性重构模型和分解回归模型可以发现，采用重构技术可能会进一步提升预测精度。重构技术是否有效也与回归模型有关，其中，基于 SPCA 模型在重构分量的预测上表现较佳，在两个数据集的平均 MSE 误差较少 3.29%；基于 MCP 模型的在重构分量的预测上表现较差，在两个数据集的平均 MSE 误差增加 3.47%。但二者的混合模型在重构层的整体表现较好，要优于最佳的单模型 SPCA 模型。进一步说明了基于记忆性重构和基于记忆性指派的准则设计是有效的。

（4）比较分层集成模型和其他层次的模型可以发现，在多变量的情形下，采用分层集成模型，可有效地提高预测精度。从 D/M 指标上可以看出，在自回归范式下采用分层集成，并没有比分解层和原始层表现得更好。而在多变量情形下，使用

SVM 进行非线性集成发生了过拟合现象，其预测结果相对采用直接加总集成的 SVMD-HLR 模型表现更差。而本文提出的 SPCA-HE-minT 模型比原始层、分解层、重构层模型在两个数据集的平均 MSE 误差较少 9.52%、12.41%和 8.82%；HLR-HE-minT 模型比原始层、分解层、重构层模型在两个数据集的平均 MSE 误差较少 10.73%、9.18%和 6.42%。此外，在伦敦黄金数据集上，基于 SPCA 模型在 MAE 预测指标达到最优，芝加哥黄金数据集上四项相关预测指标也较为接近。这说明分层集成主要是依赖于 SPCA 的回归性能，与记忆性指派的混合回归模块对于性能对预测提升是相对独立的。

（5）从表 5 的 DM 统计检验结果来看，除 MCP 回归在伦敦黄金数据集上表现较佳之外，传统的单变量模型和单变量分解集成模型相对于自回归预测而言其改进是有限的。本文提出的混合回归模型在分解层和重构层都显著优于单变量回归模型，同时，多变量的分层集成模型在水平精度上极显著优于单变量回归模型。说明提出的记忆性驱动的混合回归策略和分层集成策略在多变量情境下的性能提升是稳健的。在多变量情境下，基于 SVM 对 HLR 预测结果进行非线性集成在芝加哥黄金数据集上显著差异差于 UV-LR，这表明应用在黄金市场上非线性分量集成方案存在极大的不确定性风险。

表 5 DM 检验结果

预测模型	芝加哥黄金	伦敦黄金
SVMD-UV-LR	-0.384	0.480
MV-MCP	-0.504	0.249
MV-SPCA	-0.003	0.859
SVMD-MCP	-1.091	-2.257*
SVMD-SPCA	-0.152	-0.786
SVMD-HLR	-2.263*	-2.837**
SVMD-MR-MCP	1.274	-0.154
SVMD-MR-SPCA	-1.131	-1.584
SVMD-MTD-HLR	-3.181***	-3.173**
HLR-SVR	2.867**	1.935
LR-HE-minT	-0.521	-0.913
SPCA-HE-minT	-3.435***	-3.023**
HLR-HE-minT	-4.392***	-3.017**

注:*、**、***代表结果在 5%、1%、1‰显著性水平

4.4.2 分解方案对比

为了展现 SVMD 技术改进的差异性，以及使用分解边界建模的优越性。将 SVMD 分解与固定频率、固定迭代次数和原始版本 VMD（FixfreVMD、FixloopVMD 和 OriginVMD）进行比较。此外，还对比了一些常见分解方法，包括 EMD[16]、ICEEMDAN[20]、奇异值分解（SVD）[24]、小波分解（WT）[47]。其中，EMD 和 ICEEMDAN 的分解个数为其逐步分解不再产生多余的虚假分量的最小值（K=7）。为保证比较的公平性，所有分解方法的分解个数与 EMD 和 ICEEMDAN 保持一致。分量预测的子模型均设定为性能稳定的线性回归（LR）模型。表 6 各分解方案下黄金价格预测性能评价时展示以分解的原始分量作为输入（记为 C）和以分解分量的边界作为输入（记为 B）的结果。为了直观地显示 SVMD 分解的优越性，展示了对比的分解技术前 500 个点的分解结果。从图 6 可以看出，对比分解方案的分量边界的都在逐步分解过程种产生了不规则的尖峰或者毛刺现象，而 SVMD 分解后的分量的波动更稳定、规律性更强，说明 SVMD 技术修正了逐次分解结果产生的大幅度漂移现象。

从表 6 的预测结果可以发现，提出的 SVMD 技术相对传统分解技术、VMD 的原始版本和仅调整部分优化过程的版本具有更好的预测精度，因此保持逐步分解目标序列的平滑性和稳定性是必要的。而且可以看出，VMD 技术在未进行边界修正之前相对 ICEEMDAN 分解技术的边界效应问题更严重，这解释了为什么具有精确频域分割的 VMD 算法与经验性的时域分解在预测性能未能达成共识的争议[48]。在水平精度上，排在第二名的是 SSA 分解技术，但由于分解边界形状呈现阶跃形状，其预测方向精度较低。EMD 分解方法的水平预测性能表现最差，由于同时存在的模态混叠和边界效应问题，不适用于复杂度高的黄金价格时间序列预测。此外，稳定的 VMD 框架下，分解边界建模策略在水平精度将优于传统基于分量建模预测策略，而在其他分解方法框架下采用何种建模策略没有统一的定论。

4.4.3 预测器选择

为验证在本文提出的稳定分解-重构-分层集成框架中，使用混合线性回归模型对多变量黄金数据进行多尺度建模的合理性，将选用的 SPCA 回归和 MCP 回归的分量预测子模型替换成其他模型进行横向对比。基准子模型包括四种基于树的集成模型（RF、GBDT、XGBoost、LightGBM）[42]，广义自回归神经网络（GRNN）[49]、支持向量机（SVM）[50]、两种深度学习模型（LSTM、GRU）[20,23]和三种回归模型（PLS、Lasso、PCA）[51]，其中 SVM 和 RF 模型使用特征递归消除（RFE）做了进一步的特征选择，各个子预测器在 SVMD 框架下的预测性能如表 7 所示。

从各个指标结果可以看出，在 SVMD 框架下，

表 6 各分解方案下黄金价格预测性能评价

数据集	芝加哥黄金				伦敦黄金			
预测模型	MSE	MAE	D_{stat}(%)	D/M	MSE	MAE	D_{stat}(%)	D/M
SVMD-C-LR	327.8487	13.8126	52.22	68.79	275.7883	12.3317	53.22	75.51
SVMD-B-LR	**298.0214**	**12.9116**	51.11	**72.15**	**274.7381**	**12.3111**	52.44	**77.61**
FixFreVMD-C-LR	330.0396	13.8498	51.56	67.73	294.4208	13.1148	51.33	71.29
FixFreVMD-B-LR	322.5728	13.5973	51.78	**69.29**	296.4623	13.1438	52.67	72.99
FixloopVMD-C-LR	423.1488	15.7798	**54.89**	63.22	325.7307	13.6047	52.00	69.58
FixloopVMD-B-LR	429.6582	15.7663	52.00	59.98	404.1694	15.2342	52.67	63.02
OriginVMD-C-LR	536.3667	17.8578	51.78	52.69	368.2220	14.5860	50.89	63.45
OriginVMD-B-LR	461.9472	16.5685	52.44	57.54	459.9807	16.6394	**53.33**	58.37
ICEEMDAN-C-LR	385.6285	15.0648	50.44	61.09	335.4319	14.0542	50.22	65.13
ICEEMDAN-B-LR	399.0081	15.0950	55.11	66.45	366.6509	14.3582	53.11	67.32
EMD-C-LR	515.4149	17.3192	52.89	55.49	2767.7068	40.8141	51.33	22.99
EMD-B-LR	539.5172	18.0621	45.78	46.24	571.5142	18.8239	48.44	46.95
DWT-C-LR	395.1280	15.1754	50.00	60.02	343.6984	13.9168	**53.33**	69.78
DWT-B-LR	377.0423	14.6884	52.89	65.54	363.1614	14.5267	52.44	65.75
SSA-C-LR	407.4101	16.0148	46.00	52.39	320.8109	14.1457	47.33	61.01
SSA-B-LR	308.0430	13.6496	46.89	62.69	325.8507	13.8043	47.11	62.30

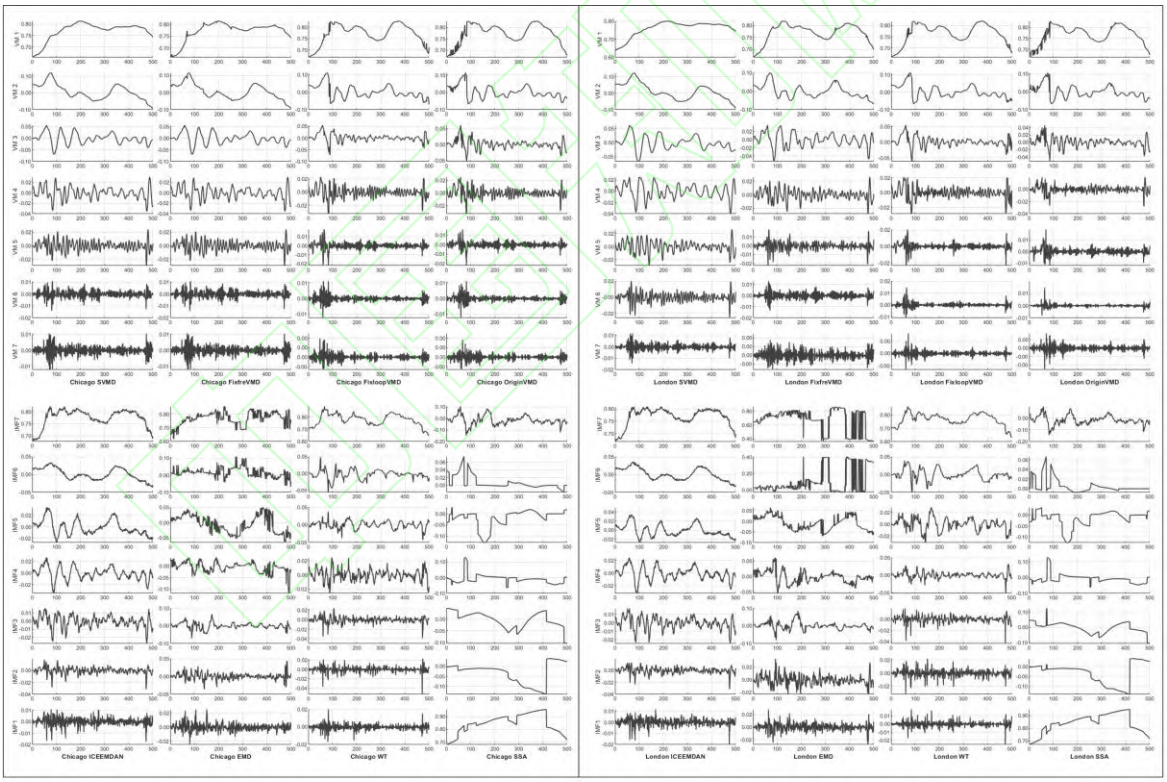

(a)芝加哥黄金价格分解结果　　(b)伦敦黄金价格分解结果

图 6 各分解技术的分解边界

以 SPCA 为代表的降维回归在芝加哥数据集表现较好，而在以 MCP 为代表的收缩回归在伦敦黄金数据集表现较好，这说明综合不同特征选择的优势所构建的混合线性模型在不同的数据集可以保持较高的泛化能力。此外，在回归模型中，PLS、PCA 和 Lasso 均在水平精度等指标稍弱于 SPCA 和 MCP 模型，说明本文模型具有更好的滤掉噪声特征的能力。在机器学习模型中，SVM-RFE 模型表现较佳，其次是 LSTM 和 GRNN 神经网络表现居中，而树集成模型表现最差。本文所选用的线性模型在 D/M 指标上明显地击败了传统的非线性模型和传统的特征选择回归模型，将其选择为各分量的预测器是合理的。

表 7 SVMD 框架下各预测器对于黄金价格预测性能评价

数据集	芝加哥黄金				伦敦黄金			
预测模型	MSE	MAE	D_{stat}(%)	D/M	MSE	MAE	D_{stat}(%)	D/M
SVMD-RF-RFE	420.9253	15.4028	**57.11**	67.81	518.0661	17.9090	49.11	49.89
SVMD-GBDT	336.0971	13.8461	53.78	70.73	356.0066	14.3416	54.67	69.32
SVMD-XGBoost	347.8793	14.1455	50.89	65.41	327.9640	13.7461	53.56	70.84
SVMD-LightGBM	329.3842	13.8780	51.78	67.86	308.1727	13.3176	54.00	73.69
SVMD-SVM-RFE	289.6998	12.8452	53.33	75.68	269.1036	12.1347	55.78	83.67
SVMD-GRNN	293.9155	12.8797	52.67	74.44	284.5915	12.7583	51.33	73.24
SVMD-LSTM	292.0098	12.8331	53.56	76.01	271.7906	12.3726	54.67	80.43
SVMD-GRU	332.5922	13.9642	53.11	69.13	292.2901	12.8820	54.00	76.09
SVMD-PLS	292.1650	12.8039	53.56	76.23	274.6803	12.3561	52.67	77.60
SVMD-Lasso	290.4264	12.7861	53.78	76.64	259.1964	12.1021	56.89	85.51
SVMD-MCP	287.3581	12.6657	56.00	**80.55**	**258.9699**	**11.9655**	57.56	**87.55**
SVMD-PCA	284.7331	12.8539	56.44	80.02	271.6163	12.4526	55.11	80.52
SVMD-SPCA	**278.3768**	12.7978	56.22	80.04	266.1858	12.1785	**58.00**	86.71

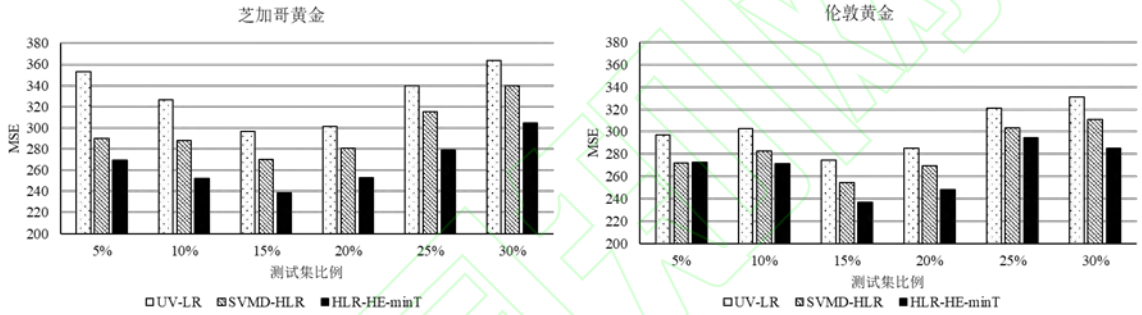

图 7 不同测训比下回归模型稳健性

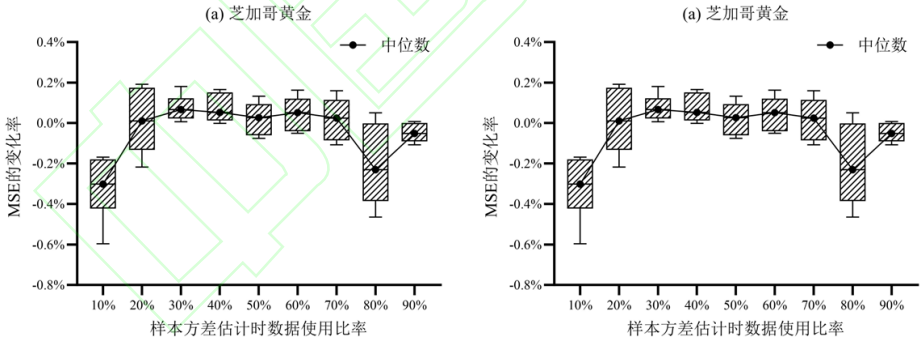

图 8 不同数据量估计下分层预测模型稳健性

4.4.4 稳健性检验

为了检验稳定分解-重构-分层集成模型的稳健性，本文从划分不同训练集测试集比例和分层方差估计的样本参数敏感性分析两个方面开展实验。首先，将训练集和测试集的比例由 95:5 调整到 70:30，主要观察在不同测试集比例下观察基于记忆性多变量分解混合回归预测模型和分层混合回归模型的预测是否持续优于单变量回归模型。如图 7 预测结果显示，SVMD-HLR 模型总是优于 UV-LR 模型，证明了本文提出的混合回归模型能够较好利用多变量信息增强预测性能的结论；除伦敦黄金数据集 5%测试集比例情形下外，HLR-HE-minT 模型通常优于 SVMD-HLR 模型，证明了分层集成方案能够进一步通过原始层和重构层的黄金价格预测弥补仅通过分解层预测的不足，无需人工干预即可选定使得预测效能最大化的层级信息。此外，训练集长度也可能作为一种特殊的超参数，影响分层集成中公式(17)的样本协方差估计情况。通过变换估计样本协方差使用的数据量比例，在不同测训比下测算了使用部分近邻样本相对采用当前的全部可用样本的分层集成的水平精度的 MSE 变化百分比。图 8 展示通过箱形图

展示了使用 10%到 90%的数据量比例的影响不超过 0.6%，说明分层集成方案具有稳健性。

5 结语

在全球经济和金融市场持续动荡的背景下，黄金价格的形成机制愈发复杂，其波动特征是黄金商品属性与金融属性等多重因素在不同时间频率尺度上交织作用的结果。本研究秉持多尺度分解建模的核心理念，通过提出稳定变分模态分解（SVMD）并引入记忆性重构技术，为黄金价格序列构建了多层次的聚合结构，从而为多尺度分量下差异化的影响因素信息融合搭建了集成平台。这一创新不仅显著提升了黄金价格预测的准确性，也为“分解-重构-集成”的预测范式注入了新的理论活力与实践方法论。

在对两个国际黄金市场的价格序列数据进行深入的实验分析后，表现最佳的模型的分解分层集成的混合线性回归模型预测机制和理论优劣如下。第一，利用 SVMD 技术对黄金价格序列进行分解频率不变的稳定分解，显著改善了逐次分解过程中的边界效应，从而确保了分量边界的稳定性高度的鲁棒性和稳定性。尽管 SVMD 技术提升了分量边界的稳定性增强挖掘边界建模范式的预测潜力，但单变量分解模型在黄金价格预测中并未显示出对基于市场价格序列建模的明显优势，这一发现与黄金市场具有弱式有效性的理论相吻合[52]。而 SVMD 技术在多变量分解混合模型和分层集成模型中的应用，显著提升了模型的预测精度，反映出分解模型的理论优势主要得益于对外部金融数据在多层次下的综合考量。第二，模型采用 Hurst 指数对分解后的分量进行记忆性分类，并采用不同的回归模型对不同记忆特性的分量进行预测，能够明显提升单一模型的预测精度。这一实践验证了记忆性作为黄金价格分解预测中一种高效、可行的分量重构与模型指派准则。混合回归模型的优势在于分别部署了缩放主成分分析回归和最小最大凹度惩罚回归，在不同记忆特性时间尺度上学习差异化的数据特征。第三，应用分层集成方案，能将原始层、分解层和重构层黄金价格与影响因素间的非线性特征进行有效整合，形成最佳协调预测。这种方法的理论优势在于通过协方差矩阵信息捕捉分解范式下不同层次之间分量预测的相关性，确保不同尺度的细粒度序列的预测值加起来与聚合序列的预测值相匹配，从而提高预测的一致性和准确性。

本文存在如下进一步研究方向：首先，鉴于本研究重点关注混合线性回归方案在多变量分解框架中的有效性，对非线性模型的探索略显不足，因此未来研究可进一步探索 SPCA 与 MCP 模型与机器学习技术的深度融合，加强对复杂性较强的分量的非平稳性、非线性数据特性的刻画。其次，从双元分解与多元分解的信号分解原理出发，拓展 SVMD 分解技术在区间值预测及高度耦合多输出值预测领域的应用，亦是一个值得深入研究的方向。

参考文献

[1] 谭德凯,田利辉. 黄金是股票市场的“避险天堂”吗?——基于动态条件相关混频数据抽样模型[J]. 中国管理科学, 2022, 30(10): 14-24.
Tan Dekai, Tian Lihui. Is Gold a Safe Haven of the Stock Market?——Based on Dynamic Conditional Correlation Mixed Data Sampling Model[J]. Chinese Journal of Management Science, 2022, 30(10): 14-24.

[2] Viktor K. Role of gold in foreign exchange reserves of commodity exporting countries[J]. Journal of European Economy, 2021, 20(2): 211-232.

[3] Serkan A, Barry E, Chima S B. Gold as international reserves: A barbarous relic no more?[J]. Journal of International Economics, 2023, 145: 103822.

[4] Debidutta P, Hassan M K, DSouza A, et al. Investment in gold: A bibliometric review and agenda for future research[J]. Research in International Business and Finance, 2023, 64: 101854.

[5] 郭杨莉,马锋. 基于马尔科夫和混频数据模型的黄金期货市场波动率预测研究[J]. 中国管理科学, 2024, 32(1): 13-22.
Yangli Guo, Feng MA. Forecasting the Chinese Gold Futures Market Volatility Using Markov-Switching Regime and Mixed Data Sampling Model[J]. Chinese Journal of Management Science, 2024, 32(1): 13-22.

[6] 吕永健,符廷銮,胡颖毅,等. 基于拔靴滤波历史模拟法的黄金市场 VaR 测度研究[J]. 中国管理科学, 2019, 27(07): 46-55.
Lyu Yongjian, Fu Tingluan, Hu Yingyi, et al. A Study of Risk Measurements of Chinese Gold Market based on Bootstraped Filtered Historical Simulation Approaches[J]. Chinese Journal of Management Science, 2019, 27(7): 46-55.

[7] 范彩云,童君逸,程俊彦,等. 基于ML-DMA的黄金期货价格预测研究[J]. 数理统计与管理, 2024, 43(03): 541-558.
Fan Caiyun, Tong Junyi, Cheng Junyan, et al. Gold futures price forecasting based on ML-DMA[J]. Journal of Applied Statistics and Management, 2024, 43(03): 541-558.

[8] 王海燕, 盛昭瀚. 大数据驱动的复杂系统管理情景建模：技术与流程[J]. 中国管理科学, 2025, 33(1): 22-33.
Wang Haiyan, Sheng Zhaohan. Modeling of Complex System Management Scenarios Driven by Big Data: Techniques and Processes[J]. Chinese Journal of Management Science, 2025, 33(1): 22-33.

[9] 王方, 张颂扬, 余乐安, 等.数据特征驱动的单变量预测建模研究. 计量经济学报, 2024, 4(4): 1124-1148.
Wang Fang, Zhang Songyang, Yu Le-an, et al. Data-Trait-Driven univariate predictive modeling[J]. China Journal of Econometrics, 2024, 4(4): 1124-1148.

[10] Yu L A, Wang Z S, Tang L. A decomposition-ensemble model with data-characteristic-driven reconstruction for crude oil price forecasting[J]. Applied Energy, 2015, 156: 251-267.

[11] 柴建,寇红红. 基于 TEI@I 方法论的系统管理预测技术研究综述及展望[J]. 管理评论, 2020, 32(7): 280-292.
Chai Jian, Kou Honghong. Review and prospect of system management prediction technology based on TEI@I methodology[J]. Management Review, 2020, 32(7): 280-292.

[12] 高晓辉,周坤,李廉水. 基于 XGBOOST 和 ELM 的混合空气质量预警系统：以南京为例[J]. 中国管理科学, 2023, 31(05): 269-278.
Gao Xiaohui, Zhou Kun, Li Lianshui. Hybrid Air Quality Early Warning System Based on XGBoost and ELM: A Case Study of Nanjing[J]. Chinese Journal of Management Science, 2023, 31(5): 269-278.

[13] 曾能民,张明,余乐安. 基于“拆分-填充-分解-集成”的我国线上零售额预测研究[J]. 中国管理科学, 2022, 30(12): 63-76.
Zeng Nengmin, Zhang Ming, Yu Lean. Forecasting Online Retail Sales of China Based on Splitting-filling-decomposition-ensemble Model[J]. Chinese Journal of Management Science, 2022, 30(12): 63-76.

[14] 梁小珍,赵欣,杨明歌,等. 基于二次分解和模型选择策略的港口集装箱吞吐量组合预测[J]. 管理评论, 2024, 36(08): 52-64.
Liang Xiaozhen, Zhao Xin, Yang Mingge, et al. Combination Forecast Method of Port Container Throughput Based on Secondary Decomposition and Model Selection Strategy[J]. Management Review, 2024, 36(8): 52-64.

[15] 李霞,李守伟. 基于 EMD 与 DVG 的非线性时间序列预测模型及其应用研究[J]. 中国管理科学, 2022, 30(09): 275-286.
Li xia, Li shouwei. Non-linear Time Series Prediction Model Based on EMD and DVG and Its Application[J]. Chinese Journal of Management Science, 2022, 30(9): 275-286.

[16] 杨晨,陈贵词. 基于 EMD-LSTM 的国际黄金期货价格预测[J]. 中南民族大学学报(自然科学版), 2023, 42(6): 857-864.
Yang Chen, Chen Guici. International gold futures price forecast based on EMD-LSTM[J]. Journal of South-central Minzu University(Natural Science Edition), 2023, 42(6): 857-864.

[17] Yang M, Wang R T, Zeng Z X, et al. Improved prediction of global gold prices: An innovative Hurst-reconfiguration-based machine learning approach[J]. Resources Policy, 2024, 88: 104430.

[18] 何林芸. 基于 ICEEMDAN-SE-SSA-ELM 算法的黄金期货价格预测[J]. 兰州文理学院学报(自然科学版), 2023, 37(01): 35-39.
He Linyun. Gold futures price forecast based on ICEEMDAN-SE-SSA-ELM algorithm[J]. Journal of Lanzhou University of Arts and Science(Natural Sciences), 2023, 37(01): 35-39.

[19] Lu W B, Qiu T T, Shi W H, et al. International gold price forecast based on CEEMDAN and support vector regression with grey wolf algorithm[J]. Complexity, 2022, 2022(1): 1511479.

[20] Liang Y H, Lin Y, Lu Q. Forecasting gold price using a novel hybrid model with ICEEMDAN and LSTM-CNN-CBAM[J]. Expert Systems with Applications, 2022, 206: 117847.

[21] 秦全德,黄兆荣,周至昊,等. 基于包络熵的双层分解流感预测模型研究[J]. 系统工程理论与实践, 2023, 43(12): 3505-3518.
Qin Quande, Huang Zhaorong, Zhou Zhihao, et al. A two-layer decomposition model based on envelope entropy for influenza forecasting[J]. Systems Engineering - Theory & Practice, 2023, 43(12): 3505-3518.

[22] 陈凯杰,唐振鹏,吴俊传,等. 贵金属期货价格预测方法及实证研究[J]. 中国管理科学, 2022, 30(12): 245-253.
Chen Kaijie, Tang Zhenpeng, Wu Junchuang, et al. Prediction method and empirical study of precious metal futures price[J]. Chinese Journal of Management Science, 2022, 30(12): 245-253.

[23] E J W, Ye J M, Jin H H. A novel hybrid model on the prediction of time series and its application for the gold price analysis and forecasting[J]. Physica A-statistical Mechanics and Its Applications, 2019, 527: 121454.

[24] 范丽伟,董欢欢,渐令. 基于滚动时间窗的碳市场价格分解集成预测研究[J]. 中国管理科学, 2023, 31(01): 277-286.

Fan Liwei, Dong Huanhuan, Jian Ling. A decomposition ensemble model with sliding time window for forecasting carbon market prices[J]. Chinese Journal of Management Science, 2023, 31(01): 277-286.

[25] Chen Y S, Yu S, Islam S, et al. Decomposition-based wind power forecasting models and their boundary issue: An in-depth review and comprehensive discussion on potential solutions[J]. Energy Reports, 2022, 8: 8805-8820.

[26] Rahim B, Mohammad T A, Jan A. Coupling a hybrid CNN-LSTM deep learning model with a boundary corrected maximal overlap discrete wavelet transform for multiscale lake water level forecasting[J]. Journal of Hydrology, 2021, 598: 126196.

[27] 崔明明,刘晓亭,李秀婷,董纪昌. 数据特征驱动的房地产市场集成预测研究[J]. 管理评论, 2020, 32(7): 89-101.
Cui Mingming, Liu Xiaoting, Li Xiuting, Dong Jichang. Integrated Data Characteristic Driven Forecasting Research on Real Estate Market[J]. Management Review, 2020, 32(7): 89-101.

[28] Yu L A, Ma M Y. A memory-trait-driven decomposition – reconstruction – ensemble learning paradigm for oil price forecasting[J]. Applied Soft Computing, 2021, 111: 107699.

[29] 王方,赵桉坤,余乐安.数据特征驱动的新能源汽车月度销量二次分解集成预测[J/OL].中国管理科学,1-15.https://doi.org/10.16381/j.cnki.issn1003-207x.2023.2035.
Wang Fang, Zhao Ankun, Yu Lean. Quadratic decomposition-ensemble method for multi-step forecast of monthly sales volume of new energy vehicles[J/OL]. Chinese Journal of Management Science, 1-15. https://doi.org/10.16381/j.cnki.issn1003-207x.2023.2035.

[30] Yu L A, Liang S D, Chen R D, et al. Predicting monthly biofuel production using a hybrid ensemble forecasting methodology[J]. International Journal of Forecasting, 2022, 38(1): 3-20.

[31] 秦全德,黄兆荣,黄凯珊. 一种基于局部回归的多尺度碳市场价格预测模型研究[J]. 运筹与管理, 2022, 31(1): 107-114.
Qin Quande, Huang Zhaorong, Huang Kaishan. A multi-scale carbon price forecasting model with local regression approach[J]. Operations Research and Management Science, 2022, 31(1): 107-114.

[32] George A, Rob J H, Nikolaos K, et al. Forecast reconciliation: A review[J]. International Journal of Forecasting, 2024, 40(2): 430-456.

[33] Dragomiretskiy K, Zosso D. Variational Mode Decomposition[J]. IEEE Transactions on Signal Processing, 2014, 62(3): 531-544.

[34] Huang D S, Jiang F W, Li K P, et al. Scaled PCA: A new approach to dimension reduction[J]. Management Science, 2021, 68(3): 1678-1695.

[35] Wang J Q, Guo X Z, Tan X P, et al. Which exogenous driver is informative in forecasting European carbon volatility: Bond, commodity, stock or uncertainty?[J]. Energy Economics, 2023, 117: 106419.

[36] He M X, Zhang Y J, Wen D Y, et al. Forecasting crude oil prices: A scaled PCA approach[J]. Energy Economics, 2021, 97: 105189.

[37] Zhang C H. Nearly unbiased variable selection under minimax concave penalty[J]. The Annals of Statistics, 2010, 38(2): 894-942.

[38] 罗孝敏,彭定涛,张弦. 基于 MCP 正则的最小一乘回归问题研究[J]. 系统科学与数学, 2021, 41(8): 2327-2337.
Luo Xiaomin, Peng Dingtao, Zhang Xian. On least absolute deviation regression problems with MCP Regularization[J]. Journal of System Science and Mathematical Science Chinese Series, 2021, 41(8): 2327-2337.

[39] Maur I F L, Erick M,Fernando L C O. Forecasting unemployment in Brazil: A robust reconciliation approach using hierarchical data[J]. Socio-economic Planning Sciences, 2022, 82: 101298.

[40] George A, Roman A A, Rob J H. Hierarchical forecasts for Australian domestic tourism[J]. International Journal of Forecasting, 2009, 25(1): 146-166.

[41] Shanika L W, George A, Rob J H. Optimal forecast reconciliation for hierarchical and grouped time series through trace minimization[J]. Journal of the American Statistical Association, 2019, 114(526): 804-819.

[42] Gil C, Avishay A. Forecasting gold price using machine learning methodologies[J]. Chaos, Solitons & Fractals, 2023, 175: 114079.

[43] Remzi G, Elie B, Eray G. Can Twitter-based economic uncertainty predict safe-haven assets under all market conditions and investment horizons?[J]. Technological Forecasting and Social Change, 2022, 185: 122091.

[44] Hong Y R, Feng M, Wang L, et al. How does the COVID-19 outbreak affect the causality between gold and the stock market? New evidence from the extreme Granger causality test[J]. Resources Policy, 2022, 78: 102859.

[45] 蔡超敏,凌立文,牛超,等. 国内猪肉市场价格的 EMD-SVM 集成预测模型[J]. 中国管理科学, 2016, 24(S1): 845-851.
Cai Chaomin, Ling Liwen, Niu Chao, et al. Integration Prediction of Domestic Pork Market Price Based on Empirical Mode Decomposition and Support Vector Machine[J]. Chinese Journal of Management Science, 2016,

24(S1): 845-851.

[46] Xiao N, Xu Q S. Multi-step adaptive elastic-net: Reducing false positives in high-dimensional variable selection[J]. Journal of Statistical Computation and Simulation, 2015, 85(18): 3755-3765.

[47] 刘金培,罗瑞,陈华友,等. 非结构化数据驱动的混合二次分解汇率区间多尺度组合预测[J]. 中国管理科学, 2023: 60-70.
Liu Jinpei, Luo Rui, Chen Huayou, et al. Multi-scale Combination Forecasting of Interval Exchange Rate with Hybrid Secondary Decomposition Driven by Unstructured Data[J]. Chinese Journal of Management Science, 2023, 31(6): 60-70.

[48] Zhou F T, Huang Z H, Chang H. Carbon price forecasting based on CEEMDAN and LSTM[J]. Applied Energy, 2022, 311: 118601.

[49] Pan W T. Mixed modified fruit fly optimization algorithm with general regression neural network to build oil and gold prices forecasting model[J]. Kybernetes, 2014, 43(7): 1053-1063.

[50] Wen F H, Yang X, Xu G, et al. Multi-Scale volatility feature analysis and prediction of gold price[J]. International Journal of Information Technology & Decision Making, 2016, 16(01): 205-223.

[51] Roh T Y, Lee B Y, Xu Y H. Extracting gold risk premium via dimension reduction tools: implication on the gold－inflation relationship[J]. Applied Economics Letters, 2024: 1-10.

[52] Anu V, Parthajit K, Moinak M. How good are different machine and deep learning models in forecasting the future price of metals? Full sample versus sub-sample[J]. Resources Policy, 2024, 92: 105040.

Hybrid Multivariate Regression Forecasting for Gold Prices: A Decomposition-Reconstruction-Ensemble Methodology

Huang Zhaorong[1], Song Zhengyang[1], Yang Bo[1, 2], Zeng Nengmin[3, 4], Yu Lean[1,2],

1.Business School, Sichuan University, Chengdu 610065, China;

2. Technology Finance Key Laboratory of Sichuan Province, Sichuan University, Chengdu 610065, China

3. School of Economics and Management, Harbin Engineering University. Harbin 150001, China;

4. Key Laboratory of Big Data and Business Intelligence Technology (Harbin Engineering University), Ministry of Industry and Information Technology. Harbin 150001, China）

Abstract: The pricing mechanism of gold assets is particularly complex, and it is difficult to fully reveal the rich multidimensional information contained in its inherent feature space through a univariate time series analysis framework. This article proposes a hybrid regression model with robust decomposition and hierarchical integration strategies for gold price prediction from the perspective of decomposition-reconstruction-ensemble, effectively exploring the synergistic effects of mixed financial influencing factors at different time scales. Firstly, a stable variational mode decomposition (SVMD) technique was developed to extract the stable center frequency component boundaries of the gold price sequence for continuous feature learning. Then, using the Hurst exponent as a memory reconstruction index, the decomposition boundary is reconstructed into short-term, medium-term, and long-term scale components. Subsequently, utilizing the advantages of feature selection from scaled principal component analysis regression and minimum maximum concavity penalty regression, a hybrid linear regression (HLR) was constructed to extract important financial features for prediction at different time scales, thereby improving the overall prediction generalization ability. Finally, the hierarchical ensemble method integrated the prediction results of the original layer, reconstruction layer, and component layer to obtain a reconciliatory gold price prediction value. The effectiveness of the proposed model in the three steps of decomposition, reconstruction, and ensemble was validated on the international gold futures price dataset, and the advantages of the proposed model were compared with various prediction models and decomposition modeling strategies in existing research.

Keywords: gold price prediction; hybrid regression model; decomposition and ensemble; variational mode decomposition; hierarchical ensemble